一、考核说明

本课程期末考核采用项目实践方式。学生以 2-3 人为一组，完成一个大数据处理与分析项目，并提交项目报告书和源代码。

项目可使用 **Java、Python 或 Scala 语言**编写。每组**需使用 HDFS** 存储数据，并**使用 MapReduce、Spark 或 Flink 中至少一种技术**完成主要计算任务。若算力有限，可选取部分数据进行实验，但需在报告中说明所使用的数据范围。

二、项目选题

以下 3 个题目可任选其一，也可根据个人兴趣自拟选题。自拟选题需在报告中说明数据来源。

选题 1：新能源汽车保有量与车型结构分析

数据集：Washington State Electric Vehicle Population Data（https://data.wa.gov/Transportation/Electric-Vehicle-Population-Data/f6w7-q2d2）

任务说明：对美国华盛顿州新能源汽车注册数据进行分析，统计不同地区、品牌、车型和车辆类型的分布情况。

可选统计指标：

- 不同城市新能源汽车数量排名；
- 不同品牌的车辆数量 Top10；
- 不同车型年份的车辆数量分布；
- 纯电动车与插电式混合动力车数量对比。

选题 2：开发者技术生态与 AI 工具使用分析

数据集：Stack Overflow Developer Survey 2025（https://github.com/StackExchange/Survey）

任务说明：对 2025 年 Stack Overflow 开发者调查数据进行分析，统计编程语言、数据库、开发工具、AI 工具使用等情况。

可选统计指标：

- 最常用编程语言/数据库 Top10；
- 不同国家或地区的开发者数量分布；
- AI 工具使用情况统计；
- 不同开发者类型的技术选择差异。

选题 3：音乐流媒体热度与歌曲特征分析

数据集：Spotify Global Chart 2024

https://www.kaggle.com/datasets/federicocester97/spotify-global-chart-2024

任务说明：对 2024 年 Spotify 全球音乐榜单数据进行分析，统计歌曲、歌手、播放量和榜单变化等信息。

可选统计指标：

- 播放量最高的歌曲/歌手 Top10；
- 不同月份的歌曲热度变化；
- 歌曲在榜周数统计；
- 歌曲排名变化趋势分析。

三、项目提交要求

请提交以下材料打包上传：

1. **项目报告（PDF 格式）：**内容包括项目背景、数据集说明、技术路线、HDFS 操作过程、数据预处理、核心程序设计、运行结果及分析讨论、小组具体任务分工、思考总结；
2. **代码与数据文件：**包括可运行代码、样例数据、运行结果文件（保存为文本、CSV 或其他可读文件）；

- **提交截止时间：2026 年 7 月 6 日 23:59** 前上传至 QQ 群期末项目栏
- **文件统一命名为：**学号-姓名-项目名称

四、评分标准

评分项	分值
数据集说明与问题定义	10
HDFS 存储与操作	15
数据读取与预处理	15
核心计算程序实现	25
统计结果与分析	15
代码规范与可运行性	10
报告质量与任务分工	10

五、额外加分项（可累计）

加分内容	加分值
使用 Flink 完成实时统计或模拟流处理	+3
使用两种计算框架完成同一指标并进行对比	+2
对统计结果进行可视化展示	+2
在基础指标之外增加有意义的扩展分析	+2