大数据应用案例

费子成

苏州大学

E-mail: feizicheng@suda.edu.cn

个人主页：https://web.suda.edu.cn/feizicheng/





01

Linux系统的安装与使用

Linux系统简介



01

类Unix操作系统

Linux是一套免费使用和自由传播的类Unix操作系统，它基于POSIX和UNIX标准，保证了与传统UNIX系统的兼容性。

02

多用户、多任务支持

Linux是一个多用户、多任务的操作系统，能够同时支持多个用户和多个程序运行，提高了计算机资源的使用效率。

03

多线程和多CPU能力

Linux支持多线程和多CPU，这使得它能够处理复杂的计算任务，特别适合于服务器和高性能计算环境。

04

开源和免费特性

Linux操作系统是开源的，用户可以自由使用、修改和分发，这降低了使用成本并促进了社区的参与和创新。

Linux系统简介

01



发行版的多样性

Linux有许多不同的发行版，这些发行版服务于不同的目的，如支持不同的计算机结构、本地化、实时应用和嵌入式系统等，目前已有超过三百个发行版。

02



商业与社区维护版本

Linux的发行版本主要可以分为两类：商业公司维护的版本和社区组织维护的版本。商业版本以Redhat为代表，而社区版本则以Debian为代表。

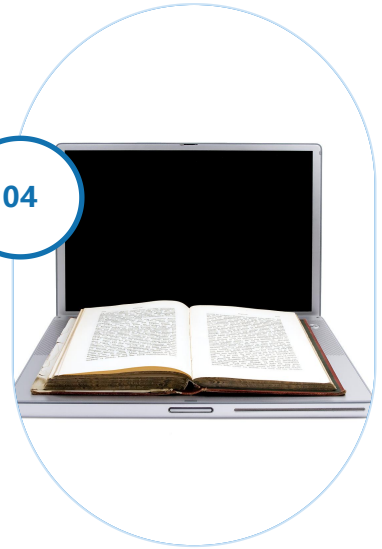
03



Debian与Ubuntu

Debian是社区维护的典范，而Ubuntu基于Debian的unstable版本加强而来，继承并强化了Debian的优点，形成了一个近乎完美的Linux桌面系统。

04



Ubuntu的普及与优势

Ubuntu因其拥有Debian的所有优点以及额外的改进，成为在服务端和桌面端使用占比最高的Linux发行版，网络上资料也最为齐全，因此在本课程中采用Ubuntu作为教学平台。

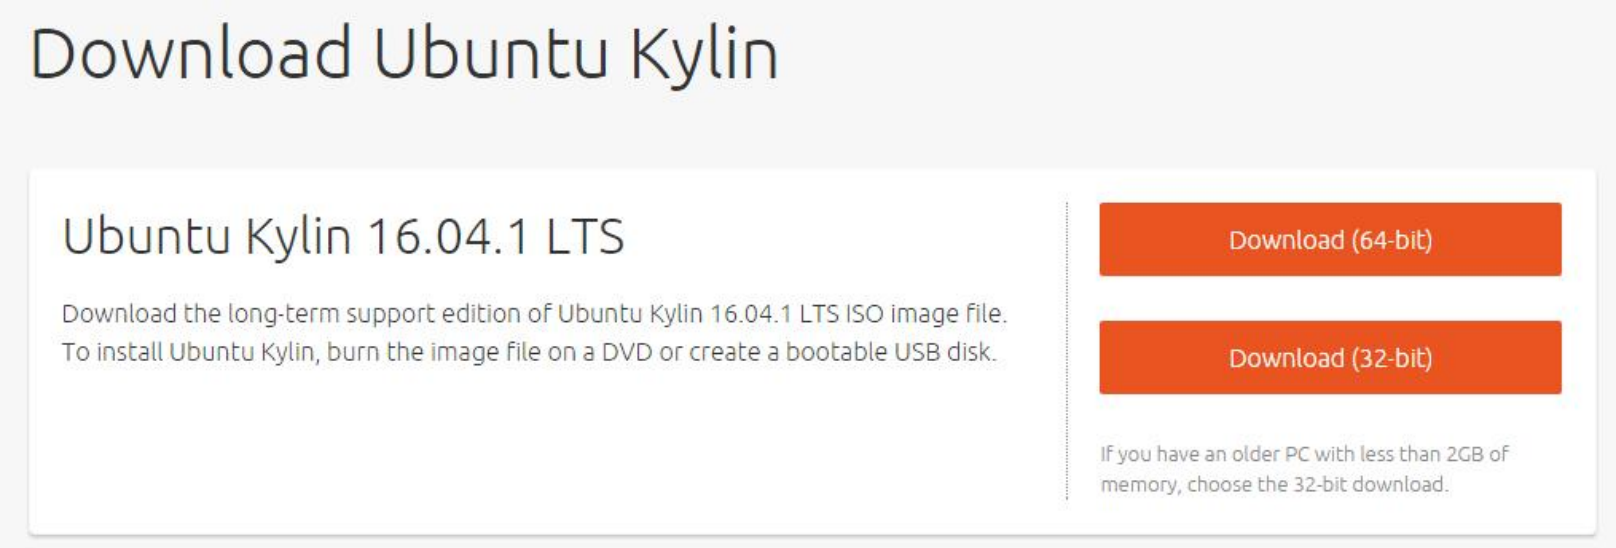
下载安装文件

- 本课程采用的Linux发行版是Ubuntu，同时，为了更好支持汉化（比如，更容易输入中文），这里采用了Ubuntu Kylin发行版。Ubuntu Kylin是针对中国用户定制的Ubuntu发行版本，里面包含了一些中国特色的软件（比如中文拼音输入法），并根据中国人的使用习惯，对系统做了一些优化。

- Ubuntu Kylin较新的版本是22.04 LTS，但是，在实际使用过程中发现，该版本对计算机的资源消耗较多，在使用虚拟机方式安装时，系统运行起来速度较慢。因此，本教程选择较低的版本**Ubuntu Kylin 16.04 LTS**，这个版本不仅降低了对计算机配置的要求，也可以保证大数据各种软件的顺利安装和运行，帮助同学们很好完成本教程的各个实验。

下载安装文件

可以通过两种途径下载Ubuntu Kylin发行版的安装映像文件，第一种方式是进入Windows系统，访问Ubuntu官网下载（https://www.ubuntu.org.cn/download/ubuntu-kylin）。进入Ubuntu官网的下载页面后（如图所示），会提供两种不同版本的安装映像文件的下载地址，即32位版本和64位版本。如果计算机硬件配置较低，内存小于2GB，建议选择32位版本；如果内存大于4GB，建议选择64位版本。



Linux系统的安装方式

Linux系统的安装主要有两种方式：虚拟机安装方式和双系统安装方式。

- （1）**虚拟机安装方式**：在Windows操作系统上安装虚拟机软件（比如VirtualBox或VMware），然后，在虚拟机软件之上安装Linux系统。采用这种安装方式时，Linux系统就相当于运行在Windows上的一个软件，如果要使用Linux系统，需要在电脑开机后，首先启动进入Windows操作系统，然后，在Windows操作系统中打开虚拟机软件（比如VirtualBox），最后，在虚拟机软件中启动Linux，之后才能使用Linux系统。

- （2）**双系统安装方式**：直接把Linux系统安装在电脑“裸机”上，而不是安装在Windows系统之上。采用这种安装方式时，Linux系统和Windows系统的地位是平等的，当电脑开机时，屏幕上会显示提示信息，让用户选择要启动的系统，如果用户选择Windows系统，电脑就继续启动进入Windows系统，如果用户选择Linux系统，电脑就继续启动进入Linux系统。

安装Linux虚拟机

1. 安装虚拟机软件

常用的虚拟机软件包括VMware和VirtualBox等，VirtualBox属于开源软件，免费，VMware属于商业软件，需要付费。从易用性的角度，VMware要比VirtualBox更胜一筹，因此，本教程采用VMware，可以访问VMware官网（https://www.vmware.com/cn/products/workstation-pro.html）下载安装文件，或者通过本课程中分享的百度网盘链接下载，文件名是VMware-workstation-full-17.0.1.exe。下载后，请在Windows操作系统中安装VMware。

安装Linux虚拟机

2. 安装Linux操作系统

请进入Windows系统，启动VMware软件，按照以下两大步骤完成Linux系统的安装：首先需要创建一个虚拟机，然后，在虚拟机上安装Linux系统。打开VMware，在“主页”选项卡中，可以看到如图所示的界面，点击“创建新的虚拟机”。



安装Linux虚拟机

在出现的界面中（如图所示），选择“典型(推荐)(T)”。



安装Linux虚拟机

在出现的界面中（如图1所示），选中“安装程序光盘映像文件(iso)(M)”，点击“浏览”按钮， 在弹出的界面中（如图2所示），找到之前已经准备好的Ubuntu安装映像文件ubuntukylin-16.04-desktop-amd64.iso，点击“打开”把它加入进来，然后点击“下一步”。

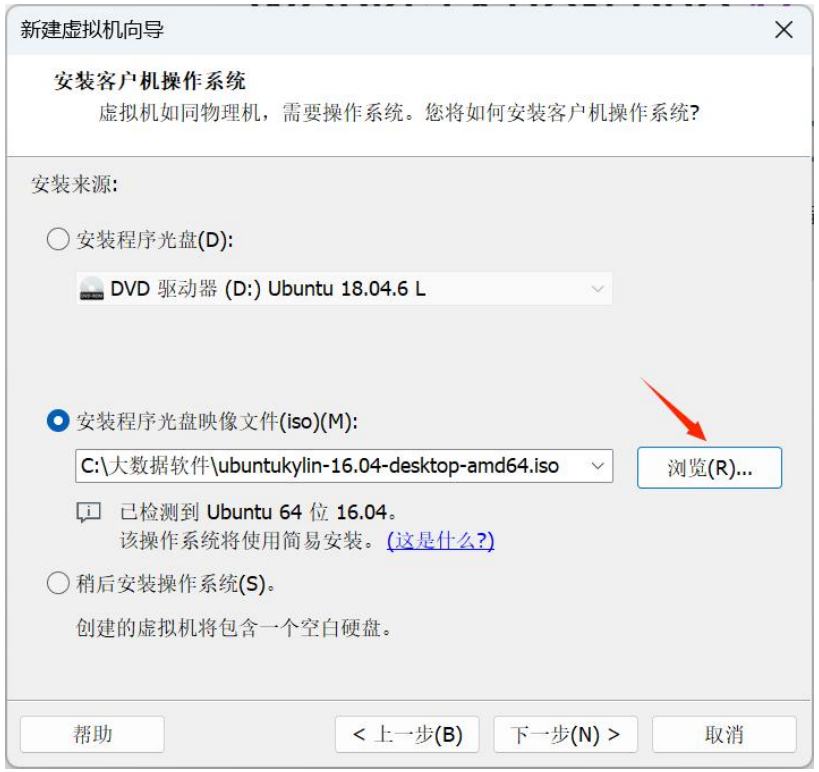


图1 安装程序光盘映像文件

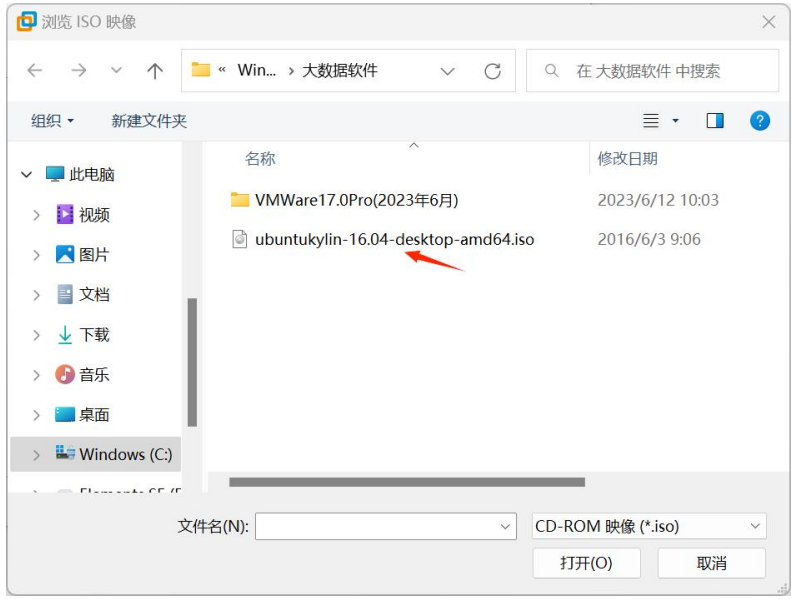


图2 打开映像文件

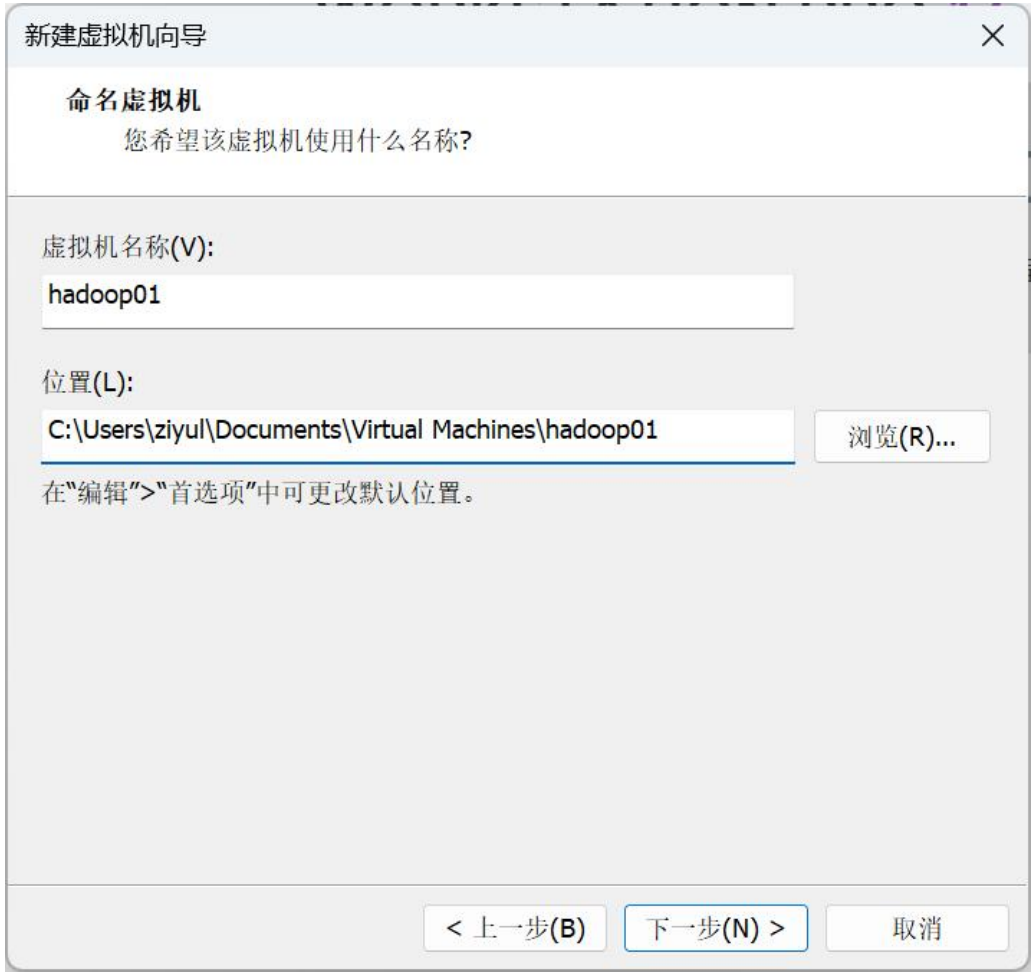
安装Linux虚拟机

在弹出的界面中（如图所示），进行个性化Linux设置，比如，可以把“全名”设置为“BigData”，“用户名”设置为“XXX”，“密码”设置为“123456”。然后，点击“下一步”。



安装Linux虚拟机

在弹出的界面中（如图所示），设置“虚拟机名称”为“hadoop01”，并设置虚拟机文件保存位置。然后点击“下一步”。



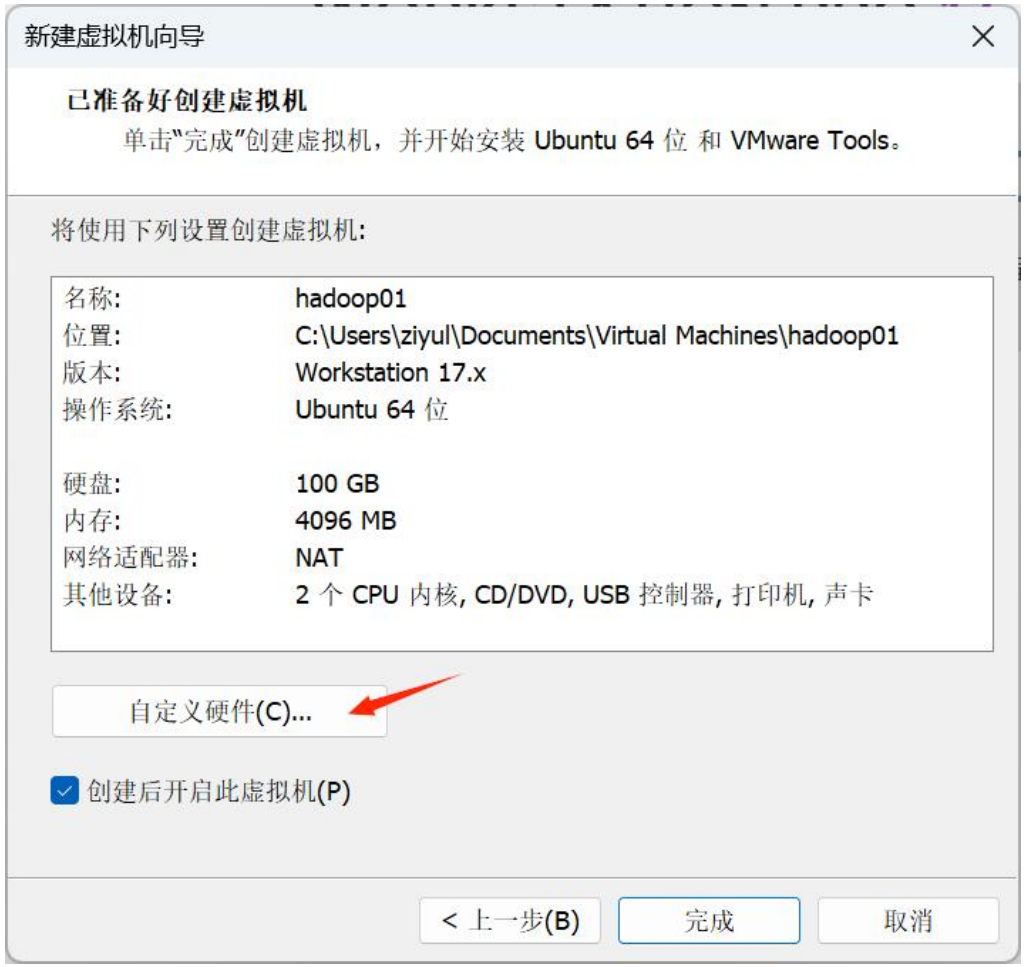
安装Linux虚拟机

在弹出的界面中（如图所示），对磁盘大小进行设置。一般而言，开展大数据实验，需要在虚拟机中安装各种大数据软件，至少需要消耗40GB磁盘空间，因此，建议把磁盘空间设置为50GB~100GB。同时，需要把“将虚拟磁盘存储为单个文件(O)”选中。然后，点击“下一步”。



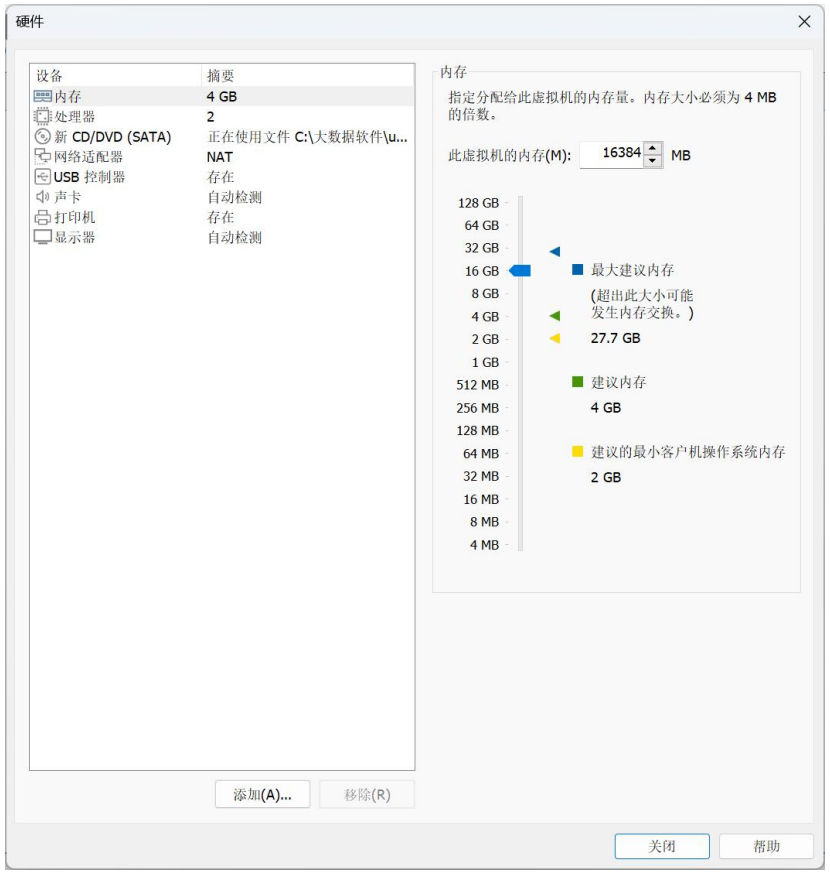
安装Linux虚拟机

在弹出的界面中（如图所示），点击“自定义硬件”按钮，对内存大小进行设置。



安装Linux虚拟机

在弹出的界面中（如图所示），对虚拟机的内存进行设置，比如，如果计算机的内存有32GB，则可以把虚拟机内存设置为16GB，最小要设置为4GB。然后，点击“关闭”，返回到图示界面，点击“完成”。这时，VMWare就会开始自动安装Ubuntu系统。



安装Linux虚拟机

系统安装完成以后，会出现如图1所示的登录界面，点击“BigTable”用户，输入密码，就可以登录Ubuntu系统了，登录后系统界面如图2所示。

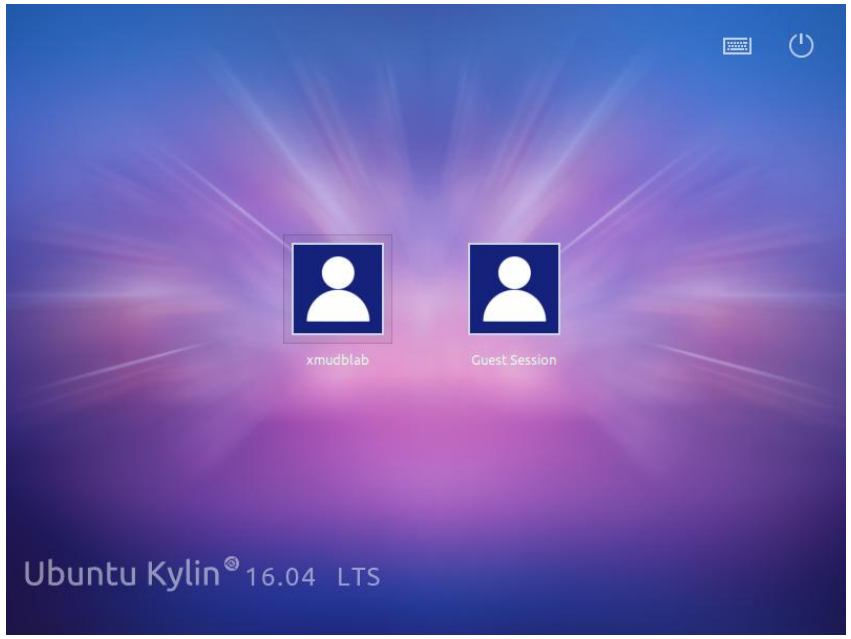


图1 Ubuntu登录界面

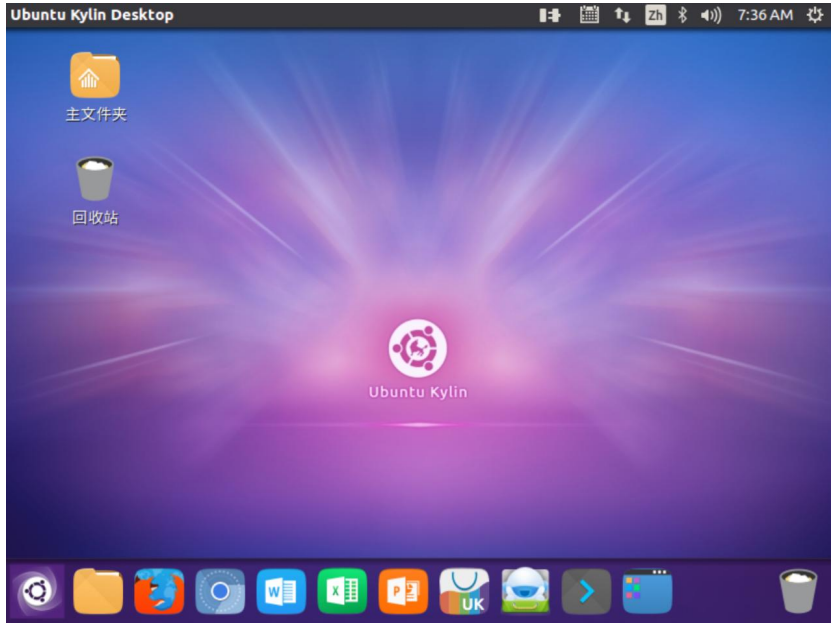


图2 Ubuntu系统界面

安装Linux虚拟机

在系统界面底部的一排按钮中，有一个最经常被使用的按钮是“终端”（Terminal）按钮（如图2-13所示），点击这个按钮，就可以新建一个Linux终端，也就是Linux Shell环境。当然，也可以使用组合键“CTRL+ALT+T”新建一个终端。



安装Linux虚拟机

在系统界面底部的一排按钮中，另一个经常被使用的按钮是“文件夹”按钮（如图2-14所示），点击这个按钮，就可以打开文件夹管理界面（如图2-15所示），就可以像Windows系统一样进行各种操作。VMWare支持Windows系统和Linux虚拟机之间的双向复制，可以把Windows系统中的文件或文字直接复制粘贴到Linux虚拟机中，也可以把Linux虚拟机中的文件或文字复制粘贴到Windows系统中。



图2-14 文件夹按钮

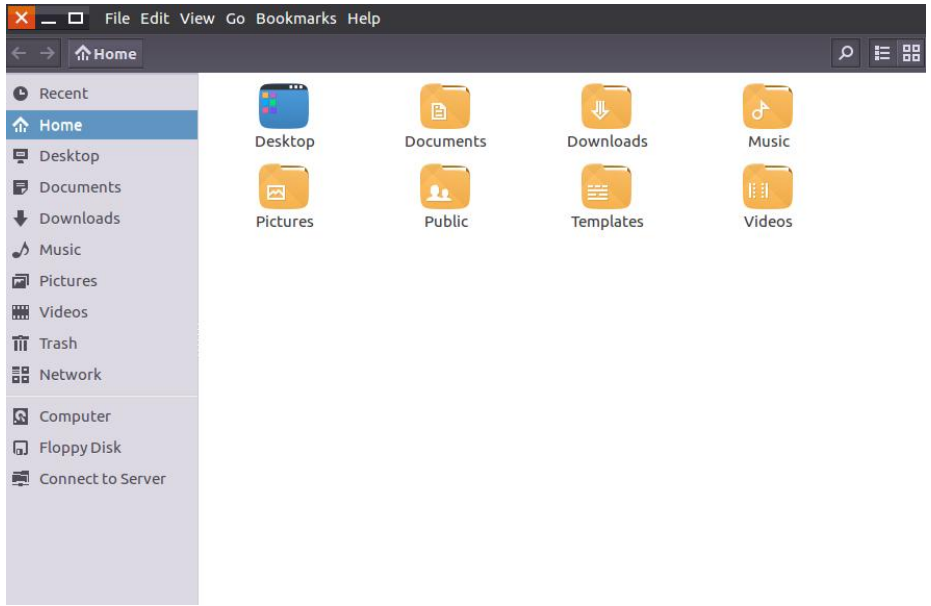
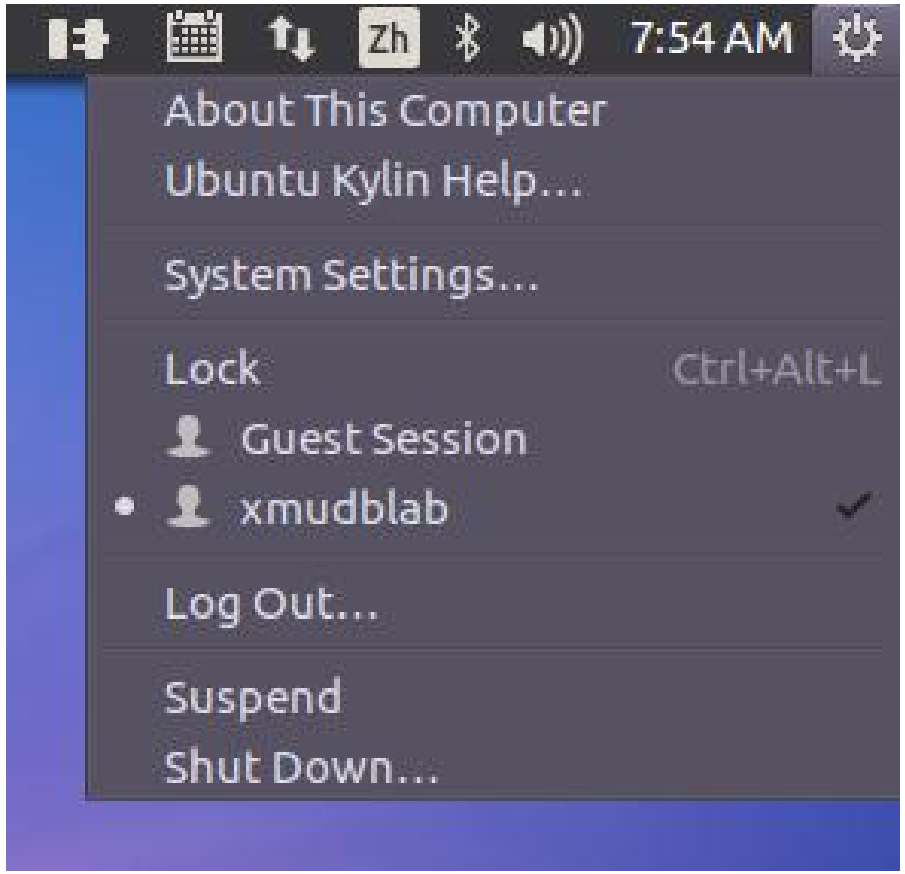


图2-15 文件夹管理界面

安装Linux虚拟机

当需要退出登录或关机时，可以点击系统界面右上角的齿轮图标，会弹出如图2-16所示的界面，若点击“Log Out…”就可以退出当前登录，若点击“Shut Down…”就可以关机，也就是关闭Ubuntu系统，而不是关闭Windows系统。



Linux系统及相关软件基本使用方法

1 Shell

2 root用户

3 创建普通用户

4 sudo命令

5 常用的Linux系统命令

6 文件解压缩

7 常用的目录

8 目录的权限

9 更新APT

10 切换中英文输入法

11 vim编辑器使用方法

12 在Linux中安装Eclipse

13 其他使用技巧

1 Shell

Shell是Linux系统的用户界面，提供了用户与Linux系统内核进行交互操作的一种接口，它接收用户输入的命令并把它送入内核去执行。当我们在Linux系统中打开一个终端（可以采用快捷键Ctrl+Alt+T）时，就进入了Shell命令提示符状态，在里面输入的用户命令，都会被送入Linux内核去执行。每个Linux系统的用户可以拥有自己的Shell，用以满足他们自己专门的Shell需要。

Shell也有多种不同的版本，主要有下列版本的Shell：

- Bourne Shell：由贝尔实验室开发；
- BASH：是GNU的Bourne Again Shell，是GNU操作系统上默认的Shell；
- Korn Shell：是对Bourne Shell的发展，在大部分内容上与Bourne Shell兼容；
- C Shell：是SUN公司Shell的BSD版本；
- Z Shell：Z是最后一个字母，也就是终极Shell，集成了BASH、ksh的重要特性，同时又增加了自己独有的特性。

2 root用户

- 对于Linux系统而言，超级用户一般命名为root，相当于Windows系统中的Administrator用户。
- root是系统中唯一的超级用户，具有系统中所有的权限，如启动或停止一个进程、删除或增加用户、增加或者禁用硬件等等。
- Linux中的root用户比Windows的Administrator用户的能力更大，足以把整个系统的大部分文件删掉，导致系统完全毁坏，不能再次使用。所以，用root进行不当的操作是相当危险的，轻微的可以造成死机，严重的甚至不能开机。因此，在实际使用中，除非确实需要，**一般情况下都不推荐使用root用户登录Linux系统进行日常的操作**。建议单独建立一个普通的用户，来学习大数据软件安装和开展编程实践。比如，本教程全部采用单独建立的hadoop用户来开展实验。

3 创建普通用户

打开一个终端（可以使用快捷键 Ctrl+Alt+T），使用如下命令创建一个用户hadoop：

```
$ sudo useradd -m hadoop -s /bin/bash
```

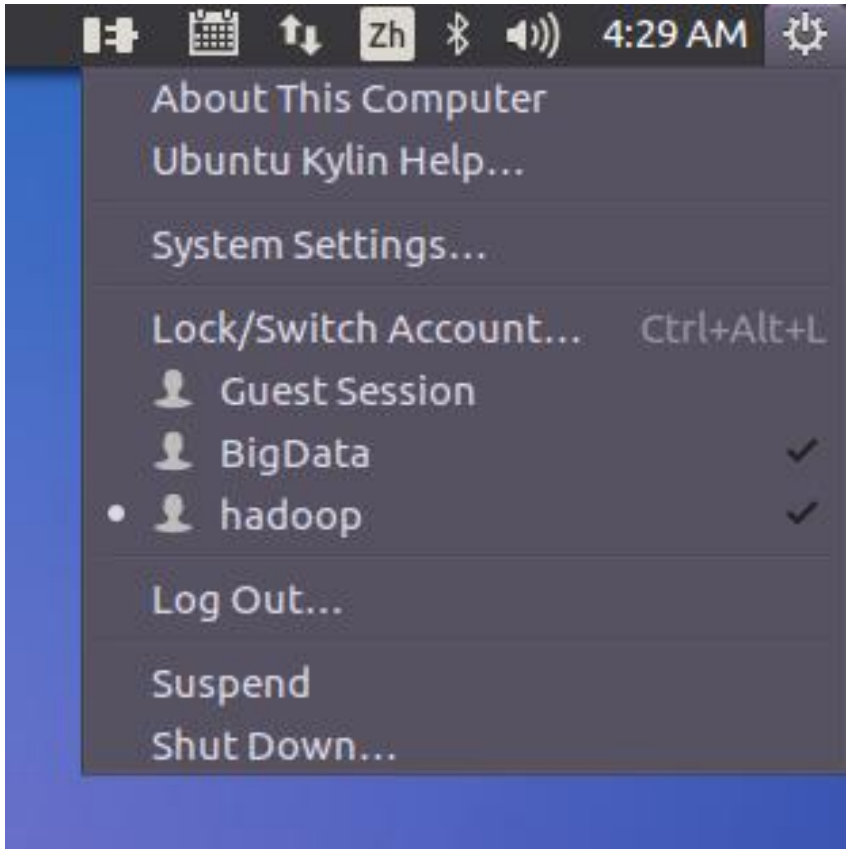
使用如下命令为hadoop用户设置密码：

```
$ sudo passwd hadoop
```

为hadoop用户增加管理员权限：

```
$ sudo adduser hadoop sudo
```

界面右上角选择新创建的hadoop用户登录进入



4 sudo命令

- sudo是Linux系统管理指令，管理员可以授权给一些普通用户去执行一些需要root权限执行的操作。这样不仅减少了root用户的登录和管理时间，同样也提高了安全性。本教程后面在执行软件安装时，都是采用hadoop用户登录，而不是root用户登录。因此，使用hadoop用户登录Linux系统以后，当需要执行只有root用户有权限执行的命令时，都要在命令前面加上sudo，才能够顺利执行，如果不加上sudo，就会被拒绝执行。

- 当使用sudo命令时，会要求输入当前用户的密码。需要注意的是，Windows系统中，用户输入密码，都会在屏幕上显示“*”号作为反馈，但是，在Linux系统中，当输入密码时，不会在屏幕上显示“*”号作为反馈。这时，不要误以为系统死机或者键盘出了问题，只要输完密码后回车即可。

5 常用的Linux系统命令

命令	含义
cd /home/hadoop	把/home/hadoop设置为当前目录
cd ..	返回上一级目录
cd ~	进入到当前Linux系统登录用户的主目录（或主文件夹）。在 Linux 系统中，~代表的是用户的主文件夹，即“/home/用户名”这个目录，如果当前登录用户名为 hadoop，则~就代表“/home/hadoop/”这个目录
ls	查看当前目录中的文件
ls -l	查看文件和目录的权限信息
cat /proc/version	查看Linux系统内核版本信息
cat /home/hadoop/word.txt	把/home/hadoop/word.txt这个文件全部内容显示到屏幕上
cat file1 file2 > file3	把当前目录下的file1和file2两个文件进行合并生成文件file3

5 常用的Linux系统命令

head -5 word.txt	把当前目录下的word.txt文件中的前5行内容显示到屏幕上
sudo cp /home/hadoop/word.txt /usr/local/	把 /home/hadoop/word.txt 文件复制到“/usr/local”目录下
rm ./word.txt	删除当前目录下的word.txt文件
rm –r ./test	删除当前目录下的test目录及其下面的所有文件
rm –r test*	删除当面目录下所有以test开头的目录和文件
ifconfig	查看本机IP地址信息
exit	退出并关闭Linux终端

6 文件解压缩

在Linux系统中，可以使用tar命令对后缀名为.tar.gz（或.tgz）的压缩文件进行解压。通常可以采用如下形式的命令：

```
$ tar -zxf /home/hadoop/Downloads/hbase-2.5.4-bin.tar.gz –C
/usr/local
```

7 常用的目录

- Linux系统的根目录“/”下，存在很多个目录，其中有两个目录，是本教程学习过程中经常用到的，一个是“/home”目录，一个是“/usr”目录。“/home”目录包含了各个用户的用户目录，每当在Linux系统中新建一个普通用户时，系统就会自动为这个用户创建用户主目录（主文件夹）

- “/usr”目录是“Unix Software Resource”的简写，表示这里是各种软件安装的目录。对于“/usr”目录而言，只需要关注它下面的子目录“/usr/local”，一般由用户安装的软件都建议安装到该目录下

8 目录的权限

Linux系统对文件权限有着严格的规定，如果一个用户不具备权限，将无法访问目录及其下面的文件。比如，使用hadoop用户登录Linux系统以后，从网络上下载了HBase安装包文件，把文件解压缩到“/usr/local/”目录下，会得到一个类似“/usr/local/hbase”这样的目录，这时，hadoop用户并不是“/usr/local/hbase”这个目录的所有者，无法对该目录进行相关操作，从而无法正常使用HBase。这时，就必须采用chown命令进行授权，让hadoop用户拥有对该目录的权限，具体命令如下：

```
$ sudo chown -R hadoop /usr/local/hbase
```

9 更新APT

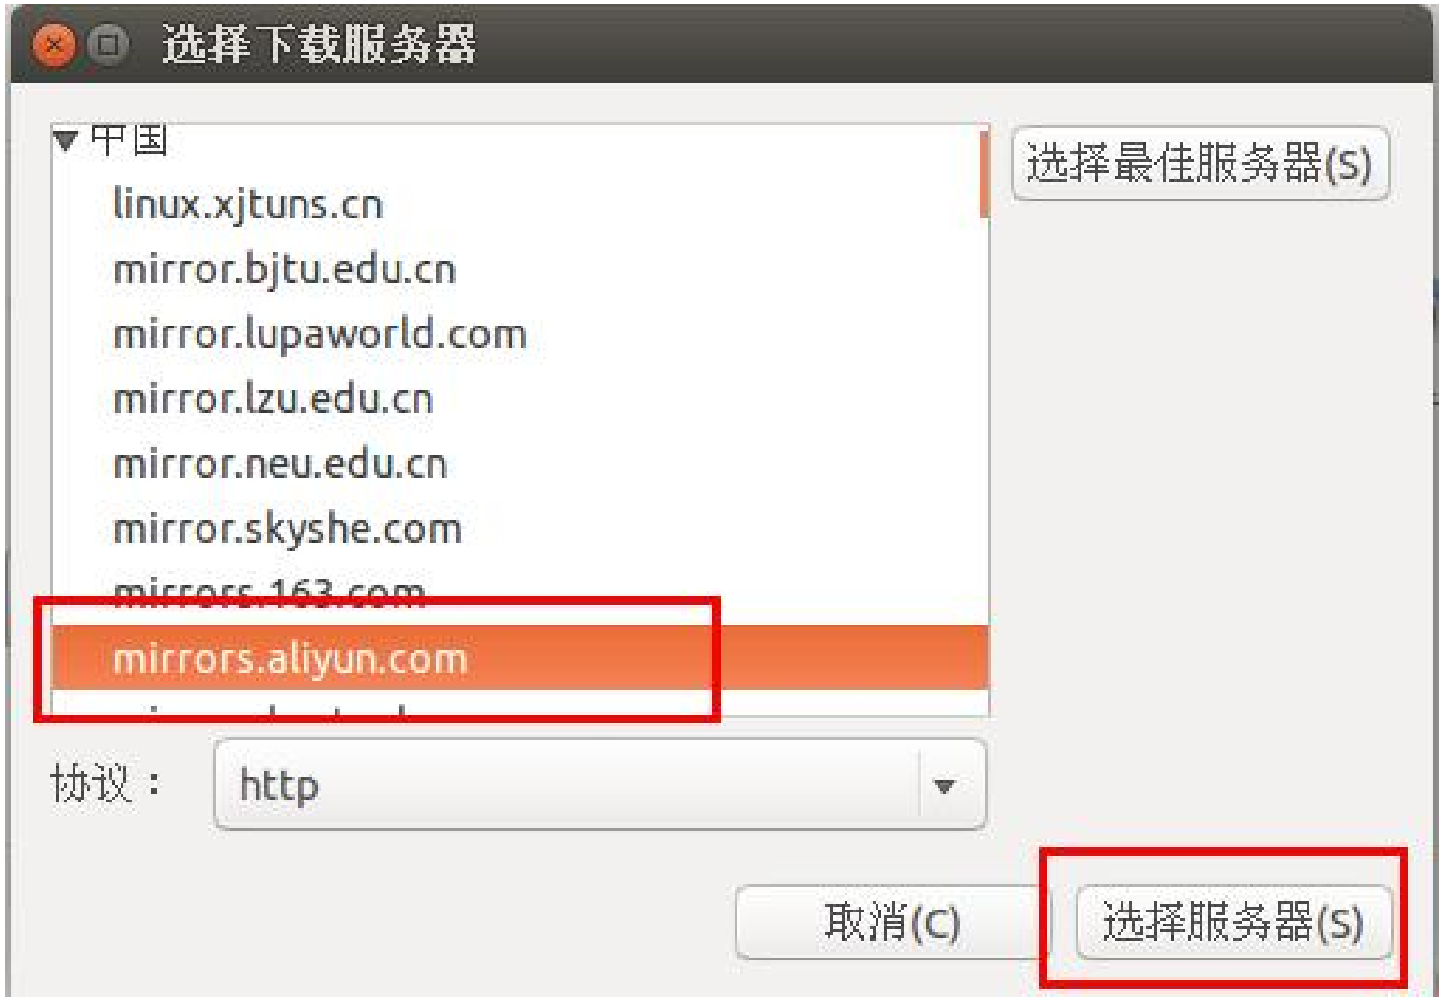
APT是一个非常优秀的软件管理工具，Linux系统采用APT来安装和管理各种软件。安装成功Linux系统以后，需要及时更新APT软件，否则，后续一些软件可能无法正常安装。请登录Linux系统，打开一个终端（可以使用快捷键Ctrl+Alt+T），进入Shell命令提示符状态，然后输入下面命令：

```
$ sudo apt-get update
```

9 更新APT


软件和更新
Ubuntu 软件
其它软件
更新
身份验证
附加驱动
可从互联网下载
Canonical 支持的免费和开源软件 (main)
社区维护的免费和开源软件 (universe)
设备的专有驱动 (restricted)
有版权和合法性问题的的软件 (multiverse)
源代码
下载自：
中国的服务器

9 更新APT


选择下载服务器
中国
linux.xjtuns.cn
mirror.bjtu.edu.cn
mirror.lupaworld.com
mirror.lzu.edu.cn
mirror.neu.edu.cn
mirror.skyshe.com
mirrors.aliyun.com
选择最佳服务器(S)
协议：
http
取消(C)
选择服务器(S)

9 更新APT


下载自：
http://mirrors.aliyun.com/ubuntu
可从光驱安装
Ubuntu 14.04 'Trusty Tahr' 光盘
官方支持
版权受限
还原(V)
关闭(C)

9 更新APT


可用软件的列表信息已过时
要通过新加入或已变更的软件源来安装或更新软件包，您必须重新载入可用软件包列表。
您需要一个有效的互联网连接才能继续。
重新载入(R)
关闭(C)

10 切换中英文输入法

Ubuntu中终端输入的命令一般都是使用英文输入。但是，有时候也会需要输入中文。 Linux系统的中英文输入法的切换方式是使用键盘“shift”键来切换，或者，也可以点击系统桌面顶部菜单的输入法按钮进行切换。Ubuntu自带的Sunpinyin中文输入法已经可以很好满足中文输入要求，不需要额外安装中文输入法。

11 vim编辑器使用方法

执行下面命令完成vim编辑器的安装：

```
$ sudo apt-get install vim
```

可以执行下面命令创建一个word.txt文件：

```
$ cd ~
$ vim word.txt
```

11 vim编辑器使用方法

通过上面命令就打开了vim编辑器，然后，需要键盘敲击输入一个英文字母i，进入编辑状态以后才能修改内容（页面左下角显示为INSERT）。这时，就可以向word.txt文件中输入一些单词。修改后，需要按键盘上的Esc键退出vim的编辑状态（左下角INSERT消失），之后有以下几种选择：

- 从键盘输入“:wq”三个英文字母，然后回车，表示保存文件并退出。
- 从键盘输入“:q”两个英文字母，然后回车，表示不保存并退出。如果本次编辑过程只是查看了文件内容，没有对文件做任何修改，则可以顺利退出。但是，如果已经修改了文件内容，则vim编辑器不允许就这样退出，会给出提示信息，这时，要想不保存就退出vim编辑器，就要采用下面一种方式，即输入“:q!”。
- 从键盘输入“:q!”三个英文字母，然后回车，表示不保存并强制退出。

安装Java环境

由于Hadoop本身是使用Java编写的，因此，Hadoop的开发和运行都需要Java的支持，对于Hadoop 3.3.5而言，其要求使用JDK 1.8或者更新的版本。

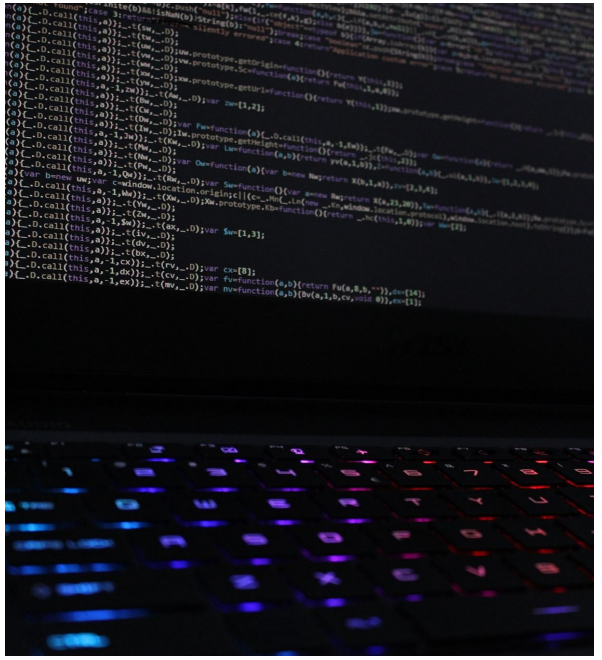
访问Oracle官网下载JDK 1.8安装包。这里假设下载得到的JDK安装文件为jdk-8u371-linux-x64.tar.gz，并且保存在Ubuntu操作系统的“/home/hadoop/Downloads/”目录下。

执行如下命令创建“/usr/lib/jvm”目录来存放JDK文件：

```
$cd /usr/lib
$sudo mkdir jvm #创建/usr/lib/jvm目录来存放JDK文件
```

执行如下命令对安装文件进行解压缩：

```
$cd ~ #进入hadoop用户的主目录
$cd Downloads
$sudo tar -zxvf ./jdk-8u371-linux-x64.tar.gz -C /usr/lib/jvm
```



安装Java环境

下面继续执行如下命令，设置环境变量：

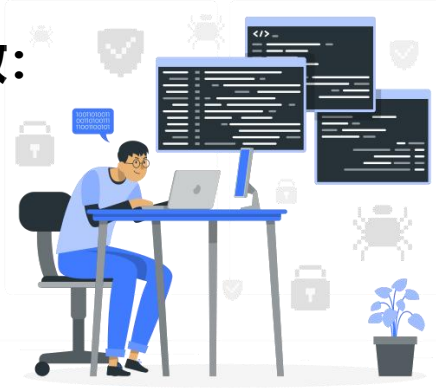
```
$vim ~/.bashrc
```

上面命令使用Vim编辑器打开了“hadoop”这个用户的环境变量配置文件，请在这个文件的开头位置，添加如下几行内容：

```
export JAVA_HOME=/usr/lib/jvm/jdk1.8.0_371
export JRE_HOME=${JAVA_HOME}/jre
export CLASSPATH=.:${JAVA_HOME}/lib:${JRE_HOME}/lib
export PATH=${JAVA_HOME}/bin:$PATH
```

保存.bashrc文件并退出Vim编辑器。然后，继续执行如下命令让.bashrc文件的配置立即生效：

```
$source ~/.bashrc
```



安装Java环境

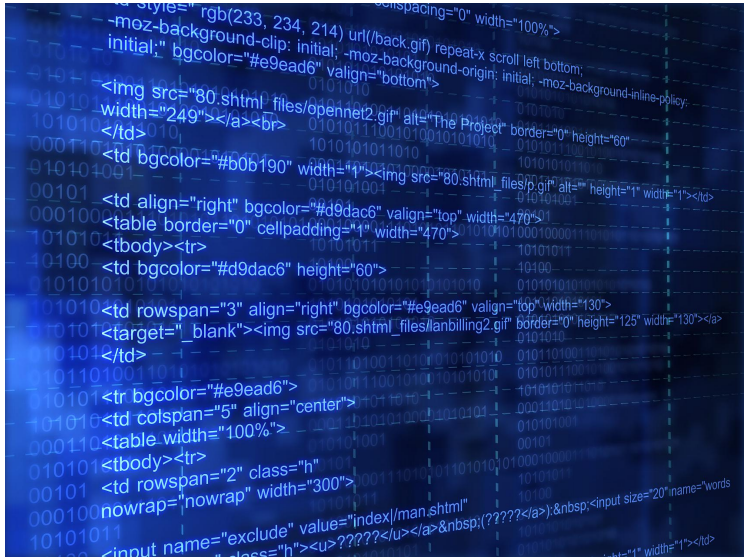
这时，可以使用如下命令查看是否安装成功：

```
$java -version
```

如果屏幕上能显示如下返回信息，则说明安装成功：

```
java version "1.8.0_371"
Java(TM) SE Runtime Environment (build 1.8.0_371-b11)
Java HotSpot(TM) 64-Bit Server VM (build 25.371-b11, mixed mode)
```







12 在Linux中安装Eclipse

Eclipse是常用的程序开发工具，本教程很多程序代码都是使用Eclipse开发调试，因此，需要在Linux系统中安装Eclipse。

可以到Eclipse官网（https://www.eclipse.org/downloads/）下载安装包，或者直接在课程分享的链接中下载，文件名是eclipse-4.7.0-linux.gtk.x86_64.tar.gz。假设安装文件下载后保存在了Linux系统的目录“~/Downloads”下，下面执行如下命令对文件进行解压缩：

```
$cd ~/Downloads
$sudo tar -zxvf ./eclipse-4.7.0-linux.gtk.x86_64.tar.gz -C /usr/local
```

然后，执行如下命令启动Eclipse：

```
$cd /usr/local/eclipse
$./eclipse
```

13 其他使用技巧

1. 使用Tab键自动补全命令: Tab

2. 隐藏文件: ls -a

3. 重现历史命令: 上方向键/history

02

Hadoop的安装与使用

Hadoop的安装与使用

Linux虚拟机安装

创建Hadoop用户

更新apt安装Vim编辑器

安装SSH配置SSH无密码登录

安装Java环境

安装单机Hadoop

Hadoop伪分布式安装

Hadoop集群安装

Linux虚拟机的安装

Ubuntu Kylin发行版

本课程采用的Linux发行版是Ubuntu，同时，为了更好支持汉化（比如，更容易输入中文），这里采用了Ubuntu Kylin发行版。Ubuntu Kylin是针对中国用户定制的Ubuntu发行版本，里面包含了一些中国特色的软件（比如中文拼音输入法），并根据中国人的使用习惯，对系统做了一些优化。

Ubuntu Kylin 16.04 LTS

Ubuntu Kylin较新的版本是22.04 LTS，但是，在实际使用过程中发现，该版本对计算机的资源消耗较多，在使用虚拟机方式安装时，系统运行起来速度较慢。因此，本教程选择较低的版本Ubuntu Kylin 16.04 LTS，这个版本不仅降低了对计算机配置的要求，也可以保证大数据各种软件的顺利安装和运行，帮助同学们很好完成本教程的各个实验。

VMware

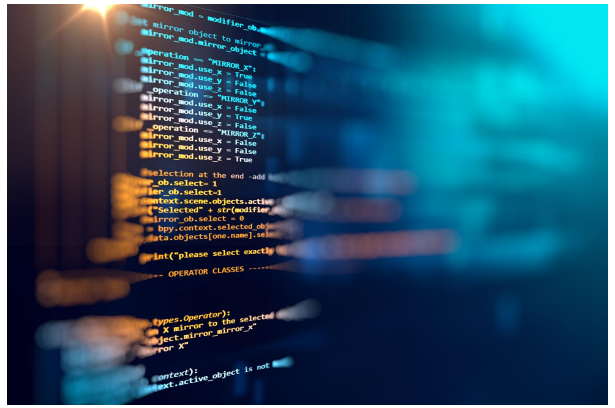
常用的虚拟机软件包括VMware和VirtualBox等，VirtualBox属于开源软件，免费，VMware属于商业软件，需要付费。从易用性的角度，VMware要比VirtualBox更胜一筹，因此，本教程采用VMware。

创建Hadoop用户

如果安装 Ubuntu 的时候不是用的 “hadoop” 用户，那么需要增加一个名为 hadoop 的用户。

- 首先按 ctrl+alt+t 打开终端窗口，输入如下命令创建新用户：

```
$ sudo useradd –m hadoop –s /bin/bash
```



- 上面这条命令创建了可以登陆的 hadoop 用户，并使用 /bin/bash 作为 shell

- 接着使用如下命令设置密码，可简单设置为 hadoop，按提示输入两次密码：

```
$ sudo passwd hadoop
```



- 可为 hadoop 用户增加管理员权限，方便部署，避免一些对新手来说比较棘手的权限问题：

```
$ sudo adduser hadoop sudo
```

更新apt和安装Vim编辑器

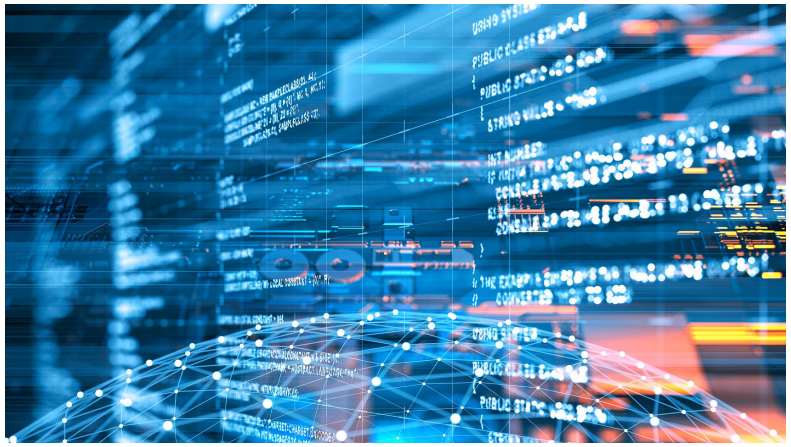
用hadoop用户登录Ubuntu操作系统后，需要首先更新一下apt，从而确保后续可以顺利安装一些软件。命令如下：

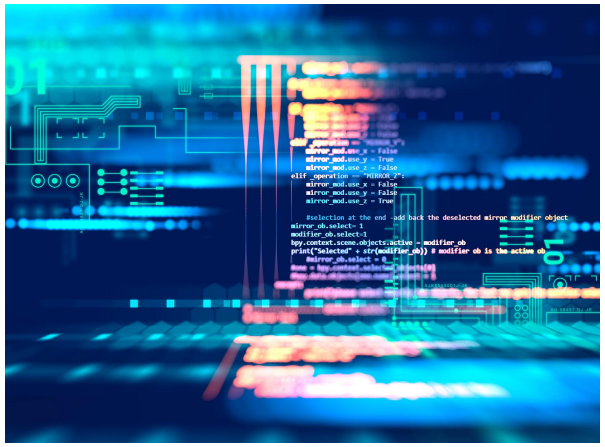
```
$sudo apt-get update
```

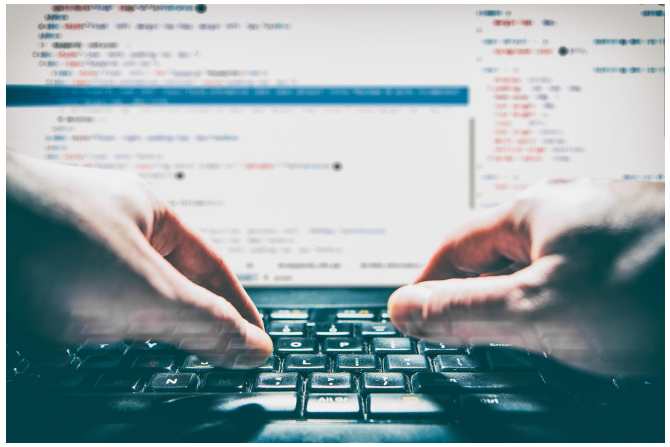
在Ubuntu操作系统中，可以使用Vim编辑器来创建文件和修改文件。执行如下命令安装Vim编辑器：

```
$sudo apt-get install vim
```

安装软件时若需要确认，在提示处输入y即可。







安装SSH和配置SSH无密码登录

■ SSH是什么?

含义

SSH 为 Secure Shell 的缩写，是**建立在应用层和传输层基础上的安全协议**。SSH 是目前较可靠、专为远程登录会话和其他网络服务提供安全性的协议。

作用

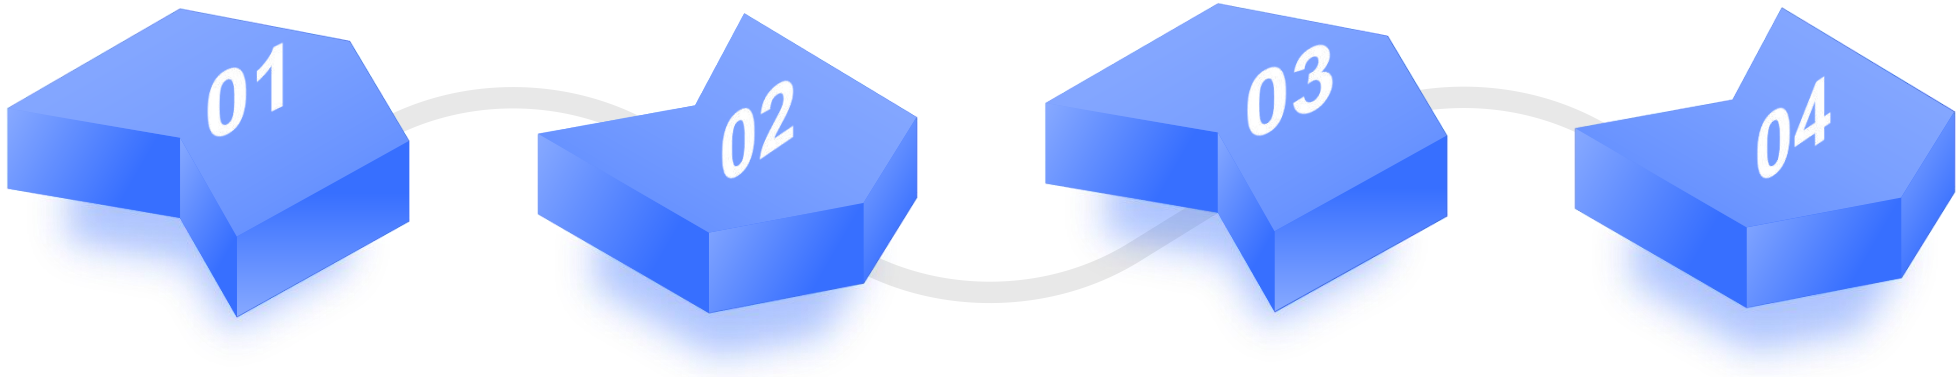
利用 SSH 协议可以**有效防止远程管理过程中的信息泄露问题**。SSH最初是UNIX系统上的一个程序，后来又迅速扩展到其他操作平台。

结构

SSH是由**客户端和服务端的软件组成**，服务端是一个守护进程(daemon)，它在后台运行并响应来自客户端的连接请求，客户端包含ssh程序以及像scp（远程拷贝）、slogin（远程登陆）、sftp（安全文件传输）等其他的应用程序。

安装SSH和配置SSH无密码登录

■ 配置SSH的原因



Hadoop名称节点（NameNode）需要启动集群中所有机器的Hadoop守护进程；

这个过程需要通过SSH登录来实现。

Hadoop并没有提供SSH输入密码登录的形式；

为了能够顺利登录每台机器，需要将所有机器配置为名称节点可以无密码登录它们。

安装SSH和配置SSH无密码登录

为了实现SSH无密码登录，需要在Ubuntu操作系统上安装SSH服务端和客户端。Ubuntu操作系统默认已安装了SSH客户端，因此这里只需要安装SSH服务端，命令如下：

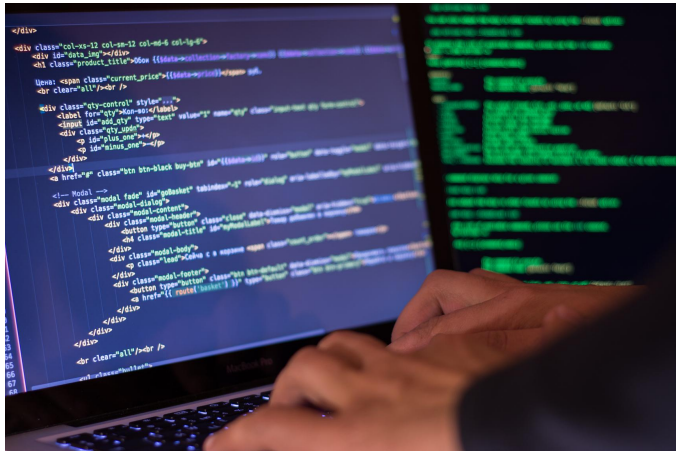
```
$sudo apt-get install openssh-server
```

安装以后，可以使用如下命令登录本机：

```
$ssh localhost
```

出现提示后，输入“yes”，并输入密码，就可以登录到本机了。但是，这样登录是需要每次都输入密码的，因此，我们**需要配置成SSH无密码登录**。







安装SSH和配置SSH无密码登录

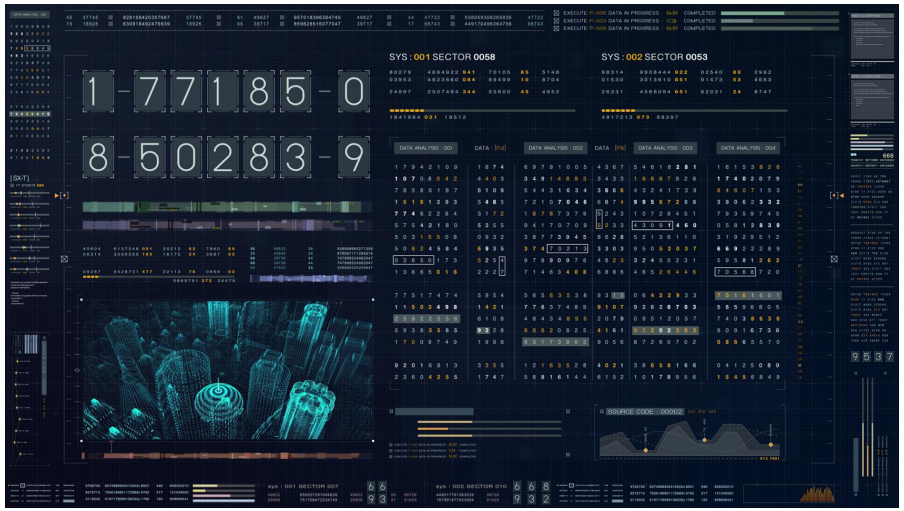
退出刚才的SSH登录，然后利用ssh-keygen生成密钥，并将密钥加入授权，具体命令如下：

```
$ exit
$ cd ~/.ssh/          # 若没有该目录，请先执行一次ssh localhost
$ ssh-keygen -t rsa    # 会有提示，都按回车即可
$ cat ./id_rsa.pub >> ./authorized_keys  # 加入授权
```

此时再用ssh localhost命令，无须输入密码就可以直接登录了。对于Ubuntu操作系统而言，到这里SSH就配置好了。







安装Java环境

由于Hadoop本身是使用Java编写的，因此，Hadoop的开发和运行都需要Java的支持，对于Hadoop 3.3.5而言，其要求使用JDK 1.8或者更新的版本。

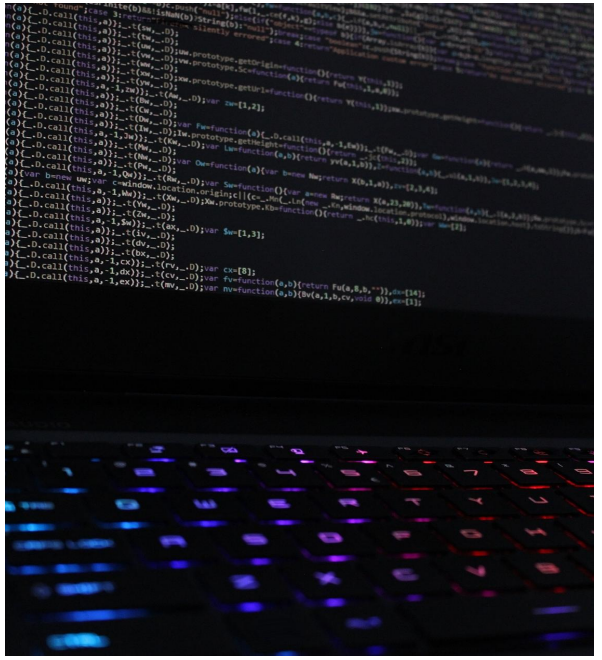
访问Oracle官网下载JDK 1.8安装包。这里假设下载得到的JDK安装文件为jdk-8u371-linux-x64.tar.gz，并且保存在Ubuntu操作系统的“/home/hadoop/Downloads/”目录下。

执行如下命令创建“/usr/lib/jvm”目录来存放JDK文件：

```
$cd /usr/lib
$sudo mkdir jvm #创建/usr/lib/jvm目录来存放JDK文件
```

执行如下命令对安装文件进行解压缩：

```
$cd ~ #进入hadoop用户的主目录
$cd Downloads
$sudo tar -zxvf ./jdk-8u371-linux-x64.tar.gz -C /usr/lib/jvm
```



安装Java环境

下面继续执行如下命令，设置环境变量：

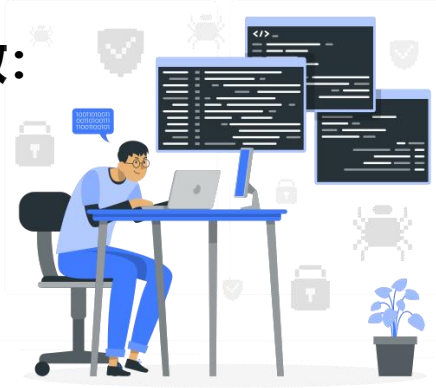
```
$vim ~/.bashrc
```

上面命令使用Vim编辑器打开了“hadoop”这个用户的环境变量配置文件，请在这个文件的开头位置，添加如下几行内容：

```
export JAVA_HOME=/usr/lib/jvm/jdk1.8.0_371
export JRE_HOME=${JAVA_HOME}/jre
export CLASSPATH=.:${JAVA_HOME}/lib:${JRE_HOME}/lib
export PATH=${JAVA_HOME}/bin:$PATH
```

保存.bashrc文件并退出Vim编辑器。然后，继续执行如下命令让.bashrc文件的配置立即生效：

```
$source ~/.bashrc
```



安装Java环境

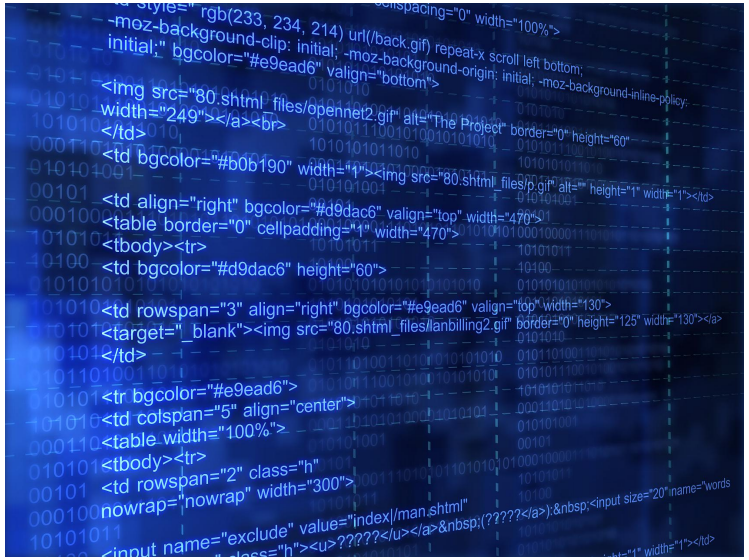
这时，可以使用如下命令查看是否安装成功：

```
$java -version
```

如果屏幕上能显示如下返回信息，则说明安装成功：

```
java version "1.8.0_371"
Java(TM) SE Runtime Environment (build 1.8.0_371-b11)
Java HotSpot(TM) 64-Bit Server VM (build 25.371-b11, mixed mode)
```







安装单机Hadoop

在采用单机模式时，Hadoop只在一台机器上运行，存储采用本地文件系统，没有采用分布式文件系统HDFS。这里使用的Hadoop版本为3.3.5。

下载地址为：https://archive.apache.org/dist/hadoop/core/hadoop-3.3.5/

在页面中选择hadoop-3.3.5.tar.gz进行下载即可。这里假设安装文件被保存到了Ubuntu操作系统的“~/Downloads”目录下，可以执行如下命令进行安装:

```
$sudo tar –zxf  ~/Downloads/hadoop-3.3.5.tar.gz -C /usr/local
$cd /usr/local/
$sudo mv ./hadoop-3.3.5/ ./hadoop     # 将目录名称修改为hadoop
$sudo chown -R hadoop ./hadoop        # 修改目录权限
```

然后，可以运行如下命令查看Hadoop的版本信息：

```
$ cd /usr/local/hadoop
$ ./bin/hadoop version
```

出现以下命令则表示安装成功：

```
Hadoop 3.3.5
……
This command was run using /usr/local/hadoop/share/hadoop/common/hadoop-common-3.3.5.jar
```



安装单机Hadoop

Hadoop默认模式为非分布式模式（本地模式），无需进行其他配置即可运行。Hadoop附带了丰富的例子，运行如下命令可以查看所有例子：

```
$ cd /usr/local/hadoop
$ ./bin/hadoop jar ./share/hadoop/mapreduce/hadoop-mapreduce-examples-3.3.5.jar
```

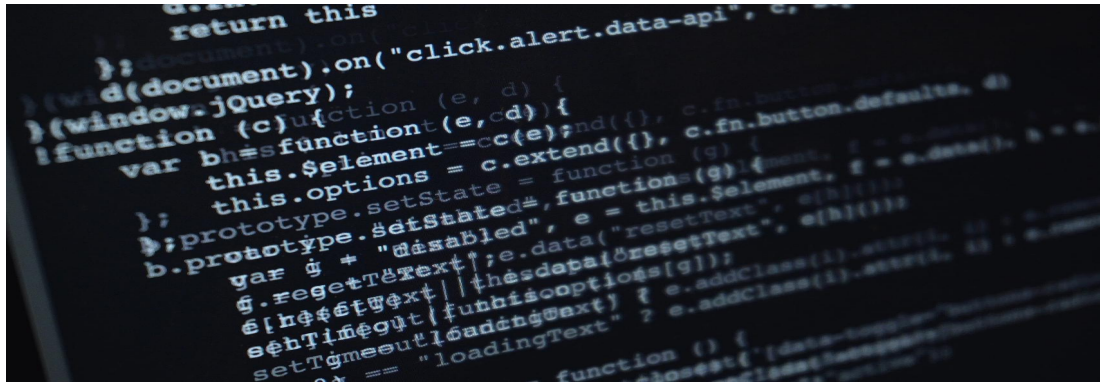
Hadoop文档中还附带了一些例子供我们测试，现在可以运行Grep实例来检测一下Hadoop是否安装成功。
首先，在Hadoop安装目录下新建input目录，用来存放输入数据，命令如下：

```
$mkdir input
```

然后，将“/usr/local/hadoop/etc/hadoop”目录下的配置文件复制到input目录，命令如下：

```
$cp ./etc/hadoop/*.xml ./input  #所有尾缀为’xml’的配置文件
```





安装单机Hadoop

接下来，执行如下代码运行Grep实例：

```
$./bin/hadoop jar /usr/local/hadoop/share/hadoop/mapreduce/hadoop-mapreduce-examples-3.3.5.jar grep ./input ./output 'dfs[a-z.]+'
```

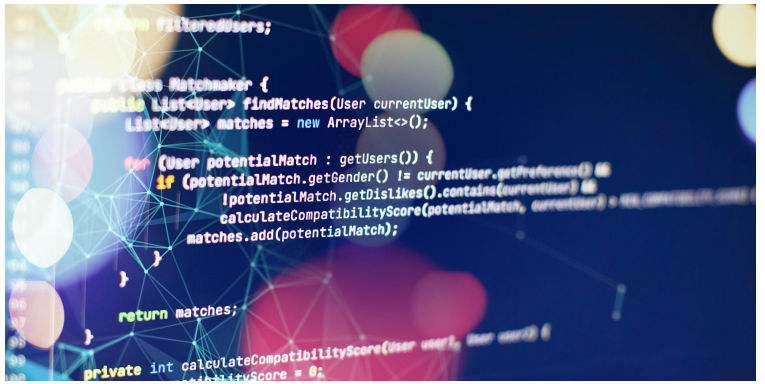
最后，可以执行以下命令查看输出数据：

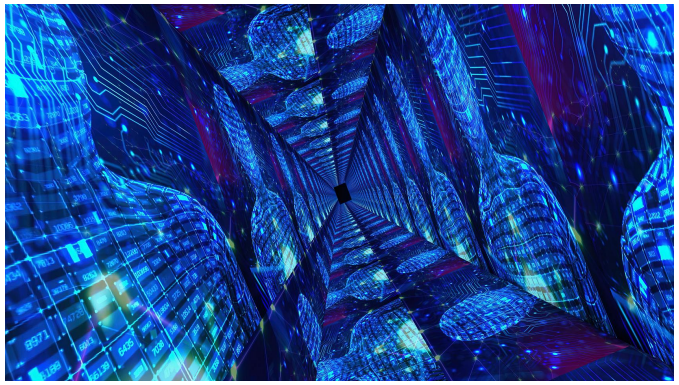
```
$cat ./output/*
```

运行上面命令后，可以得到以下结果：

```
1       dfsadmin
```







Hadoop伪分布式安装

用gedit编辑器修改后的core-site.xml文件的内容如下（路径：/usr/local/hadoop/etc/hadoop）：

```
<configuration>
        <property>
                <name>hadoop.tmp.dir</name>
                <value>file:/usr/local/hadoop/tmp</value>
                <description>Abase for other temporary directories.</description>
        </property>
        <property>
                <name>fs.defaultFS</name>
                <value>hdfs://localhost:9000</value>
        </property>
</configuration>
```

Hadoop伪分布式安装

用gedit编辑器修改后的hdfs-site.xml文件的内容如下（路径：/usr/local/hadoop/etc/hadoop）

```
<configuration>
        <property>
                <name>dfs.replication</name>
                <value>1</value>
        </property>
        <property>
                <name>dfs.namenode.name.dir</name>

        <value>file:/usr/local/hadoop/tmp/dfs/name</value>
        </property>
        <property>
                <name>dfs.datanode.data.dir</name>

        <value>file:/usr/local/hadoop/tmp/dfs/data</value>
        </property>
</configuration>
```



Hadoop伪分布式安装

在配置完成后，首先需要初始化文件系统，由于Hadoop的很多工作是在自带的HDFS上完成的，因此，需要将文件系统初始化之后才能进一步执行计算任务。执行初始化的命令如下：

```
$cd /usr/local/hadoop
$./bin/hdfs namenode -format
```

如果格式化成功，会看到“successfully formatted”的提示信息（如图所示）。

```
2023-06-16 20:15:26,505 INFO common.Storage: Storage directory /usr/local/hadoop/tmp/df
s/name has been successfully formatted.
2023-06-16 20:15:26,562 INFO namenode.FSImageFormatProtobuf: Saving image file /usr/loc
al/hadoop/tmp/dfs/name/current/fsimage.ckpt_0000000000000000000 using no compression
2023-06-16 20:15:26,764 INFO namenode.FSImageFormatProtobuf: Image file /usr/local/hado
op/tmp/dfs/name/current/fsimage.ckpt_0000000000000000000 of size 401 bytes saved in 0 s
econds .
2023-06-16 20:15:26,788 INFO namenode.NNStorageRetentionManager: Going to retain 1 imag
es with txid >= 0
2023-06-16 20:15:26,840 INFO namenode.FSNamesystem: Stopping services started for activ
e state
2023-06-16 20:15:26,841 INFO namenode.FSNamesystem: Stopping services started for stand
by state
2023-06-16 20:15:26,847 INFO namenode.FSImage: FSImageSaver clean checkpoint: txid=0 wh
en meet shutdown.
2023-06-16 20:15:26,847 INFO namenode.NameNode: SHUTDOWN_MSG:
/************************************************************
SHUTDOWN_MSG: Shutting down NameNode at ubuntu/127.0.1.1
************************************************************/
```

执行名称节点格式化后的提示信息

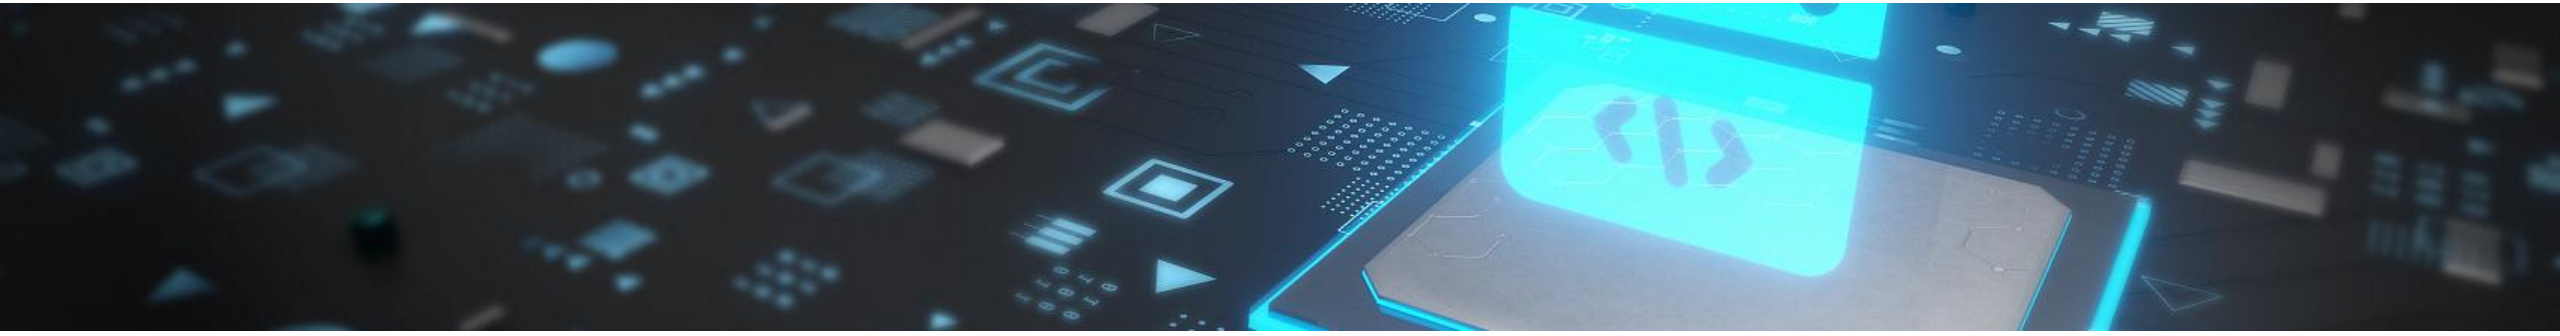
Hadoop伪分布式安装

文件系统初始化成功以后，可以用如下命令启动HDFS：

```
$cd /usr/local/hadoop
$./sbin/start-dfs.sh
```

根据启动过程中屏幕上出现的提示信息可以知道，**启动过程的所有启动信息都写入了对应的日志文件**。如果出现启动错误，则可以在日志中查看错误原因。
启动之后，可以输入jps指令查看所有的Java进程。如果HDFS启动mn成功，可以得到如下类似结果：

```
$jps
4011 jps
3516 NameNode
3852 SecondaryNameNode
3638 DataNode
```



Hadoop伪分布式安装

此时，可以访问Web页面（http://localhost:9870）来查看Hadoop的信息。
接下来，执行如下命令，在HDFS中创建hadoop用户的用户目录：

```
$cd /usr/local/hadoop
$./bin/hdfs dfs -mkdir -p /user/hadoop
```

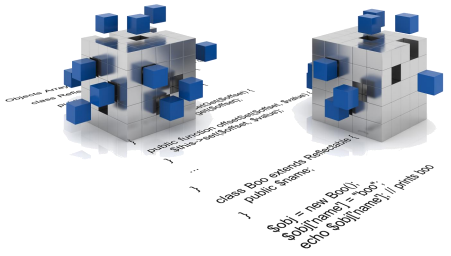


然后，在HDFS的“/user/hadoop”目录下创建input目录，命令如下：

```
$./bin/hdfs dfs -mkdir input
```

现在，需要将“/usr/local/hadoop/etc/hadoop”目录下的本地文本文件（配置文件）“上传”到分布式文件系统HDFS中的“/user/hadoop/input”目录下。当然，**这里的“上传”并不意味着数据通过网络传输**。实际上，在伪分布式Hadoop环境下，**本地的“/usr/local/hadoop/etc/hadoop”目录和HDFS中的“/user/hadoop/input”目录都在同一台机器上，并不需要通过网络传输数据**。可以执行如下命令实现文件“上传”：

```
$./bin/hdfs dfs -put ./etc/hadoop/*.xml input
```



Hadoop伪分布式安装

接着，运行如下命令来执行测试样例程序Grep：

```
$./bin/hadoop jar /usr/local/hadoop/share/hadoop/mapreduce/hadoop-mapreduce-examples-3.3.5.jar grep input output 'dfs[a-z.]+'
```

在计算完成后，系统会自动在HDFS中生成“/user/hadoop/output”目录来存储计算结果。可以输入如下命令查看最终结果：

```
$./bin/hdfs dfs -cat output/*
```

运行上面命令后，可以得到以下结果：

```
1       dfsadmin
1       dfs.replication
1       dfs.namenode.name.dir
1       dfs.datanode.data.dir
```



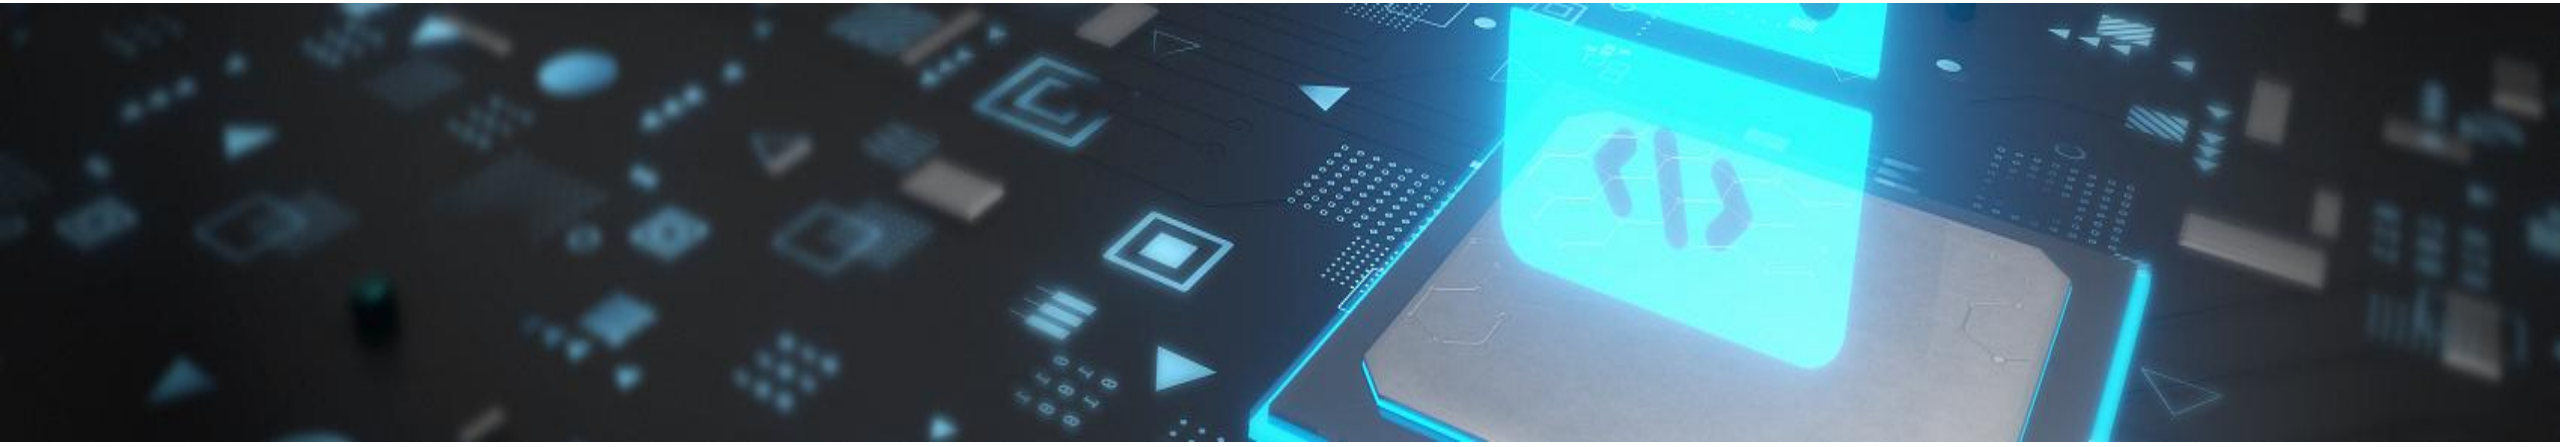
Hadoop伪分布式安装

需要指出的是，当需要重新运行程序时，首先应将 HDFS 中的 output 目录删除，然后运行程序。删除 output 目录的命令如下：

```
$./bin/hdfs dfs -rm -r output
```

需要停止运行 HDFS 时，可以执行如下命令：

```
$cd /usr/local/hadoop
$./sbin/stop-dfs.sh
```



Hadoop集群的安装

当Hadoop采用分布式模式部署和运行时，其存储采用分布式文件系统HDFS。在这种模式下，**HDFS的名称节点和数据节点位于集群中的不同机器上**。这时，数据就可以分布到多个节点上，**不同数据节点上的数据计算可以并行执行**，此时 Hadoop 的核心—MapReduce的分布式计算能力才能真正发挥作用。

伪分布式安装是在单台机器上模拟一个小型集群，虽然仍然使用 HDFS 文件系统，但**名称节点和数据节点都部署在同一台机器上**。这种方式便于开发、调试和学习 Hadoop 的基本使用流程，但不具备真正的分布式性能优势。



