《大数据应用案例》随堂作业

一、选择题

1. 在大数据平台的分层架构中，主要负责离线处理、实时处理、交互式分析等任务的一层是

A. 数据存储层 B. 数据处理层 C. 数据应用层 D. 数据源层

2. 更适合用于采集网站访问日志、服务器运行日志这类持续产生数据的工具是

A. Sqoop B. Flume C. MySQL D. Kylin

3. 最适合“每天夜里统一统计前一天订单数据并生成日报”的处理模式是

A. 实时处理 B. 交互式多维分析 C. 离线批处理 D. 图计算

4. 如果需要分析“社交网络中哪些人处于核心位置”，更适合使用哪类计算模式

A. 批处理计算 B. 查询分析计算 C. 图计算 D. 数据仓库计算

5. 在分布式文件系统 HDFS 中，负责管理文件系统命名空间和元数据的组件是

A. DataNode B. NameNode C. SecondaryNameNode D. YARN

6. HDFS 将一个大文件切分后，分散存储的基本单位是

A. Packet B. Replica C. Block D. Node

7. 在 HDFS 的写入流程中，客户端首先向哪个组件请求 block 的存放位置

A. DataNode B. NameNode C. SecondaryNameNode D. JournalNode

8. 在 Hadoop 2.x 中，解决 NameNode 单点故障问题的机制是

A. HDFS Federation B. HDFS HA C. MapReduce D. Flume

9. 在 MapReduce 中，Map 阶段处理的数据单位是

A. Block B. Split C. Partition D. Replica

10. 下列关于 split 的说法，正确的是

A. split 是 HDFS 中真实切出的物理小文件

B. split 是一种逻辑分片，一个 split 通常对应一个 Map Task

C. split 的个数由 Reduce Task 的个数决定

D. split 只在 Reduce 阶段使用

11. 在 WordCount 程序中，Map 阶段输出的典型结果形式是

A. (line, word) B. (word, 1) C. (1, word) D. (word, total)

12. Shuffle 阶段的核心作用是

A. 将 HDFS 文件切分成 block

B. 将 Map 输出的中间结果按 key 重新组织并分发给对应的 Reduce 节点

C. 负责执行 reduce() 函数

D. 将最终结果写回 HDFS

13. 在 Hadoop 1.x 中，负责资源监控和作业调度的组件是

A. NameNode B. JobTracker C. DataNode D. TaskTracker

14. 关于 slot 的说法，正确的是

A. slot 是 HDFS 中存储数据的物理单位

B. slot 是一个逻辑资源单位，用来表示节点可并发执行任务的能力

C. 一个 Task 不需要 slot 也能运行

D. slot 只供 Reduce Task 使用

15. 下列关于 NoSQL 数据库的说法，正确的是

A. NoSQL 一定完全替代关系型数据库

B. NoSQL 更适合大规模、高并发、灵活结构的数据场景

C. NoSQL 都支持复杂事务和多表连接

D. NoSQL 只能存储键值型数据

16. HBase 中负责管理 Region 分配与表管理的组件是

A. Zookeeper B. RegionServer C. HMaster D. HDFS

二、填空题

1. 在 Hadoop 生态中，_____ 负责分布式存储，_____ 负责资源管理和任务调度。

2. HDFS 中保存命名空间和元数据信息的节点是 _____，真正负责存储数据块的节点是 _____。

3. HDFS 中提高系统可靠性和容错能力的重要机制是 _____ 机制。

4. MapReduce 中，Map 阶段处理的数据单位是 _____，Reduce 阶段处理的是按规则划分后的中间结果 _____。

5. 一个 InputSplit 通常对应一个 _____ Task；一个 Partition 通常对应一个 _____ Task。

6. MapReduce 的完整处理流程一般可以概括为：split、_____、_____、reduce。

7. Shuffle 的本质，是把相同 _____ 的数据汇总到同一个 Reduce 上。

8. HBase 中，一个表会被水平划分成多个 _____ 来分布式存储。

三、问答题

1. 简述 Hadoop 生态系统中 HDFS、YARN、MapReduce 分别负责什么。

2. 简述 HDFS 中 NameNode 和 DataNode 的分工。

3. 简述 HDFS HA 和 HDFS Federation 分别解决了什么问题。

4. 简述 MapReduce 中 Map 阶段、Shuffle 阶段、Reduce 阶段各自的主要作用。

5. 为什么 MapReduce 中 split 的默认大小通常与 HDFS 的 block 大小相同？

6. 简述 NoSQL 数据库与传统关系型数据库相比有哪些主要特点。