一、实验目的

（1）掌握使用 Spark 访问本地文件和 HDFS 文件的方法。
（2）掌握 Spark 应用程序的编写、编译和运行方法。

二、实验平台

- 操作系统：Ubuntu 16.04 及以上。
- Spark 版本：3.4.0。
- Hadoop 版本：3.3.5。

进入 Linux 操作系统，完成 Hadoop 伪分布式模式的安装。完成 Hadoop 的安装以后，再安装 Spark（Local 模式）。**具体安装过程参考群文件 PPT**。

三、作业要求（给出具体步骤及代码）

1．Spark 读取文件系统的数据

（1）在 spark-shell 中读取 Linux 操作系统本地文件“/home/hadoop/test.txt”，然后统计出文件的行数；
（2）在 spark-shell 中读取 HDFS 文件“/user/hadoop/test.txt”（如果该文件不存在，请先创建），然后统计出文件的行数；
（3）编写独立应用程序（推荐使用 Scala 或 Java），读取 HDFS 文件“/user/hadoop/test.txt”（如果该文件不存在，请先创建），然后统计出文件的行数；通过 sbt 或 Maven 将整个应用程序编译打包成 JAR 包，并将生成的 JAR 包通过 spark-submit 提交到 Spark 中运行。

2．编写独立应用程序实现数据去重

对于两个输入文件 A 和 B，编写 Spark 独立应用程序（推荐使用 Scala 或 Java），对两个文件进行合并，并剔除其中重复的内容，得到一个新文件 C。通过 sbt 或 Maven 将整个应用程序编译打包成 JAR 包，并将生成的 JAR 包通过 spark-submit 提交到 Spark 中运行。
下面是输入文件和输出文件的一个样例，可供参考。
输入文件 A 的样例如下：

```
20170101    x
20170102    y
20170103    x
20170104    y
20170105    z
20170106    z
```

输入文件 B 的样例如下：

```
20170101    y
```

20170102 y
20170103 x
20170104 z
20170105 y

根据输入的文件 A 和 B 合并得到的输出文件 C 的样例如下：

20170101 x
20170101 y
20170102 y
20170103 x
20170104 y
20170104 z
20170105 y
20170105 z
20170106 z

3．编写独立应用程序实现求平均值问题

每个输入文件表示班级学生某个学科的成绩，每行内容由两个字段组成，第一个是学生名字，第二个是学生的成绩；编写 Spark 独立应用程序求出所有学生的平均成绩，并输出到一个新文件中。通过 sbt 或 Maven 将整个应用程序编译打包成 JAR 包，并将生成的 JAR 包通过 spark-submit 提交到 Spark 中运行。

下面是输入文件和输出文件的一个样例，可供参考。

Algorithm 成绩：

小明 92
小红 87
小新 82
小丽 90

Database 成绩：

小明 95
小红 81
小新 89
小丽 85

Python 成绩：

小明 82
小红 83
小新 94
小丽 91

平均成绩如下：

(小红,83.67)
(小新,88.33)
(小明,89.67)
(小丽,88.67)