


数据挖掘

Data Mining



基本信息

- 教师：高宏
- 办公室：未来科创中心 605
- 联系邮箱：gaohong@suda.edu.cn

基本信息


● 研究方向:

- 虚拟/增强/扩展现实
- 人机交互

● 主页: <https://web.suda.edu.cn/gaohong/>

- 招生: 本课题组招收免试推荐研究生(推免生), 欢迎成绩优异、对科研有浓厚兴趣的同学申请加入!






QQ群号：
1061722660



数据挖掘-2025秋...

群号: 1061722660



教材-作者

- <http://www.cs.illinois.edu/homes/hanj/>
- The book will be covered in two courses at CS, UIUC: 伊利诺伊大学, 厄巴纳-尚佩恩(University of Illinois at Urbana-Champaign)
 - **CS412: Introduction to data warehousing and data mining**
Coverage (Chapters 1-7 of This Book)
 - **CS512: Data mining: Principles and algorithms**
(Chapters 8-11 of This Book)



Jiawei Han


Professor, Department of Computer Science
Univ. of Illinois at Urbana-Champaign
Rm 2132, Siebel Center for Computer Science
201 N. Goodwin Avenue
Urbana, IL 61801, USA
E-mail: hanj[at]cs.uiuc.edu


Ph.D. (1985), Computer Science, Univ. Wisconsin-Madison

Data Mining and Databases

Data Mining Research Group
(Data Mining Group Summary Report: Sp
Database and Information Systems Research
(UIUC Academic Calendar)

Fax: (217) 265-6494
Web: www.cs.uiuc.edu/~hanj






课程概述

■ 总体课程目标


数据仓库与数据挖掘技术是多学科交叉的新兴技术，它是随着数据的大量积累以及市场竞争对信息与知识的迫切需求而产生和发展起来的，是计算机学科的重要分支。该课程主要目的是使学生建立数据仓库与数据挖掘的概念，进而掌握数据仓库与数据挖掘的基本原理及应用。



课程概述

- 具体课程目标

- 数据仓库和数据挖掘的基本知识；
- 用于挖掘关联规则知识的基本算法，用于挖掘分类和预测知识的分类算法、神经网络、遗传算法等经典算法；
- 了解先进的数据挖掘方法，以及对实际应用问题展开讨论。




课程信息

- 主要授课内容

- 第1章： 引言
- 第2章： 认识数据
- 第3章： 数据预处理
- 第4-5章： 数据仓库与OLAP、数据立方体
- 第6-7章： 挖掘频繁模式、关联和相关、高级模式挖掘
- 第8章： 分类基本概念
- 第9章： 分类高级方法
- 第10章： 聚类基本概念
- 第11章： 聚类高级方法
- 第12章： 离群点检测
- 第13章： 数据挖掘的应用和发展趋势（选讲）

- 所需前置知识： Python、数据库系统、统计学与机器学习




课时安排与考核

■ 课时安排

- 总学时 54，讲课学时 36，课内上机学时 18
- 起止：第1-17周（3-5 节/周一）
 - 其中第6周（中秋节）全校停课
- 上课地点：未来科创中心3层云桌面机房1号


■ 考核

- 平时成绩50%（点名20%+作业30%）+ 期末考试50%





第1章 引论

- **动机：为什么要数据挖掘？**
- **什么是数据挖掘？**
- **数据挖掘：在什么数据上进行？**
- **数据挖掘功能**
- **所有的模式都是有趣的吗？**
- **数据挖掘系统分类**
- **数据挖掘的主要问题**




数据处理技术的演进

- 1960s:
 - 数据收集, 数据库创建, IMS层次和网状 DBMS
- 1970s:
 - 关系数据库模型, 关系 DBMS 实现
- 1980s:
 - RDBMS, 先进的数据模型和面向应用的
- 1990s—2000s:
 - 数据挖掘和数据仓库, 多媒体数据库, 和 Web 数据库



动机：需要是发明之母



■ 数据爆炸问题

- 自动的数据收集工具和成熟的数据库技术导致大量数据存放在数据库, 数据仓库, 和其它信息存储中


- Business: Web, e-commerce, transactions, stocks, ...
- Science: Remote sensing, bioinformatics, scientific simulation, ...
- Society and everyone: news, digital cameras, YouTube

■ 我们正被数据淹没, 但却缺乏知识

- 数据丰富, 但信息贫乏


■ 解决办法: 数据仓库与数据挖掘

- 数据仓库与联机分析处理(OLAP)
- 从大型数据库的数据中提取有趣的知识(规则, 规律性, 模式, 限制等)



数据挖掘界简史（学术会议）

- 1989 IJCAI Workshop on Knowledge Discovery in Databases (Piatetsky-Shapiro)
 - Knowledge Discovery in Databases (G. Piatetsky-Shapiro and W. Frawley, 1991)
- 1991-1994 Workshops on Knowledge Discovery in Databases
 - Advances in Knowledge Discovery and Data Mining (U. Fayyad, G. Piatetsky-Shapiro, P. Smyth, and R. Uthurusamy, 1996)
- 1995-1998 International Conferences on Knowledge Discovery in Databases and Data Mining (KDD'95-98)
 - Journal of Data Mining and Knowledge Discovery (1997)
- 1998 ACM SIGKDD, SIGKDD'1999-2001 conferences, and SIGKDD Explorations
- More conferences on data mining
 - PAKDD, PKDD, SIAM-Data Mining, (IEEE) ICDM, etc.
- ACM Transactions on KDD starting in 2007



Conferences and Journals on Data Mining

- **KDD Conferences**


- **ACM SIGKDD Int. Conf. on Knowledge Discovery in Databases and Data Mining (KDD)**
- **SIAM Data Mining Conf. (SDM)**
- **(IEEE) Int. Conf. on Data Mining (ICDM)**
- **Conf. on Principles and practices of Knowledge Discovery and Data Mining (PKDD)**
- **Pacific-Asia Conf. on Knowledge Discovery and Data Mining (PAKDD)**

- **Other related conferences**

- **ACM SIGMOD**
- **VLDB**
- **(IEEE) ICDE**
- **WWW, SIGIR**
- **ICML, CVPR, NIPS**

- **Journals**

- **Data Mining and Knowledge Discovery (DAMI or DMKD)**
- **IEEE Trans. On Knowledge and Data Eng. (TKDE)**
- **KDD Explorations**
- **ACM Trans. on KDD**



How to Find References? DBLP, CiteSeer, Google

- Data mining and KDD (SIGKDD: CDROM)
 - Conferences: ACM-SIGKDD, IEEE-ICDM, SIAM-DM, PKDD, PAKDD, etc.
 - Journal: Data Mining and Knowledge Discovery, KDD Explorations, ACM TKDD
- Database systems (SIGMOD: ACM SIGMOD Anthology—CD ROM)
 - Conferences: ACM-SIGMOD, ACM-PODS, VLDB, IEEE-ICDE, EDBT, ICDT, DASFAA
 - Journals: IEEE-TKDE, ACM-TODS/TOIS, JIIS, J. ACM, VLDB J., Info. Sys., etc.
- AI & Machine Learning
 - Conferences: Machine learning (ML), AAAI, IJCAI, COLT (Learning Theory), CVPR, NIPS, etc.
 - Journals: Machine Learning, Artificial Intelligence, Knowledge and Information Systems, IEEE-PAMI, etc.
- Web and IR
 - Conferences: SIGIR, WWW, CIKM, etc.
 - Journals: WWW: Internet and Web Information Systems,
- Statistics
 - Conferences: Joint Stat. Meeting, etc.
 - Journals: Annals of statistics, etc.
- Visualization
 - Conference proceedings: CHI, ACM-SIGGraph, etc.
 - Journals: IEEE Trans. visualization and computer graphics, etc.

什么是数据挖掘?




- **数据挖掘 (从数据中挖掘知识):**
 - 从大型数据(库)中提取有趣的 (非平凡的, 蕴涵的, 先前未知的 并且是 潜在有用的) 信息或模式
 - 数据挖掘: 用词不当?
- **其它叫法和“inside stories”内幕新闻:**
 - 数据库中知识发现(挖掘) (Knowledge discovery in databases, KDD), 知识提取(knowledge extraction), 数据/模式分析(data/pattern analysis), 数据考古(data archeology), 数据捕捞(data dredging), 信息收获 (information harvesting), 商务智能(business intelligence), 等.
- **什么不是数据挖掘?**
 - (演绎) 查询处理 (是“已知”而去“验证”) → 数据挖掘是“未知”而去“发现”
 - 专家系统 (if-then系统, 人类灌输知识) 或小型 机器学习(ML)/统计程序
 - **DM处理大量数据/ 有效的可伸缩的技术**


Why Not Traditional Data Analysis?

- **巨大的数据** Tremendous amount of data
 - **Algorithms must be highly scalable to handle such as tera-bytes (太字节TB) of data**
- **High-dimensionality of data**
 - **Micro-array may have tens of thousands of dimensions**
- **High complexity of data**
 - **Data streams and sensor data**
 - **Time-series data, temporal data, sequence data**
 - **Structure data, graphs, social networks and multi-linked data**
 - **Heterogeneous databases (异构数据库) and legacy databases (遗产/遗留数据库)**
 - **Spatial, spatiotemporal, multimedia, text and Web data**
 - **Software programs, scientific simulations**
- **New and sophisticated applications**

数据挖掘过程


- 数据挖掘： KDD
(Knowledge discovery in
databases) 的核心





KDD过程的步骤

- **学习应用领域:**
 - 相关的先验知识和应用的目标
- **创建目标数据集: 数据选择**
- **数据清理和预处理: (可能占全部工作的 60%!)**
- **数据归约与变换:**
 - 发现有用的特征, 维/变量归约, 不变量的表示.
- **选择数据挖掘函数**
 - 汇总, 分类, 回归, 关联, 聚类.
- **选择挖掘算法**
- **数据挖掘: 搜索有趣的模式**
- **模式评估和知识表示**
 - 可视化, 变换, 删除冗余模式, 等.
- **发现知识的使用**




KDD过程—请你举例！

■ 举例：电商公司的“猜你喜欢”与营销策略

→第1步：数据（Data）—原始数据

- **是什么：** 公司数据库里海量、原始的日志和数据表。
- **例子：**
 - 用户信息表：用户ID、注册时间、性别、地区。
 - 商品信息表：商品ID、品类、价格、品牌。
 - 行为日志表：用户ID、商品ID、浏览时间、是否购买、购买时间、评分。
 - 订单表：订单ID、用户ID、支付金额、商品列表。
- **状态：** 数据分散、庞大、杂乱（有些浏览记录没用户信息，有些商品已下架，有些地址填写错误）



KDD过程—请你举例！


- 举例：电商公司的“猜你喜欢”与营销策略

→第2步：数据集成 (Data Integration) - 把数据拢到一起

- **做什么：**把上述四个分散的数据源整合到同一个数据分析平台或数据仓库里。

- **例子：**

通过用户ID和商品ID这几个键，将用户信息、商品信息、行为日志和订单表关联成一张巨大的、宽泛的“事实表”。这样，一条记录就能看到“谁”、“什么时候”、“对什么商品”、“做了什么操作”、“最后是否成交”。



KDD过程—请你举例！

■ 举例：电商公司的“猜你喜欢”与营销策略

→第3步：数据清理 (Data Cleaning) - 处理脏数据


- **做什么：** 处理缺失、错误、不一致的数据。

- **例子：**

处理缺失值： 有些用户没填性别，系统可能根据其购买记录（如常买男装还是女装）推断一个性别，或直接标记为“未知”。

消除噪声： 剔除那些因为页面脚本错误生成的、停留时间极短（<1秒）的“虚假”点击记录。

纠正错误： 将用户地址栏里写的“Zhejiang”、“ZheJiang”、“浙江”统一规范成“浙江省”。




KDD过程—请你举例！

■ 举例：电商公司的“猜你喜欢”与营销策略

→第4步：数据选择与变换 (Data Selection & Transformation)

- 挑出有用的，变成合适的

- **数据选择：**并不是所有数据都对“推荐商品”这个任务有用。
- **例子：**分析师决定，本次分析只选取过去一年的购买记录和收藏行为，而忽略“浏览”行为（因为数据量太大且噪声多）。这就是在选择与任务相关的数据。
- **数据变换：**将数据变成更适合挖掘的形态。
- **例子：**将连续型的“价格”变量离散化，变成“低价位（0-100）”、“中价位（100-500）”、“高价位（500+）”三个等级。或者，为每个用户构造一个新特征：“最近30天活跃度”，这个特征更好用。




KDD过程—请你举例！

■ 举例：电商公司的“猜你喜欢”与营销策略

→第5步：数据挖掘 (Data Mining) - 核心算法上场

- **做什么：** 从应用算法从处理好的数据中寻找模式。
- **例子：**
 - 使用关联规则分析：发现{奶粉，尿布} -> {儿童湿巾}这样的强关联规则（经典的“购物篮分析”）。这意味着买奶粉和尿布的顾客很可能会买儿童湿巾。
 - 使用聚类分析：将用户分成不同的群体，比如“高消费年轻女性群体”、“偏爱折扣的老年群体”、“母婴用品群体”。这就是用户分群。




KDD过程—请你举例！

■ 举例：电商公司的“猜你喜欢”与营销策略

→第6步：模式评估 (Pattern Evaluation) - 判断模式的价值

- **做什么：** 评估上一步挖掘出的模式是否有趣、有用、可应用。
- **例子：**
 - 算法可能挖出{游戏鼠标} -> {高端机械键盘}的规则，但进一步评估发现，虽然置信度高，但支持度非常低（只有极少数人这么买），没有大规模推广的价值，这个规则就被舍弃。
 - 而{奶粉，尿布} -> {儿童湿巾}这条规则，支持度和置信度都很高，被认为是一个强规则，具有商业价值。




KDD过程—请你举例！

■ 举例：电商公司的“猜你喜欢”与营销策略

→第7步：知识 (Knowledge) - 模式变成 actionable 的策略

- **做什么：** 将评估后的模式转化为具体的商业知识或应用。
- **例子：**
 - 基于关联规则的知识：“将儿童湿巾作为奶粉和尿布购物车的推荐商品或组合折扣商品。”这就是一条可执行的营销知识。
 - 基于聚类分析的知识：“针对‘母婴用品群体’，应在App首页推送奶粉、玩具广告；而针对‘偏爱折扣的老年群体’，应推送粮油副食的折扣券。”这就是一条精准营销的知识。

KDD 过程: 机器学习和统计的角度



- This is a view from typical machine learning and statistics communities

典型的数据挖掘系统结构






图 1.5：典型的数据挖掘系统结构


数据挖掘和商务智能






什么时候使用数据挖掘?

- **数据库分析和决策支持**
 - **市场分析和管埋**
 - 针对销售(target marketing), 顾客关系管理, 购物篮分析, 交叉销售(cross selling), 市场分割(market segmentation)
 - **风险分析与管理**
 - 预测, 顾客关系, 改进保险, 质量控制, 竞争能力分析
 - **欺骗检测与管理**
- **其它应用**
 - **文本挖掘 (新闻组, email, 文档资料)**
 - **流数据挖掘(Stream data mining)**
 - **Web挖掘.**
 - **生物信息学/生物 数据分析**




市场分析与管理(1)

- **用于分析的数据源在哪?**
 - 信用卡交易, 会员卡, 打折优惠券, 顾客投诉电话, (公共) 生活时尚研究
- **针对销售(Target marketing)**
 - 找出顾客群, 他们具有相同特征: 兴趣, 收入水平, 消费习惯, 等.
- **确定顾客随时间变化的购买模式**
 - 个人帐号到联合帐号的转变: 结婚, 等.
- **交叉销售分析(Cross-market analysis)**
 - 产品销售之间的关联/相关
 - 基于关联信息的预测




市场分析与管理(2)

- **顾客分类(Customer profiling)**
 - **数据挖掘能够告诉我们什么样的顾客买什么产品(聚类或分类)**
- **识别顾客需求**
 - **对不同的顾客识别最好的产品**
 - **使用预测发现什么因素影响新顾客**
- **提供汇总信息**
 - **各种多维汇总报告**
 - **统计的汇总信息 (数据的中心趋势和方差)**



法人分析和风险管理

- **财经规划和资产评估**
 - 现金流分析和预测
 - 临时提出的资产评估
 - 交叉组合、时间序列分析、趋势分析等)
- **资源规划：**
 - 资源与开销的汇总与比较
- **竞争：**
 - 管理竞争者和市场指导
 - 对顾客分类和基于类的定价
 - 在高度竞争的市场调整价格策略



欺骗检测和管理(1)

- 应用


- 广泛用于健康照料, 零售, 信用卡服务, 电讯 (电话卡欺骗), 等.

- 方法

- 使用历史数据建立欺骗行为模型, 使用数据挖掘帮助识别类似的实例


- 例

- 汽车保险: 检测这样的人, 他/她假造事故骗取保险赔偿
- 洗钱: 检测可疑的金钱交易
- 医疗保险: 检测职业病患者, 医生和介绍人圈




欺骗检测和管理(2)

- **检测不适当的医疗处置**
 - 澳大利亚健康保险会发现许多全面的检查是请求做的，而不是实际需要的 (每年节省100万澳元)
- **检测电话欺骗**
 - 电话呼叫模式: 通话距离, 通话时间, 每天或每周通话次数
 - 英国电讯识别频繁内部通话的呼叫者的离散群, 特别是移动电话, 超过数百万美元的欺骗
- **零售**
 - 分析家估计38%的零售业萎缩是由于不忠诚的雇员造成的



生物数据分析/挖掘


- microarray data analysis 微阵列数据
- biological sequence analysis 生物序列
- 生物文本挖掘
 - 文本数据中抽取 biological information
 - 从抽取信息中 infer, predict biological features



生物数据分析/挖掘

■ microarray data analysis 微阵列数据


- 它是什么？ 微阵列（或称基因芯片）是一种同时测量成千上万个基因在特定样本（如正常细胞 **vs** 癌细胞）中表达水平（即活性高低）的技术。
- 分析目标（挖什么？）：
 - 识别差异表达基因：找出在两种不同条件下（如癌与正常）表达水平存在显著差异的基因。这些基因可能与疾病密切相关。
 - 分类：基于基因表达谱构建模型，用于对疾病进行分类（如癌症分型）或预测预后。
 - 聚类：将表达模式相似的基因或样本聚在一起。共表达的基因可能具有相似的功能或受相同的调控；样本聚类可以发现新的疾病亚型。
- 简单比喻：就像 同时 给数万个人做“问卷调查”，问他们在某个特定时刻“忙不忙”（表达水平高低），然后找出哪些人在“生病时”比“健康时”明显更忙或更闲（差异表达），从而锁定可疑对象（候选疾病基因）。



生物数据分析/挖掘


■ biological sequence analysis生物序列

- 分析DNA（基因蓝图）、RNA（工作指令）、蛋白质（功能执行者）的序列数据。
- 分析目标（挖什么？）：
 - 序列比对：比较不同物种或个体的序列，寻找相似性，用于发现基因功能、追溯进化关系。
 - 基因识别：在长长的DNA序列中预测哪里是基因的起始和结束位置。
 - 变异分析：识别个体基因组中的突变（如单核苷酸多态性SNP），研究其与疾病或性状的关联。
- 简单比喻：像“文本分析”。DNA序列是由A, T, C, G四个“字母”写成的“天书”。分析就是在这本天书中进行“查找关键词（基因）”、“比较不同版本的文章（序列比对）”、“检查拼写错误（变异分析）”。




其它应用

- **运动**
 - **IBM Advanced Scout分析NBA的统计数据（阻挡投篮, 助攻, 和犯规）获得了纽约尼克斯队对迈阿密热火队的竞争优势**
- **Internet Web Surf-Aid**
 - **IBM Surf-Aid 将数据挖掘算法用于有关交易的页面的Web访问日志, 以发现顾客喜爱的页面, 分析Web 销售的效果, 改进Web 站点的组织等**
- **Web: 页面的分类、聚类、推荐/用户的访问模式**




数据挖掘:在什么数据上进行?

- 关系数据库
- 数据仓库
- 事务(交易)数据库
- 先进的数据库和信息存储
 - 面向对象和对象-关系数据库
 - 空间和时间数据
 - 时间序列数据和流数据
 - 文本数据库和多媒体数据库
 - 异种数据库和遗产数据库
 - WWW




数据挖掘功能(1)

- **概念描述: 特征和区分** Characterization and discrimination
 - 概化, 汇总和比较数据特征, 例如, 干燥和潮湿的地区
 - 两种地区的特征是什么? 如何区分?
 - 特征化→ “自己是什么样” ; 区分→ “我和别人那哪里不一样”



数据挖掘功能(1)

- 频繁模式、关联、相关 Frequent patterns, association, correlation vs. causality
 - **频繁模式**：数据中频繁出现的模式
 - **多维和单维关联**
 - $age(X, "20..29") \wedge income(X, "20..29K") \Rightarrow buys(X, "PC")$
[support = 2%, confidence = 60%]
 - $contains(T, "computer") \Rightarrow contains(T, "software")$
[support = 1%, confidence = 75%]



数据挖掘功能(2)

■ 分类和预测

- 找出描述和识别类或概念的模型(函数), 用于标号未知的对象的标号 预测/Predict some unknown class labels
- 例如根据气候对国家分类, 或根据单位里程的耗油量对汽车分类
 - 模型表示: 判定树(decision-tree), 分类规则, 神经网络
- 判别分析discriminate analysis
 - 有监督方法 supervised method/在已知对象分成若干类别并取得各种类别的一组观测样本, 在此基础上根据某些准则 (学习) 建立判别式; 然后对未知类别样本进行(判别) 分类
- 预测: 预测某些未知或遗漏的数据值/定量的quantitative输出变量

数据挖掘功能(3)

- **聚类分析** Unsupervised learning (i.e., Class label is unknown)
 - **类标号(Class label) 未知: 对数据分组, 形成新的类. 例如, 对房屋分类, 找出分布模式**
 - **聚类原则: 最大化类内的相似性, 最小化类间的相似性**






Figure 1. Data clustering.




数据挖掘功能(4)

- 孤立点(Outlier, 离群点or异常值)分析

- 孤立点: 一个数据对象, 它与数据的一般行为不一致
- 孤立点可以被视为例外, 但对于欺骗检测和罕见事件分析, 它是相当有用的

- ✓ 视为需要研究的“宝藏”(Treasure)

- ✓ 孤立点欺骗检测: 一次非常规的、高额的信用卡消费记录, 可能意味着信用卡盗刷。
- ✓ 罕见事件分析: 在工业检测中, 一个零件的振动数据突然出现异常峰值, 可能预示着它即将发生故障; 在天文学中, 一个突然出现然后又消失的亮点, 可能是一次超新星爆发; 在网络安全中, 一个IP地址在深夜试图上万次登录服务器, 可能是一次黑客攻击。




数据挖掘功能(4)

- 孤立点(Outlier, 离群点or异常值)分析

- 孤立点: 一个数据对象, 它与数据的一般行为不一致
- 孤立点可以被视为例外, 但对于欺骗检测和罕见事件分析, 它是相当有用的

- × 视为需要处理的“噪声”(Noise)

- × 在分析公司员工年薪时, CEO的千万年薪作为一个孤立点, 会大幅拉高平均薪资, 使得这个“平均薪资”指标失去对普通员工的参考意义。
- × 在训练一个预测房价的模型时, 几个标价明显错误的极端房源 (如1元豪宅或10亿的公寓) 会严重干扰模型学习真正的价格规律。




数据挖掘功能(4)

- 趋势和演变分析

- 趋势和偏离： 回归分析（线性趋势、非线性趋势）

- ✓ 举例：分析过去10年的全球年平均气温数据，发现一条向上的直线趋势，这证明了全球变暖；

- ✓ 举例：分析一家初创公司过去5年的用户数量，拟合出一条指数增长曲线




数据挖掘功能(4)

- 趋势和演变分析

- 序列模式挖掘、周期性分析

- ✓ 举例：first buy digital camera, then buy large SD memory cards

- ✓ 举例：外卖订单在每天午餐和晚餐时间达到高峰；冰淇淋销量每年夏季达到高峰。




数据挖掘功能(4)

- 趋势和演变分析

- 基于相似的分析

- ✓ Approximate and consecutive motifs
- ✓ Motifs: 在一段长时间序列中, 彼此之间非常相似的一对或多对子序列。它们代表了数据中重复出现的典型模式。
- ✓ 举例: 心电图分析, 在心电图信号中寻找“正常心跳”的模式(一个Motif)。一旦发现一个与正常模式不相似的心跳, 可能就是心律失常的征兆。



数据挖掘功能(5) -Structure and Network Analysis

- **Graph mining**
 - **Finding frequent subgraphs (e.g., chemical compounds), trees (XML), substructures (web fragments)**
- **Information network analysis**
 - **Social networks: actors (objects, nodes) and relationships (edges)**
 - **e.g., author networks in CS, terrorist networks**
 - **Multiple heterogeneous networks**
 - **A person could be multiple information networks: friends, family, classmates, ...**
 - **Links carry a lot of semantic information: Link mining**
- **Web mining**
 - **Web is a big information network: from PageRank to Google**
 - **Analysis of Web information networks**
 - **Web community discovery, opinion mining, usage mining**


Top-10 Most Popular DM Algorithms: 18 Identified Candidates (I)

■ Classification

- #1. C4.5: Quinlan, J. R. C4.5: Programs for Machine Learning. Morgan Kaufmann., 1993.
- #2. CART: L. Breiman, J. Friedman, R. Olshen, and C. Stone. Classification and Regression Trees. Wadsworth, 1984.
- #3. K Nearest Neighbours (kNN): Hastie, T. and Tibshirani, R. 1996. Discriminant Adaptive Nearest Neighbor Classification. TPAMI. 18(6)
- #4. Naive Bayes Hand, D.J., Yu, K., 2001. Idiot's Bayes: Not So Stupid After All? Internat. Statist. Rev. 69, 385-398.

■ Statistical Learning

- #5. SVM: Vapnik, V. N. 1995. The Nature of Statistical Learning Theory. Springer-Verlag.
- #6. EM: McLachlan, G. and Peel, D. (2000). Finite Mixture Models. J. Wiley, New York. Association Analysis
- #7. Apriori: Rakesh Agrawal and Ramakrishnan Srikant. Fast Algorithms for Mining Association Rules. In VLDB '94.
- #8. FP-Tree: Han, J., Pei, J., and Yin, Y. 2000. Mining frequent patterns without candidate generation. In SIGMOD '00.



The 18 Identified Candidates (II)

■ **Link Mining**


- **#9. PageRank: Brin, S. and Page, L. 1998. The anatomy of a large-scale hypertextual Web search engine. In WWW-7, 1998.**
- **#10. HITS: Kleinberg, J. M. 1998. Authoritative sources in a hyperlinked environment. SODA, 1998.**

■ **Clustering**

- **#11. K-Means: MacQueen, J. B., Some methods for classification and analysis of multivariate observations, in Proc. 5th Berkeley Symp. Mathematical Statistics and Probability, 1967.**
- **#12. BIRCH: Zhang, T., Ramakrishnan, R., and Livny, M. 1996. BIRCH: an efficient data clustering method for very large databases. In SIGMOD '96.**


■ **Bagging and Boosting**

- **#13. AdaBoost: Freund, Y. and Schapire, R. E. 1997. A decision-theoretic generalization of on-line learning and an application to boosting. J. Comput. Syst. Sci. 55, 1 (Aug. 1997), 119-139.**




The 18 Identified Candidates (III)

- **Sequential Patterns**
 - #14. GSP: Srikant, R. and Agrawal, R. 1996. Mining Sequential Patterns: Generalizations and Performance Improvements. 5th International Conference on Extending Database Technology, 1996.
 - #15. PrefixSpan: J. Pei, J. Han, B. Mortazavi-Asl, H. Pinto, Q. Chen, U. Dayal and M-C. Hsu. PrefixSpan: Mining Sequential Patterns Efficiently by Prefix-Projected Pattern Growth. In ICDE '01.
- **Integrated Mining**
 - #16. CBA: Liu, B., Hsu, W. and Ma, Y. M. Integrating classification and association rule mining. KDD-98.
- **Rough Sets**
 - #17. Finding reduct: Zdzislaw Pawlak, Rough Sets: Theoretical Aspects of Reasoning about Data, Kluwer Academic Publishers, Norwell, MA, 1992
- **Graph Mining**
 - #18. gSpan: Yan, X. and Han, J. 2002. gSpan: Graph-Based Substructure Pattern Mining. In ICDM '02.



挖掘出的所有模式都是有趣的吗?


- 一个数据挖掘系统/查询可以挖掘出数以千计的模式, 并非所有的模式都是有趣的
 - 建议的方法: 以人为中心, 基于查询的, 聚焦的挖掘
- 兴趣度度量 : 一个模式是 **有趣的** 如果它是 易于被人理解的, 在某种程度上在新的或测试数据上是有效的, 潜在有用的, 新颖的, 或验证了用户希望证实的某种假设
- 客观与主观的兴趣度度量 :
 - 客观: 基于模式的统计和结构, 例如, 支持度, 置信度, 等.
 - 主观: 基于用户对数据的确信, 例如, 出乎意料, 新颖性, 可行动性(actionability), 等.




能够只发现有趣的模式吗?

- 发现所有有趣的模式: 完全性
 - 数据挖掘系统能够发现所有有趣的模式吗?
 - 关联 vs. 分类 vs. 聚类
- 仅搜索有趣的模式: 优化
 - 数据挖掘系统能够仅发现有趣的模式吗?
 - 方法
 - 首先找出所有模式, 然后过滤掉那些不是有趣的
 - 仅产生有趣的模式— 挖掘查询优化


数据挖掘: 多学科交叉





数据挖掘分类

- **一般功能**
 - **描述式数据挖掘——描述数据的一般性质**
 - **预测式数据挖掘——对数据进行推断，做预测**
- **不同的角度,不同的分类**
 - **待挖掘的数据库类型**
 - **待发现的知识类型**
 - **所用的技术类型**
 - **所适合的应用类型**



数据挖掘分类的多维视图

- 待挖掘的数据库

- 关系的, 事务的, 面向对象的, 对象-关系的, 主动的, 空间的, 时间序列的, 文本 的, 多媒体的, 异种的, 遗产的, WWW, 等.

- 所挖掘的知识


- 特征, 区分, 关联, 分类, 聚类, 趋势, 偏离和孤立点分析, 等.
- 多/集成的功能, 和多层次上的挖掘

- 所用技术

- 面向数据库的, 数据仓库 (OLAP), 机器学习, 统计学, 可视化, 神经网络, 等.


- 适合的应用

- 零售, 电讯, 银行, 欺骗分析, DNA 挖掘, 股票市场分析, Web 挖掘, Web日志分析, 等




OLAP挖掘: 数据挖掘与数据仓库的集成

- **OLAP (Online Analytical Processing) 联机分析处理**
- **数据挖掘系统, DBMS, 数据仓库系统的耦合**
 - 不耦合, 松耦合, 半紧密耦合, 紧密耦合
- **联机分析挖掘**
 - 挖掘与 OLAP 技术的集成
- **交互挖掘多层知识**
 - 通过下钻, 上卷, 转轴, 切片, 切块等操作, 在不同的抽象层挖掘知识和 模式的必要性.
- **多种挖掘功能的集成**
 - 特征分类, 先聚类再关联



OLAP挖掘: 数据挖掘与数据仓库的集成


- **OLAP (Online Analytical Processing)** 联机分析处理
 - 一种基于数据仓库的技术，允许分析人员通过多维、多角度的方式快速、交互地观察数据。其核心操作是上卷（**Roll-up**，汇总到更高层次）、下钻（**Drill-down**，查看更细节数据）、切片（**Slice**，固定一个维度值）、切块（**Dice**，选择维度值范围）和旋转（**Pivot**，变换维度方向）。



OLAP挖掘: 数据挖掘与数据仓库的集成


■ 数据挖掘系统, DBMS, 数据仓库系统的耦合

- 不耦合: 数据挖掘系统独立工作, 不使用DBMS或数据仓库的功能。数据从这些系统中导出为平面文件(如CSV), 然后再进行挖掘。缺点: 效率低, 无法利用数据库的优化能力, 数据可能不是最新的。
- 松耦合: 数据挖掘系统使用DBMS或数据仓库作为数据源, 从中提取数据到内存或本地存储中进行挖掘。这是最常见的方式。优点: 比不耦合更高效, 实现了数据共享。
- 半紧密耦合: 数据挖掘系统不仅将DBMS作为数据源, 还将一些中间结果(如频繁项集)存储回数据库中, 并利用数据库的某些功能(如排序、索引)来提升挖掘效率。优点: 性能更好, 实现了部分功能互补。
- 紧密耦合: 数据挖掘功能完全内嵌到DBMS或数据仓库系统中, 成为其一个核心组件。数据挖掘请求被优化成数据库查询或执行计划。优点: 效率最高, 系统高度集成, 但对系统架构设计要求极高。



OLAP挖掘: 数据挖掘与数据仓库的集成


- 交互挖掘多层知识（**OLAP**的核心思想）
 - 必要性：知识是分层次的。高层概念（如“华东地区”）的总结性知识和高层模式，与底层细节（如“上海市某门店”）的具体模式可能完全不同。我们需要在不同粒度上都能发现知识。
 - 如何实现：通过下钻, 上卷, 转轴, 切片, 切块等操作, 在不同的抽象层挖掘知识和 模式的必要性。



OLAP挖掘: 数据挖掘与数据仓库的集成


■ 多种挖掘功能的集成

- 必要性: 一个复杂分析任务通常需要多种数据挖掘技术协同完成, 而不是孤立地使用某一种。
- 举例:
 - ✓ 特征化然后分类: 首先通过特征挖掘 (一种描述性挖掘) 来概括某一类客户的特征 (如 “高价值客户的特点是年收入 > **50**万, 购买过奢侈品”), 然后利用这些特征来帮助构建更好的分类模型, 以识别新的高价值客户。
 - ✓ 先聚类再关联: 首先使用聚类算法将客户分成不同的群组 (如 “年轻家庭”、 “退休人士”), 然后对每个群组单独进行关联规则分析, 发现 “年轻家庭” 群体中 “尿布和啤酒” 的关联性, 而 “退休人士” 群体中则是 “报纸和咖啡” 的关联性。这样得到的规则比在整个客户数据集上挖掘的规则更精确、更有意义。



数据挖掘的主要问题(1)

- 挖掘方法和用户交互
 - 在数据库中挖掘不同类型的知识
 - 在多个抽象层的交互式知识挖掘
 - 结合背景知识
 - 数据挖掘语言和启发式数据挖掘
 - 数据挖掘结果的表示和可视化
 - 处理噪音和不完全数据
 - 模式评估: 兴趣度问题
- 性能和可伸缩性(scalability)
 - 数据挖掘算法的性能和可伸缩性
 - 并行, 分布和增量的挖掘方法




数据挖掘的主要问题(1)

- **挖掘方法和用户交互**

- **在数据库中挖掘不同类型的知识**


- ✓ 数据形式多样（表格、文本、图、序列），用户目标也不同（想分类、聚类、找关联规则等）。没有一种“万能算法”可以解决所有问题。
 - ✓ 数据就像食材，有蔬菜、肉类、海鲜。你想做的菜也不同，有的要炒，有的要炖。因此，我们需要一整套“厨具”（多种挖掘算法）来处理不同类型的“食材”（数据），以做出不同的“菜肴”（知识）。比如，购物数据用关联规则，客户分组用聚类，预测股价用时间序列分析。



数据挖掘的主要问题(1)

- **挖掘方法和用户交互**

- 在多个抽象层的交互式知识挖掘
 - ✓ 知识是分层次的，用户需要动态调整挖掘的粒度。
 - ✓ 分析销售数据，你既想看全国的总销售额（高层抽象），也想下钻到广东省、再到深圳市的数码产品销售额（低层细节）。优秀的挖掘系统应该允许用户这种交互式的、层层深入的分析，而不是只给出一个扁平的结果。




数据挖掘的主要问题(1)

- 挖掘方法和用户交互

- 结合背景知识

- ✓ 如何将人类已有的领域知识融入自动化的挖掘过程？
 - ✓ 如果我们知道‘元旦、中国年促销会对销量产生巨大影响’这个背景知识，在挖掘12/1/2月销售规则时，算法就应该能理解这是一个特殊事件，而不是一个普通的模式。结合背景知识可以引导挖掘方向，避免产生大量无意义的模式，提升挖掘效率和质量。




数据挖掘的主要问题(1)

- 挖掘方法和用户交互

- 数据挖掘语言和启发式数据挖掘

- ✓ 如何让用户（尤其是非程序员）能清晰地表达他们的挖掘需求？
- ✓ 这需要一种像SQL（Structured Query Language，结构化查询语言）一样标准、易懂的数据挖掘查询语言。同时，由于挖掘过程计算复杂，需要一些启发式规则（经验法则）来高效地搜索可能的模式，避免像无头苍蝇一样在巨大的搜索空间里乱撞。




数据挖掘的主要问题(1)

- 挖掘方法和用户交互

- 数据挖掘结果的表示和可视化

- ✓ 如何让机器挖掘出的模式被人轻松理解？
 - ✓ 不能直接把一堆数字和规则扔给决策者。必须用图表、决策树、知识图谱、热力图等直观的方式将结果可视化。
‘一图胜千言’，好的可视化是数据挖掘价值最终呈现的关键。




数据挖掘的主要问题(1)

- 挖掘方法和用户交互

- 处理噪音和不完全数据

- ✓ 现实世界的的数据是复杂的，包含错误（噪音）、缺失值和不一致。
 - ✓ ‘垃圾进，垃圾出’。如果数据中年龄有‘-5岁’（噪音），或者很多人的收入字段是空的（不完全），这会严重干扰挖掘结果。因此，数据预处理（清洗、去噪、填充缺失值）是挖掘前不可或缺的一步，通常占整个项目**70-80%**的时间。




数据挖掘的主要问题(1)

- 挖掘方法和用户交互


- 兴趣度问题

- ✓ 算法可能找出成千上万个模式，如何自动判断哪些是有趣、有用的？
 - ✓ 要用客观指标（支持度、置信度）和主观指标（新颖性、可行动性）来过滤掉那些显而易见或毫无用处的模式，只把‘金子’呈现给用户。



数据挖掘的主要问题(1)

- 性能和可伸缩性(scalability)
 - 数据挖掘算法的性能和可伸缩性
 - ✓ 当数据量从GB增长到TB、PB级别时，算法还能正常工作吗？
 - ✓ 一个在小样本数据上表现良好的算法，在真实的海量数据面前可能会慢到无法接受。可伸缩性衡量的的是一个算法处理不断增长的数据规模的能力。这是评估数据挖掘算法是否可用的硬性指标。




数据挖掘的主要问题(1)

- 性能和可伸缩性(scalability)


- 并行分布和增量的挖掘方法

- ✓ 并行挖掘： 让一台计算机的多个**CPU**核心同时工作来加速计算。好比让一个小组的几个人一起分工完成一个大项目。
- ✓ 分布式挖掘： 当一台机器扛不住时，用多台计算机（集群）协同工作。这需要将数据和计算任务拆分。好比让多个分公司 **across the country** 共同处理一项全国性任务。
- ✓ 增量挖掘： 数据是不断增长的。不需要每次都从头重新挖掘全部数据，而是只对新增的数据进行挖掘，并将其结果与旧模型融合。这极大地节约了计算资源。好比做工作总结，不需要把过去十年的事重新捋一遍，只需要在上个月总结的基础上加上这个月的新内容即可。




数据挖掘的主要问题(2)

- 数据类型的多样性问题
 - 处理关系的和复杂类型的数据
 - 从异种数据库和全球信息系统 (WWW)挖掘信息
- 应用和社会效果问题
 - 发现知识的应用
 - 特定领域的数据挖掘工具（生物信息学、金融风控、精准营销）
 - 智能查询回答（进行有推理和深度问答）
 - 过程控制和决策制定（例如，银行系统实时用风控模型评估每一笔交易，自动拦截可疑交易）
 - 发现知识与已有知识的集成: 知识融合问题
 - 数据安全, 完整和私有的保护




小结

- **数据挖掘: 从大量数据中发现有趣的模式**
- **数据库技术的自然进化, 具有巨大需求和广泛应用**
- **KDD 过程包括数据清理, 数据集成, 数据选择, 变换, 数据挖掘, 模式评估, 和知识表示**
- **挖掘可以在各种数据存储上进行**
- **数据挖掘功能: 特征, 区分, 关联, 分类, 聚类, 孤立点 和趋势分析, 等.**
- **数据挖掘系统的分类**
- **数据挖掘的主要问题**



参考文献

- U. M. Fayyad, G. Piatetsky-Shapiro, P. Smyth, and R. Uthurusamy. **Advances in Knowledge Discovery and Data Mining**. AAAI/MIT Press, 1996.
- J. Han and M. Kamber. **Data Mining: Concepts and Techniques**. Morgan Kaufmann, 2000.
- T. Imielinski and H. Mannila. A database perspective on knowledge discovery. **Communications of ACM**, 39:58-64, 1996.
- G. Piatetsky-Shapiro, U. Fayyad, and P. Smith. From data mining to knowledge discovery: An overview. In U.M. Fayyad, et al. (eds.), **Advances in Knowledge Discovery and Data Mining**, 1-35. AAAI/MIT Press, 1996.
- G. Piatetsky-Shapiro and W. J. Frawley. **Knowledge Discovery in Databases**. AAAI/MIT Press, 1991.



谢谢大家!

