


课程回顾

- **数据挖掘: 从大量数据中发现有趣的模式**
- **数据库技术的自然进化, 具有巨大需求和广泛应用**
- **KDD 过程包括数据清理, 数据集成, 数据选择, 变换, 数据挖掘, 模式评估, 和知识表示**
- **挖掘可以在各种数据存储上进行**
- **数据挖掘功能: 特征, 区分, 关联, 分类, 聚类, 孤立点 和趋势分析, 等.**
- **数据挖掘系统的分类**
- **数据挖掘的主要问题**




第2章：认识数据

数据对象和属性类型

数据的基本统计描述

数据可视化

度量数据的相似性和相异性



数据对象Data Objects

数据集由数据对象组成。

一个数据对象代表一个实体(entity)。

销售数据库: 顾客, 商品, 销售


医疗数据库: 患者

大学数据库: 学生、教授、课程

数据对象又称为样本 (sample)、实例 (instance)、数据点、(data point)、观测值 (observation) 或对象 (object)。

数据对象用属性(attribute)描述。


数据行对应数据对象; 列对应属性。



数据对象Data Objects

Item	Color	Date	Amount
Shorts	red	1-Jan-2002	\$20.00
Flip flops	black	1-Jan-2002	\$10.00
Hat	red	4-Jan-2015	\$12.00
Flip flops	gray	4-Jan-2015	\$10.00
Flip flops	black	5-Jan-2015	\$10.00
T-shirt	blue	8-Jan-2015	\$15.00
Hoodie	blue	9-Jan-2015	\$25.00
T-shirt	gray	10-Jan-2015	\$15.00
Shorts	khaki	23-Jan-2015	\$20.00
Flip flops	gray	23-Jan-2015	\$10.00
T-shirt	khaki	24-Jan-2015	\$15.00
T-shirt	blue	27-Jan-2015	\$15.00

数据行对应数据对象; 列对应属性。



属性Attributes

属性(attribute)是一个数据字段，表示数据对象的一个特征。

如：customer_ID, name, address

类型：

标称属性(nominal)：只代表类别、代码或状态，没有顺序和排名关系


二元属性(binary)：只有两个可能状态的特殊标称属性

序数属性(ordinal)：其值具有有意义的顺序或排名，相邻值之间的差异是没有意义的

数值属性(numeric)：可度量的数量，用整数或实数表示

区间标度属性(interval-scaled)：

比率标度属性(ratio-scaled)：



属性类型Attribute Types

标称属性(nominal attribute)

其值是一些符号或者事物的名称。

头发颜色={黑色, 棕色, 灰色, 白色}

二元属性(binary attribute)

是一种标称属性, 只有两个状态: 0或1。


对称的(symmetric): 两种状态具有同等价值, 携带相同权重。

如: 性别

非对称的(asymmetric): 其状态的结果不是同样重要。

如: 艾滋病毒的阳性和阴性结果。

对重要的结果用1编码, 另一个用0编码。



序数属性(ordinal attribute)


其可能的值之间具有有意义的序或者秩评定(ranking), 但是相继值之间的差是未知的。

成绩={优, 良, 中, 差}

其中心趋势可以用它的众数和中位数表示, 但不能定义均值。

注意

标称、二元和序数属性都是定性的, 即只描述对象的特征, 不给出实际的大小。



数值属性(numeric attribute)

区间标度(interval-scaled)属性

使用相等的单位尺度度量。

值有序，可以评估值之间的差，不能评估倍数。

没有绝对的零点。


如:摄氏温度，华氏温度

比率标度(ratio-scaled)属性

具有固定零点的数值属性。

值有序，可以评估值之间的差，也可以说一个值是另一个的倍数。

如：开式温温标(K)，重量，高度，速度



离散属性(discrete Attribute)

具有有限或者无限可数个值。


如： 邮编、省份数目具有有限个值， `customer_Id`是无限可数的。

可以用或者不用整数表示。

连续属性(Continuous Attribute)

属性值为实数。

一般用浮点变量表示。




第二章：认识数据

数据对象和属性类型

数据的基本统计描述

数据可视化

度量数据的相似性和相异性



数据的基本统计描述

目的

更好地识别数据的性质，把握数据全貌：中心趋势度量，数据散布

中心趋势度量(measures of central tendency)


均值、中位数、众数、中列数

数据的散布(dispersion of the data)

极差、四分位数极差、五数概括、盒图

数据可视化(graphic displays of basic statistical descriptions)

分位数图、分位数-分位数图、直方图、散点图



中心趋势度量

均值 (mean)

加权算术平均：每*i*个*x_i*与一个权重*w_i*相关联

截尾均值：丢弃高低端极值

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n x_i$$

中位数 (median)

有序数值的中间值

数据集的中位数可以通过插值(interpolation)估算

$$\bar{X} = \frac{\sum_{i=1}^n W_i X_i}{\sum_{i=1}^n W_i}$$

$$median = L_1 + \left(\frac{N / 2 - (\sum freq)_1}{freq_{median}} \right) width$$

L₁: 中位数区间下界 **N**: 数据集中值的个数

($\sum freq$)₁ 所有区间频率、 **$freq_{median}$** 中位数区间的频率

width: 中位数区间的宽度

习题

设给定的数据集已经分组到区间，这些区间和对应频率如图。

计算该数据的近似中位数

$$median = L_1 + \left(\frac{N/2 - (\sum freq)_1}{freq_{median}} \right) width$$

■ 确定中位数所在组

$$(\sum freq)_1 / 2 = 3194 / 2 = 1597$$


$$950 < 1597 < 950 + 1500$$

因此中位数在21~50组

■ 计算中位数

$$median = 21 + \frac{3194 / 2 - 950}{1500} \times 29 = 33.508 \approx 34$$

age	frequency
1 ~ 5	200
6 ~ 15	450
16 ~ 20	300
21 ~ 50	1500
51 ~ 80	700
81 ~ 110	44



众数(mode)

数据集中出现频率最高的值

最高频率对应多个峰值，分为单峰的(unimodal), 双峰的(bimodal),
三峰的(trimodal)

$$mean - mode = 3 \times (mean - median)$$


<i>age</i>	<i>frequency</i>
1-5	200
6-15	450
16-20	300
21-50	1500
51-80	700
81-110	44

中列数(midrange)


最大数和最小数的平均值

对称数据和非对称数据


对称、正倾斜、负倾斜数据的中位数、均值和众数




a) 对称数据



b) 正倾斜数据



c) 负倾斜数据



数据统计常识

Quartiles, outliers and boxplots

四分位数 Quartiles: Q_1 (25th percentile), Q_3 (75th percentile)

四位分数极差 Inter-quartile range: $IQR = Q_3 - Q_1$

五数概括 Five number summary: min, Q_1 , median, Q_3 , max

盒图 Boxplot: 分布直观表示, 体现五数概括

离群点 Outlier: 第三个四分位数之上或者第一个四分位数之下至少 $1.5 \times IQR$ 的值

Variance and standard deviation (sample: s, population: σ)

方差 Variance (衡量每个数据点与平均值之间差异的平方的平均数):

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^n (x_i - \mu)^2 = \frac{1}{N} \sum_{i=1}^n x_i^2 - \mu^2$$

标准差 Standard deviation (方差的平方根, 变回原单位)

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n-1} \left[\sum_{i=1}^n x_i^2 - \frac{1}{n} \left(\sum_{i=1}^n x_i \right)^2 \right]$$

盒图

五数概括

Minimum, Q1, Median, Q3, Maximum



盒图


盒的端点在四分位数上，使得盒长度为四分位数极差

IQR


中位数用盒内线标记


盒外线延伸到最小和最大的观测值





3-D盒图





基本统计图

盒图 Boxplot: 五数概括

直方图 Histogram: x-axis 数值大小, y-axis 频率

分位数图 Quantile plot: 观测单变量数据分布, x_1 最小 x_n 最大

分位数-分位数图 Quantile-quantile (q-q) plot: 两个观测集,
观察一个分布到另一个分布是否漂移


散点图 Scatter plot: 每个值视作一个坐标对, 作为一个点画
在平面上

分位数图

显示给定属性所有数据

绘制分位数信息

增序排列，每个观测值 x_i 与一个百分数 f_i 配对，百分比0.5对应中位数，0.75对应Q3





分位数-分位数图

对着另一个对应的分位数，绘制一个单变量分布的分位数


使得用户可以观测从一个分布到另一个分布


X，Y轴分别代表不同的观测集，存在两个观测集的值的不一致时，不是所有的值都被表示





确定两个数值变量之间看上去是否存在联系
观察双变量数据的有用的方法






第二章：认识数据

数据对象和属性类型

数据的基本统计描述

数据可视化

度量数据的相似性和相异性



数据可视化

数据可视化意义

通过将数据映射在图元 (graphical primitives) 上来表示数据, 便于深刻理解数据信息

便于对大型数据集进行定性描述 (qualitative overview)

便于搜索数据间的模式 (patterns) , 倾向 (trends) , 结构 (structure) , 不规则性 (anomalies) 与联系性 (relationships)

为进一步的定量分析找到合适的区间与变量

数据可视化的技术:


基于像素

几何投影

基于图符


层次可视化

可视化复杂对象与关系




基于像素可视化技术


对于一个 m 维的数据集，在屏幕上创建 m 个窗口，每个窗口代表一个维度记录的 m 个维值映射到这些窗口对应位置上的 m 个像素
像素的颜色反映相对应的值（corresponding values）




(a) Income




(b) Credit Limit



(c) transaction volume




(d) age




圆弓分割技术


圆弓分割是一种节约空间且简明扼要展示多维间关系的方法



(a) 在圆弓内表示一个数据记录



(b) 在圆弓内安排像素



几何投影可视化


基于像素：对理解多维空间数据分布帮助不大
将数据几何化，帮助用户发现多维数据在高维空间上的投影
技术

- 直接投影

- 散点图或散点图矩阵


- 平行坐标

直接投影




Ribbons with Twists Based on Vorticity

散点图矩阵




Used by permission of M. Ward, Worcester Polytechnic Institute


Matrix of scatterplots (x-y-diagrams) of the k-dim. data




平行坐标


绘制 n 个等距离，相互平行的轴，每个代表一个维
数据记录用折线表示，与每个轴在对应相应维值的点上相交





平行坐标






基于图符可视化技术

将数据值可视化为有不同特征的图符
代表技术


切尔诺夫脸
人物线条画




切尔诺夫图

用二维的脸表示 18 维的多维数据（赫尔曼·切尔诺夫）

切尔诺夫脸利用脸的眼耳口鼻等要素的不同形状，大小，位置和方向代表维的值。利用人的思维能力，识别面部特征的微小差异来理解许多面部特征，有助于数据的规律性和不规则性的可视化。




人物线条画



X和Y轴映射两个维

用五段人物线条画表示
其他维



层次可视化技术

把所有维划分成子集（子空间），子空间按层次可视化

Methods


世界中的世界
树图




对六维数据集 $(F, X_1, \dots, X_5)$ 可视化

把 X_3, X_4, X_5 作为选定值，例如 (c_3, c_4, c_5) ，对另外三维可视化，内世界的点位于外世界 (c_3, c_4, c_5) 处，外世界是另一个三维图






把层次数据显示成嵌套矩形的集合




Schneiderman@UMD: Tree-Map of a File System



Schneiderman@UMD: Tree-Map to support large data sets of a million items

- 除了文本数据，还有用于可视化社交网络关系的技术






第二章：认识数据

数据对象和属性类型

数据的基本统计描述

数据可视化

度量数据的相似性和相异性



度量数据的相似性和相异性

相似性(Similarity)

两个对象相似程度的数量表示

数值越高表明相似性越大

通常取值范围为[0,1]

相异性(Dissimilarity)(例如距离)

两个对象不相似程度的数量表示

数值越低表明相似性越大

相异性的最小值通常为0

相异性的最大值(上限)是不同的

邻近性(Proximity):相似性和相异性都称为邻近性

数据矩阵与相异性矩阵

数据矩阵-对象-属性结构

行-对象: n个对象

列-属性: p个属性

二模矩阵(Two modes)

$$\begin{bmatrix} x_{11} & \cdots & x_{1f} & \cdots & x_{1p} \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ x_{i1} & \cdots & x_{if} & \cdots & x_{ip} \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ x_{n1} & \cdots & x_{nf} & \cdots & x_{np} \end{bmatrix}$$

相异性矩阵

(Dissimilarity matrix)


n个对象两两之间的邻近度

对称矩阵

单模(Single mode)

$$\begin{bmatrix} 0 & & & & \\ d(2,1) & 0 & & & \\ d(3,1) & d(3,2) & 0 & & \\ \vdots & \vdots & \vdots & & \\ d(n,1) & d(n,2) & \cdots & \cdots & 0 \end{bmatrix}$$

其中d(i,j)表示对象i与对象j之间的相异性



标称属性的邻近性度量

标称属性(Nominal Attributes):可以取两个或多个状态

例如：颜色属性，可以取值为：红、黄、蓝、绿

两个对象*i*和*j*之间的相异性使用不匹配率来表示

$$d(i, j) = \frac{p - m}{p}$$

m: 对象匹配数目, *p*: 对象的属性总数

表2.2 包含混合类型属性的样本数据表

对象标识符	Test-1 (标称的)	Test-2 (序数的)	Test-3 (数值的)
1	A	优秀	45
2	B	一般	22
3	C	好	64
4	A	优秀	28

只对标称属性test1计算相异性，
因此 $p=1$ ，当对象 i 和 j 匹配时，
 $d(i, j)=0$ ，当对象不同时 $d(i, j)=1$

$$d(i, j) = \frac{p-m}{p}$$

$$\begin{bmatrix} 0 & & & \\ 1 & 0 & & \\ 1 & 1 & 0 & \\ 0 & 1 & 1 & 0 \end{bmatrix}$$

二元属性的邻近性度量

对象*i*和对象*j*的频数表


		Object <i>j</i>		
		1	0	sum
Object <i>i</i>	1	<i>q</i>	<i>r</i>	<i>q</i> + <i>r</i>
	0	<i>s</i>	<i>t</i>	<i>s</i> + <i>t</i>
	sum	<i>q</i> + <i>s</i>	<i>r</i> + <i>t</i>	<i>p</i>

对称的二元相异性

$$d(i, j) = \frac{r + s}{q + r + s + t}$$

非对称的二元相异性(*t*被认为不重要, 例如: 病理化验呈阴性)

$$d(i, j) = \frac{r + s}{q + r + s}$$



二元属性的邻近性度量

Jaccard系数(非对称的二元相似性):

$$\text{sim}_{Jaccard}(i, j) = \frac{q}{q + r + s}$$

Note: Jaccard系数与“一致性”计算相同:

$$\text{coherence}(i, j) = \frac{\text{sup}(i, j)}{\text{sup}(i) + \text{sup}(j) - \text{sup}(i, j)} = \frac{q}{(q + r) + (q + s) - q}$$

二元属性的相异性（例子）

Name	Gender	Fever	Cough	Test-1	Test-2	Test-3	Test-4
Jack	M	Y	N	P	N	N	N
Mary	F	Y	N	P	N	P	N
Jim	M	Y	P	N	N	N	N

Name(姓名)和Gender(性别)是对称属性

其他属性是非对称二元属性，假设只针对非对称二元属性进行相异性计算


$$d(i, j) = \frac{r + s}{q + r + s}$$

值 Y 和 P 是 1, 值 N 是 0

$$d(jack, mary) = \frac{0 + 1}{2 + 0 + 1} = 0.33$$

$$d(jack, jim) = \frac{1 + 1}{1 + 1 + 1} = 0.67$$

$$d(jim, mary) = \frac{1 + 2}{1 + 1 + 2} = 0.75$$



数值属性的相异性: 闵可夫斯基距离

闵可夫斯基距离(Minkowski Distance): 计算距离的通用的公式:

$$d(i, j) = \sqrt[h]{|x_{i1} - x_{j1}|^h + |x_{i2} - x_{j2}|^h + \cdots + |x_{ip} - x_{jp}|^h}$$

$i = (x_{i1}, x_{i2}, \dots, x_{ip})$ 和 $j = (x_{j1}, x_{j2}, \dots, x_{jp})$ 是 p 维数据对象


距离需要满足的性质:

非负性: $d(i, j) > 0$ if $i \neq j$, and $d(i, i) = 0$

对称性: $d(i, j) = d(j, i)$

三角不等式: $d(i, j) \leq d(i, k) + d(k, j)$

满足上述条件的测度称为度量(metric)



闵可夫斯基距离的特殊表现形式

$$d(i, j) = \sqrt[h]{|x_{i1} - x_{j1}|^h + |x_{i2} - x_{j2}|^h + \cdots + |x_{ip} - x_{jp}|^h}$$

$h = 1$: 曼哈顿距离(或城市块距离 **Manhattan distance**)

$$d(i, j) = |x_{i1} - x_{j1}| + |x_{i2} - x_{j2}| + \cdots + |x_{ip} - x_{jp}|$$

$h = 2$: 欧几里德距离(用的最多的)

$$d(i, j) = \sqrt{(|x_{i1} - x_{j1}|^2 + |x_{i2} - x_{j2}|^2 + \cdots + |x_{ip} - x_{jp}|^2)}$$

$h \rightarrow \infty$: 上确界距离


找出两个对象的属性中最大的距离

$$d(i, j) = \lim_{h \rightarrow \infty} \left(\sum_{f=1}^p |x_{if} - x_{jf}|^h \right)^{\frac{1}{h}} = \max_f |x_{if} - x_{jf}|$$

例：闵可夫斯基距离 Manhattan (L_1)

point	attribute 1	attribute 2
x1	1	2
x2	3	5
x3	2	0
x4	4	5

相异性矩阵




L	x1	x2	x3	x4
x1	0			
x2	5	0		
x3	3	6	0	
x4	6	1	7	0

Euclidean (L_2)

L2	x1	x2	x3	x4
x1	0			
x2	3.61	0		
x3	2.24	5.1	0	
x4	4.24	1	5.39	0

Supremum

L_∞	x1	x2	x3	x4
x1	0			
x2	3	0		
x3	2	5	0	
x4	3	1	5	0



序数属性的邻近性度量

序数属性：值之间是有意义的序或者排位

假设f为n个对象的一组序数属性之一，第i个对象的f值为 x_{if} ，

属性f有 M_f 个有序状态，表示排位 $r_{if} \in \{1, \dots, M_f\}$

用下面公式实现数据规格化

$$Z_{if} = \frac{r_{if} - 1}{M_f - 1}$$

相异性计算可以用数值属性的距离度量来计算





表2.2

对象标识符	Test-1 (标称的)	Test-2 (序数的)	Test-3 (数值的)
1	A	1.0	45
2	B	0.0	22
3	C	0.5	64
4	A	1.0	28

- $M_f=3$ ，把test2的每个值替换为它的排位，则4个对象将分别被赋值为3、1、2、3
- 实现规格化：将1映射为0.0，2映射为0.5，3映射为1.0
- 使用欧几里德距离求相异性矩阵

$$\begin{bmatrix} 0 & & & \\ 1.0 & 0 & & \\ 0.5 & 0.5 & 0 & \\ 0 & 1.0 & 0.5 & 0 \end{bmatrix}$$



混合类型属性的相异性


数据库中可能包含各种属性类型

标称的、对称二元的、非对称二元的、数值的或序数的

分别对每类数据进行数据挖掘分析，可能产生的结果不兼容
所有类型一起处理，公式为：

$$d(i, j) = \frac{\sum_{f=1}^p \delta_{ij}^{(f)} d_{ij}^{(f)}}{\sum_{f=1}^p \delta_{ij}^{(f)}}$$

如果 x_{if} 或者 x_{jf} 缺失，即对象 i 或者对象 j 没有属性 f 的度量值，或者 $x_{if} = x_{jf} = 0$ ，并且 f 是非对称的二元属性，则 $\delta_{ij}^{(f)} = 0$
其他情况指示符 $\delta_{ij}^{(f)} = 1$



混合类型属性的相异性

$$d(i, j) = \frac{\sum_{f=1}^p \delta_{ij}^{(f)} d_{ij}^{(f)}}{\sum_{f=1}^p \delta_{ij}^{(f)}}$$

若 f 是标称或二元的:

如果 $x_{if} = x_{jf}$, 则 $d_{ij}^{(f)} = 0$, 否则 $d_{ij}^{(f)} = 1$

若 f 是数值的:

$$d_{if}^{(f)} = \frac{|x_{if} - x_{jf}|}{\max_h x_{hf} - \min_h x_{hf}}$$

其中 h 遍取属性 f 的所有非缺失对象

若 f 是序数的:

计算 r_{if} 和 z_{if} , 并将 z_{if} 作为数值属性对待。

$$z_{if} = \frac{r_{if} - 1}{M_f - 1}$$




表2.2

对象标识符	Test-1 (标称的)	Test-2 (序数的)	Test-3 (数值的)
1	A	优秀	45
2	B	一般	22
3	C	好	64
4	A	优秀	28

对于数值属性Test3，计算相异性并规格化：
max=64，min=22


$$d_{if}^{(f)} = \frac{|X_{if} - X_{jf}|}{\max_h X_{hf} - \min_h X_{hf}}$$

$$\begin{bmatrix} 0 & & & \\ 0.55 & 0 & & \\ 0.45 & 1.00 & 0 & \\ 0.40 & 0.14 & 0.86 & 0 \end{bmatrix}$$

Test1	Test2	Test3
0	0	0
1 0	1.0 0	0.55 0
1 1 0	0.5 0.5 0	0.45 1.00 0
0 1 1 0	0 1.0 0.5 0	0.40 0.14 0.86 0

对象标识符	Test-1 (标称的)	Test-2 (序数的)	Test-3 (数值的)
1	A	优秀	45
2	B	一般	22
3	C	好	64
4	A	优秀	28

对象1和对象4的最相似，对象1和对象2最不相似。



余弦相似性


对文档中的关键词或短语的频度表：

<i>Document</i>	<i>team coach</i>		<i>hockey</i>	<i>baseball</i>	<i>soccer</i>	<i>penalty</i>	<i>score</i>	<i>win</i>	<i>loss</i>	<i>season</i>
Document1	5	0	3	0	2	0	0	2	0	0
Document2	3	0	2	0	1	1	0	1	0	1
Document3	0	7	0	2	1	0	0	3	0	0
Document4	0	1	0	0	1	2	2	0	3	0

词频向量通常很长，稀疏的，使用余弦相似性作为度量：

$$\text{sim}(\mathbf{x}, \mathbf{y}) = (\mathbf{x} \bullet \mathbf{y}) / \|\mathbf{x}\| \|\mathbf{y}\|,$$

其中： $\bullet$ 表示向量积， $\|\mathbf{x}\|$:向量 $\mathbf{x}$ 的长度



例：余弦相似性

$$\text{sim}(d_1, d_2) = (d_1 \bullet d_2) / \|d_1\| \|d_2\| ,$$

例：求文档1与文档2的相似性

$$d_1 = (5, 0, 3, 0, 2, 0, 0, 2, 0, 0)$$


$$d_2 = (3, 0, 2, 0, 1, 1, 0, 1, 0, 1)$$

$$d_1 \bullet d_2 = 5*3 + 0*0 + 3*2 + 0*0 + 2*1 + 0*1 + 0*1 + 2*1 + 0*0 + 0*1 = 25$$

$$\|d_1\| = (5*5 + 0*0 + 3*3 + 0*0 + 2*2 + 0*0 + 0*0 + 2*2 + 0*0 + 0*0)^{0.5} = (42)^{0.5} = 6.481$$

$$\|d_2\| = (3*3 + 0*0 + 2*2 + 0*0 + 1*1 + 1*1 + 0*0 + 1*1 + 0*0 + 1*1)^{0.5} = 4.12$$

$$\text{sim}(d_1, d_2) = 0.94$$



习题2.6


给定两个被元组(22, 1, 42, 10)和(20, 0, 36, 8)表示的对象。

(a)计算这两个对象之间的欧几里得距离。

$$\begin{aligned} d(i, j) &= \sqrt{(X_{i1} - X_{j1})^2 + (X_{i2} - X_{j2})^2 + \cdots + (X_{in} - X_{jn})^2} \\ &= \sqrt{45} = 6.708 \end{aligned}$$

(b)计算这两个对象之间的曼哈顿距离。

$$\begin{aligned} d(i, j) &= |x_{i1} - x_{j1}| + |x_{i2} - x_{j2}| + \cdots + |x_{ip} - x_{jp}| \\ &= |22 - 20| + |1 - 0| + |42 - 36| + |10 - 8| = 11 \end{aligned}$$



习题2.6

给定两个被元组(22, 1, 42, 10)和(20, 0, 36, 8)表示的对象。


(c)使用 $q=3$, 计算这两个对象之间的闵可夫斯基距离。

$$\begin{aligned} d(i, j) &= \sqrt[3]{(X_{i1} - X_{j1})^3 + (X_{i2} - X_{j2})^3 + \cdots + (X_{in} - X_{jn})^3} \\ &= \sqrt[3]{8 + 1 + 216 + 8} = 6.15 \end{aligned}$$

(d)计算这两个对象之间的上确界距离

$$d(i, j) = \max_f^p |x_{if} - x_{jf}| = 6$$





第3章: 数据预处理

- **为什么预处理数据?**
- **数据清理**
- **数据集成**
- **数据归约**
- **离散化和概念分层产生**
- **小结**



为什么数据预处理?

- **现实世界中的数据是脏的**
 - **不完全**: 缺少属性值, 缺少某些有趣的属性, 或仅包含聚集数据
 - 例, occupation=""
 - **噪音**: 包含错误或孤立点
 - 例, Salary="-10"
 - **不一致**: 编码或名字存在差异
 - 例, Age="42" Birthday="03/07/2010"
 - 例, 以前的等级 "1,2,3", 现在的等级 "A, B, C"
 - 例, 重复记录间的差异




数据为什么脏?

- **不完全数据源于**
 - 数据收集时未包含
 - 数据收集和数据分析时的不同考虑.
 - 人/硬件/软件问题
- **噪音数据源于**
 - 收集
 - 录入
 - 变换
- **不一致数据源于**
 - 不同的数据源
 - 违反函数依赖




为什么数据预处理是重要的?

- **没有高质量的数据, 就没有高质量的数据挖掘结果!**
 - **高质量的决策必然依赖高质量的数据**
 - **例如, 重复或遗漏的数据可能导致不正确或误导的统计.**
 - **数据仓库需要高质量数据的一致集成**



数据质量：一个多维视角

- 一种广泛接受的多角度：
 - 正确性(Accuracy)
 - 完全性(Completeness)
 - 一致性(Consistency)
 - 合时(Timeliness): timely update?
 - 可信性(Believability)
 - 可解释性(Interpretability)
 - 可存取性(Accessibility)




数据预处理的主要任务


- **数据清理**
 - 填充缺失值, 识别/去除离群点, 光滑噪音, 并纠正数据中的不一致
- **数据集成**
 - 多个数据库, 数据立方体, 或文件的集成
- **数据变换**
 - 规范化和聚集
- **数据归约**
 - 得到数据的归约表示, 它小得多, 但产生相同或类似的分析结果: 维度规约、数值规约、数据压缩
- **数据离散化和概念分层**

数据预处理的形式

Data Cleaning




Data Integration




Data Transformation

-2, 32, 100, 59, 48 → -0.02, 0.32, 1.00, 0.59, 0.48


Data Reduction






第3章: 数据预处理

- **为什么预处理数据?**
- **数据清理**
- **数据集成**
- **数据归约**
- **离散化和概念分层产生**
- **小结**




数据清理 Data Cleaning

- 现实世界de数据是脏：很多潜在的不正确的数据，比如，仪器故障，人为或计算机错误，许多传输错误
 - incomplete:缺少属性值, 缺少某些有趣的属性, 或仅包含聚集数据
 - e.g., 职业=“ ” (missing data)
 - noisy:包含错误或孤立点
 - e.g., *Salary*=“-10” (an error)
 - inconsistent:编码或名字存在差异, e.g.,
 - *Age*=“42”, *Birthday*=“03/07/2010”
 - 以前的等级 “1, 2, 3”, 现在等级 “A, B, C”
 - 重复记录间的差异
 - 有意的(e.g.,变相丢失的数据)
 - Jan. 1 as everyone’s birthday?




如何处理缺失数据?

- **忽略元组: 缺少类别标签时常用(假定涉及分类—不是很有效, 当每个属性的缺失百分比变化大时)**
- **手工填写缺失数据: 乏味+费时+不可行?**
- **自动填充**
 - **一个全局常量: e.g., “unknown”, a new class?!**
 - **使用属性均值**
 - **与目标元组同一类的所有样本的属性均值: 更巧妙**
 - **最可能的值: 基于推理的方法, 如贝叶斯公式或决策树**



噪音数据Noisy Data

- **Noise: 被测量的变量的随机误差或方差**
- **不正确的属性值可能由于**
 - **错误的数据收集工具**
 - **数据录入问题 data entry problems**
 - **数据传输问题 data transmission problems**
 - **技术限制 technology limitation**
 - **不一致的命名惯例 inconsistency in naming convention**
- **其他需要数据清理的问题**
 - **重复记录 duplicate records**
 - **数据不完整 incomplete data**
 - **不一致的数据 inconsistent data**




如何处理噪音数据?

- **分箱Binning method:**
 - 排序数据, 分布到等频/等宽的箱/桶中
 - 箱均值光滑、箱中位数光滑、箱边界光滑, etc.
- **聚类Clustering**
 - 检测和去除 离群点/孤立点 outliers
- **计算机和人工检查相结合**
 - 人工检查可疑值 (e.g., deal with possible outliers)
- **回归 Regression**
 - 回归函数拟合数据




分箱：简单的离散化方法

- **等宽度Equal-width (distance) 剖分:**
 - 分成大小相等的n个区间: 均匀网格 uniform grid
 - 若A和B是属性的最低和最高取值, 区间宽度为: $W = (B - A) / N$.
 - 孤立点可能占据重要影响 may dominate presentation
 - 倾斜的数据处理不好.
- **等频剖分 (frequency) /等深equi-depth :**
 - 分成n个区间, 每一个含近似相同数目的样本
 - Good data scaling
 - 类别属性可能会非常棘手.





Binning Methods for Data Smoothing 分箱

- * Sorted data for price (in dollars): 4, 8, 9, 15, 21, 21, 24, 25, 26, 28, 29, 34
- * Partition into (equi-depth) bins:
 - **Bin 1:** 4, 8, 9, 15
 - **Bin 2:** 21, 21, 24, 25
 - **Bin 3:** 26, 28, 29, 34
- * Smoothing by bin means:
 - **Bin 1:** 9, 9, 9, 9
 - **Bin 2:** 23, 23, 23, 23
 - **Bin 3:** 29, 29, 29, 29
- * Smoothing by bin boundaries:
 - **Bin 1:** 4, 4, 4, 15
 - **Bin 2:** 21, 21, 25, 25
 - **Bin 3:** 26, 26, 26, 34





聚类分析






Regression






数据清理作为一个过程

- **数据偏差检测 Data discrepancy detection**
 - 使用元数据(数据性质的知识)(e.g., 领域, 长度范围, 从属, 分布)
 - 检查字段过载 field overloading
 - 检查唯一性规则, 连续性规则, 空值规则
 - 使用商业工具
 - 数据清洗 Data scrubbing: 使用简单的领域知识(e.g., 邮编, 拼写检查) 检查并纠正错误
 - 数据审计 Data auditing: 通过分析数据发现规则和联系发现违规者(孤立点)
- **数据迁移和集成**
 - 数据迁移工具 Data migration tools: 允许指定转换
 - 提取/变换/装入工具 ETL (Extraction/Transformation/Loading) tools: 允许用户通过图形用户界面指定变换
- **整合两个过程**
 - 两个过程迭代和交互执行(e.g., Potter's Wheels)



第3章: 数据预处理

- 为什么预处理数据?
- 数据清理
- **数据集成**
- 数据归约
- 离散化和概念分层产生
- 小结



数据集成

- **数据集成 Data integration:**
 - 合并多个数据源中的数据, 存在一个一致的数据存储中
 - 涉及3个主要问题: 模式集成、冗余数据、冲突数据值
- **模式集成 Schema integration**
 - 例如., A.cust-id $\equiv$? B.cust-#
 - **实体识别问题 Entity identification problem:**
 - 多个数据源的真实世界的实体的识别, e.g., Bill Clinton = William Clinton
 - 集成不同来源的元数据
- **冲突数据值的检测 and 解决**
 - 对真实世界的实体, 其不同来源的属性值可能不同
 - 原因: 不同的表示, 不同尺度, 公制 vs. 英制



数据集成中冗余数据处理

- 冗余数据Redundant data （集成多个数据库时出现）
 - 目标识别：同一个属性在不同的数据库中有不同的名称
 - 衍生数据：一个属性值可由其他表的属性推导出, e.g., 年收入
- 相关分析 *correlation analysis* / 协方差分析 *covariance analysis*
 - 可用于检测冗余数据
- 小心的集成多个来源的数据可以帮助降低和避免结果数据集中的冗余和不一致，提高数据挖掘的速度和质量

相关分析 (数值数据)


- Correlation coefficient (also called **Pearson's product moment coefficient**)
- 相关系数 (皮尔逊相关系数)

$$r_{A,B} = \frac{\sum_{i=1}^n (a_i - \bar{A})(b_i - \bar{B})}{(n-1)\sigma_A \sigma_B} = \frac{\sum_{i=1}^n (a_i b_i) - n\bar{A}\bar{B}}{(n-1)\sigma_A \sigma_B}$$


n 元组个数, $\bar{A}$ 和 $\bar{B}$ 属性A和B上的平均值, σ_A and σ_B 分别为各自标准差, $\sum(a_i b_i)$ is the AB叉积 cross-product之和.

- If $r_{A,B} > 0$, A and B **正相关** (A's values increase as B's). **值越大相关程度越高.**
- $r_{A,B} = 0$: **不相关**; $r_{AB} < 0$: **负相关**

相关性的视觉评价



**Scatter plots
showing the
similarity from
-1 to 1.**



相关 (线形关系)

- 相关测量的是对象间的线性关系
- To compute correlation, we standardize data objects, A and B, and then take their dot product

$$a'_k = (a_k - \text{mean}(A)) / \text{std}(A)$$

$$b'_k = (b_k - \text{mean}(B)) / \text{std}(B)$$

$$\text{correlation}(A, B) = A' \bullet B'$$



协方差Covariance (Numeric Data)

- Covariance is similar to correlation


$$Cov(A, B) = E((A - \bar{A})(B - \bar{B})) = \frac{\sum_{i=1}^n (a_i - \bar{A})(b_i - \bar{B})}{n}$$

Correlation coefficient:

$$r_{A,B} = \frac{Cov(A, B)}{\sigma_A \sigma_B}$$

n元组个数, $\bar{A}$ 和 $\bar{B}$ 属性A和B上的平均值, σ_A and σ_B 分别为各自标准差.

- 正covariance: If $Cov_{A,B} > 0$, 则A和B同时倾向于大于期望值.
- 负covariance: If $Cov_{A,B} < 0$, 则如果A > 其期望值, B is likely to be smaller than its expected value.
- Independence: $Cov_{A,B} = 0$ but the converse is not true:
 - Some pairs of random variables may have a covariance of 0 but are not independent. Only under some additional assumptions (e.g., the data follow multivariate normal distributions) does a covariance of 0 imply independence



Co-Variance: An Example

$$Cov(A, B) = E((A - \bar{A})(B - \bar{B})) = \frac{\sum_{i=1}^n (a_i - \bar{A})(b_i - \bar{B})}{n}$$

- It can be simplified in computation as

$$Cov(A, B) = E(A \cdot B) - \bar{A}\bar{B}$$

- 设两个股票 A 和 B 一周内值如下 (2, 5), (3, 8), (5, 10), (4, 11), (6, 14).
- 问: 如果股票是由同行业趋势的影响, 它们的价格将一起上升或下降?
 - $E(A) = (2 + 3 + 5 + 4 + 6) / 5 = 20/5 = 4$
 - $E(B) = (5 + 8 + 10 + 11 + 14) / 5 = 48/5 = 9.6$
 - $Cov(A, B) = (2 \times 5 + 3 \times 8 + 5 \times 10 + 4 \times 11 + 6 \times 14) / 5 - 4 \times 9.6 = 4$
- Thus, A and B rise together since $Cov(A, B) > 0$.

相关分析 (名义/定类数据Nominal Data)

■ χ^2 (chi-square) test 开方检验

- σ_{ij} 是 (a_i, b_j) 的观测频度 (实际计数)
- e_{ij} 是 (a_i, b_j) 的期望频度
- N 数据元组的个数

$$\chi^2 = \sum_{i=1}^c \sum_{j=1}^r \frac{(\sigma_{ij} - e_{ij})^2}{e_{ij}}$$

		属性 A			
		a_1	a_2	$\vdots$	a_c
属性 B	b_1				
	b_2				
	$\vdots$				
	b_r				

($A=a_i, B=b_j$)

$$e_{ij} = \frac{\text{count}(A = a_i) * \text{count}(B = b_j)}{N}$$

- χ^2 值越大, 相关的可能越大
- 对 χ^2 值贡献最大的项, 其实际值与期望值相差最大的项
- 相关不意味着因果关系

Chi-Square 卡方值计算: 例子


	Play chess	Not play chess	Sum (row)
看小说	250(90)	200(360)	450
不看小说	50(210)	1000(840)	1050
Sum(col.)	300	1200	1500

$$e_{11} = \frac{\text{count(看小说)} * \text{count(下棋)}}{N} = \frac{450 * 300}{1500} = 90$$

- χ^2 (chi-square) 计算(括号中的值为期望计值, 由两个类别的分布数据计算得到)

$$\chi^2 = \frac{(250 - 90)^2}{90} + \frac{(50 - 210)^2}{210} + \frac{(200 - 360)^2}{360} + \frac{(1000 - 840)^2}{840} = 507.93$$

- 结果表明like_fiction 和play_chess 关联



数据变换Data Transformation

- 光滑: 去掉噪音, 技术: 分箱、回归、聚类
 - 聚集Aggregation: 汇总, 数据立方体构造
 - 数据泛化Generalization: 概念分层
 - 规范化Normalization: 按比例缩放到一个具体区间
- } 数据规约
- 最小-最大规范化
 - z-score 规范化
 - 小数定标规范化
- 属性Attribute/特征feature 构造
 - 从给定的属性构造新属性
 - 机器学习中称为: 特征构造

规范化数据的方法

- 最小-最大规范化 min-max normalization

$$v' = \frac{v - \min_A}{\max_A - \min_A} (\text{new_max}_A - \text{new_min}_A) + \text{new_min}_A$$


- 新数据可能“越界”

- z-score normalization
$$v' = \frac{v - \text{均值}_A}{\text{标准差}_A}$$

- normalization by decimal scaling

- 移动属性A的小数点位置(移动位数依赖于属性A的最大值)

$$v' = \frac{v}{10^j} \quad J \text{ 为使得 } \text{Max}(|v'|) < 1 \text{ 的整数中最小的那个}$$



第3章: 数据预处理

- 为什么预处理数据?
- 数据清理
- 数据集成
- 数据归约
- 离散化和概念分层产生
- 小结




数据规约策略

- 在完整数据上的分析/挖掘耗时太长，以至于不现实
- Data reduction 获得数据集的一个规约表示，小很多，接近保持原数据的完整性，使得可得到相同/几乎相同的分析结果
- 数据规约策略如下；
 - 数据立方体聚集：聚集数据立方体结构的数据
 - 维度规约—去除不重要的属性
 - 主成份分析Principal Components Analysis (PCA)
 - 特征子集选择Feature subset selection,
 - 属性产生
 - 数据压缩 Data Compression
 - 基于离散小波变换的数据压缩：图像压缩
 - 数值规约—用某种表示方式替换/估计原数据
 - Regression and Log-Linear Models
 - Histograms, clustering, sampling
 - 离散化和产生概念分层

数据立方体聚集

- 数据立方体存储多维聚集信息
 - 某抽象层上建的数据立方体称为方体(cuboid)
 - 最底层建的方体称为基本方体(base cuboid)
 - 最高层的立方体称为 顶点方体(apex cuboid)
- 每个更高层的抽象将减少数据的规模



年=1999	
年=1998	
年=1997	
季度	销售额
Q1	\$224,000
Q2	\$408,000
Q3	\$350,000
Q4	\$586,000

→


年	销售额
1997	\$1,568,000
1998	\$2,356,000
1999	\$3,594,000

- 使用合适的抽象层上的数据
 - 对数据立方体聚集得到与任务相关的最小立方体





数据压缩 Data Compression

- **字符串压缩**
 - 有丰富的理论和调优的算法
 - 典型的是有损压缩;
 - 但只有有限的操作是可行的
- **音频/视频压缩**
 - 通常有损压缩, 逐步细化
 - 有时小片段的信号可重构, 而不需要重建整个信号
- **时间序列不是音频**
 - 通常短, 随时间缓慢变化
- **维度和数值规约可以被看成是数据压缩的一种形式**



数据压缩





维度规约-特征选择

- **特征选择** Feature selection (i.e., 属性子集选择):
 - 删除不相关/冗余属性, 减少数据集
 - 找出最小属性集, 类别的数据分布尽可能接近 使用全部属性值的原分布
 - 减少了发现的模式数目, 容易理解
- **d个属性, 有 2^d 个可能的属性子集**
- **启发式方法** Heuristic methods (因为指数级的可能性):
 - 局部最优选择, 期望获得全局最优解
 - 逐步向前选择
 - 逐步向后删除 step-wise backward elimination
 - 向前选择和向后删除结合
 - 决策树归纳 decision-tree induction



维度规约-启发式特征选择方法


- 特征独立性假设下，最好的单个属性: 统计显著性检验方法
 - 两样本t-test, 等
- 逐步最好特征选择:
 - 先选出最好的单个属性
 - 下一个最好的特征加进来, ...
- 逐步向后删除:
 - 重复删除最差的特征
- 向前选择和向后删除结合
- 优化分支定界 (Optimal branch and bound)
 - 使用特征删除和回溯
- 中止条件各有不同。

维度规约-决策树规约


最初的属性集合:

{A1, A2, A3, A4, A5, A6}

出现在决策树中的属性构成最后的属性子集



-----> 最后的集合: {A1, A4, A6}





维度规约-属性/特征产生

- Feature Generation 产生新的属性，其可以比原始属性更有效地表示数据的重要信息。
- 三个一般方法：
 - 属性提取 Attribute extraction
 - 特定领域的
 - 映射数据到新空间
 - E.g., 傅立叶变换, wavelet transformation, 流形方法 (manifold approaches)
 - 属性构造
 - 组合特征
 - 数据离散化 Data discretization

主成分分析 (PCA)


- principal component analysis, K-L变换
- 找到一个投影, 其能表示数据的最大变化
- 原始数据投影到一个更小的空间中, 导致维度减少.
 - 发现的协方差矩阵的特征向量, 用这些特征向量定义新的空间







主成分分析 (Steps)

- 给定 p 维空间中的 N 各点, 找到 $k \leq p$ 个正交向量 (*principal components*) 可以很好表示原始数据的
 - 归范化输入数据: 每个属性值位于相同的区间内
 - 计算 k 个标准正交向量, i.e., *principal components*
 - 每个输入的点在这 k 个主成分的线性组合
 - The principal components are sorted in order of decreasing “significance” or strength
 - Since the components are sorted, the size of the data can be reduced by eliminating the *weak components*(i.e., using the strongest principal components, it is possible to reconstruct a good approximation of the original data)
- Works for numeric data only



Principal Component Analysis






回归和对数线性模型

- **线性回归: 数据拟合到一条直线上**
 - **通常使用最小二乘法拟合**
- **多元线性回归**
 - **允许响应变量 Y 表示为多个预测变量的函数**
- **对数线性模型:**
 - **近似离散的多维概率分布**

回归分析

- 研究因变量/响应变量Y(dependent variable/response variable) 对个或多个自变量/解释变量(*independent variable / explanatory variable*)的相依关系的方法的统称

- 参数需要估计以最好的拟合给定的数据
- 绝大多数情况“最好的拟合”是由最小二乘法(*least squares method*)实现, 其他的方法也有





- 用于预测（包括时间序列数据的预测），推断，假设检验和因果关系的建模

线性回归-用于预测

Y: --diameter at breast height(*DBH*) $\leftrightarrow$ X: -- Age

	0	1	2	3	4	5	6	7	8	9	10	11	12
Y	?	1.0	1.0	1.5	6.0	9.0	10.5	11	16.5	9.5	8.0	12.5	12.5
X	34	11	12	15	28	45	52	57	75	81	88	93	97



线性回归(cont.)

- Given x , construct the linear regression model for y against x as:

$$y = \alpha + \beta x + e$$

- Least squares estimation of y given variable x is:

of α and β is $\hat{\alpha} = \bar{y} - \hat{\beta}\bar{x}$ and

$$\hat{\beta} = \frac{s_{xy}}{s_{xx}}, \quad \text{where} \quad s_{xy} = \frac{1}{n-1} \sum_{j=1}^n (x_j - \bar{x})(y_j - \bar{y})$$

is the empirical covariance between x and y ,

$$s_{xx} = \frac{1}{n-1} \sum_{j=1}^n (x_j - \bar{x})^2$$

$$\hat{y} = \bar{y} + \frac{s_{xy}}{s_{yy}} (x - \bar{x}).$$

- ## ■ “5” 样本数目

$$w \quad A_1 \quad A_2 \quad \dots \quad A_k \quad (1)$$

$$\begin{pmatrix} \mathbf{g}_1^T \\ \mathbf{g}_{s_1}^T \\ \vdots \\ \mathbf{g}_{s_k}^T \end{pmatrix} = \begin{pmatrix} \alpha & \mathbf{w}^T \\ \mathbf{b} & A \end{pmatrix}$$

$$= \begin{pmatrix} \alpha & \mathbf{w}_1 & \mathbf{w}_2 & \mathbf{w}_3 & \mathbf{w}_4 & \mathbf{w}_5 \\ \mathbf{b}_1 & A_{1,1} & A_{1,2} & A_{1,3} & A_{1,4} & A_{1,5} \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ \mathbf{b}_k & A_{k,1} & A_{k,2} & A_{k,3} & A_{k,4} & A_{k,5} \end{pmatrix}$$

$$\min_{\mathbf{x}} \|A^T \mathbf{x} - \mathbf{w}\|_2.$$


value α is estimated as a li
genes

$$\alpha = \mathbf{b}^\top \mathbf{x} = \mathbf{b}^\top (\mathbf{A}^\top)^\dagger \mathbf{w},$$

$$W \simeq \mathbf{x}_1 \mathbf{a}_1 + \mathbf{x}_2 \mathbf{a}_2 + \cdots + \mathbf{x}_k \mathbf{a}_k,$$


are the coefficients of the linear combination in the least squares formulation (2). According to the least squares value α in $\mathbf{g}_1$ can be estimated by


$$\alpha = \mathbf{b}^T \mathbf{x} = \mathbf{b}_1 \mathbf{x}_1 + \mathbf{b}_2 \mathbf{x}_2 + \cdots + \mathbf{b}_k \mathbf{x}_k.$$



直方图Histograms

- 把数据划分成不相交的子集或桶
- 一维时可用动态规划优化构建
- 涉及量化问题





聚类Clustering

- 将对象划分成集/簇, 用簇的表示替换实际数据
 - 技术的有效性依赖于数据的质量
- 使用层次聚类, 并多维索引树结构存放
- 非常多的聚类算法和定义






图 3.12 给定数据集的 B+树的根



抽样Sampling


- **抽样: 获得一个小的样本集 s 来表示整个数据集 N**
- **允许一个挖掘算法运行复杂度子线性于样本大小**
- **关键原则: 选择一个有代表性的数据子集**
 - **数据偏斜时简单随机抽样的性能很差**
 - **发展适应抽样方法: 分层抽样**
- **Note: Sampling may not reduce database I/Os (page at a time)**



抽样类型 Types of Sampling

- 简单随机抽样 Simple random sampling
 - **相同的概率选择任何特定项目**
- 无放回抽样 Sampling without replacement
 - **Once an object is selected, it is removed from the population**
- 放回抽样 Sampling with replacement
 - **一个被抽中的目标不从总体中去除**
- 分层抽样 Stratified sampling:
 - **把数据分成不相交部分(层), 然后从每个层抽样(按比例/大约相同比例的数据)**
 - **偏斜数据**


Sampling: With or without Replacement







Sampling: Cluster or Stratified Sampling

Raw Data




Cluster/Stratified Sample
(整群/分层抽样)






第3章: 数据预处理

- 为什么预处理数据?
- 数据清理
- 数据集成
- 数据归约
- 离散化和概念分层产生
- 小结



离散化 Discretization和概念分层




- **三种类型属性:**
 - **名义** — values from an unordered set, color, profession
 - **顺序数** — values from an ordered set , e.g., military or academic rank
 - **连续** — real numbers
- **离散化 Discretization: 把连续属性的区域分成区间**
 - **区间标号可以代替实际数据值**
 - **利用离散化减少数据量**
 - **有监督 vs. 无监督: 是否使用类的信息**
 - **某个属性上可以递归离散化**
 - **分裂 Split (top-down) vs. 合并merge (bottom-up)**
 - **自顶向下: 由一个/几个点开始递归划分整个属性区间**
- **递归离散化属性, 产生属性值分层/多分辨率划分: 概念分层**




数值数据离散化/概念分层

- **分箱 Binning**(Top-down split, unsupervised)
- **直方图** (Top-down split, unsupervised)
- **聚类** (unsupervised, top-down split or bottom-up merge)
- **基于 χ^2 分析的区间合并**(unsupervised, bottom-up merge)
- **基于熵 Entropy-based discretization** (0=完全纯净, 一个类别; 1=数据均匀分布在每个类, 非常无序。)
- **根据自然划分**

不用类别(Binning vs. Clustering)



**Equal frequency
(binning)**



**K-means clustering leads to
better results**

基于熵Entropy的离散化

给定一个数据元素的集合 S 。基于熵对 A 离散化的方法如下：

1. A 的每个值可以认为是一个潜在的区间边界；
2. 选择的阈值 T 使其后划分得到的信息增益最大

$$I(S, T) = \frac{|S_1|}{|S|} Ent(S_1) + \frac{|S_2|}{|S|} Ent(S_2)$$

其中， S_1 和 S_2 分别对应于 S 中满足条件 $A < T$ 和 $A \geq T$ 的样本

$$Ent(S_1) = - \sum_{i=1}^m p_i \log_2(p_i)$$

其中， p_i 是类 i 在 S_1 中的概率，

等于 S_1 中类 i 的样本数除以 S_1 中的样本总数。

3. 直到满足某个终止条件 $Ent(S) - I(S, T) > \delta$



由自然划分离散化


- **3-4-5 规则**

- **如果最高有效位包含 3, 6, 7 or 9 个不同的值, partition the range into 3 个等宽区间 (7: 2-3-2分成3个区间)**
- **2, 4, or 8 不同的值, 区域分成 4 个等宽区间**
- **1, 5, or 10 不同的值, 区域分成5 个等宽区间**
- **类似地, 逐层使用此规则**




分类数据的概念分层 Categorical Data


- **用户/专家在模式级显式地指定属性的偏序**
 - `street < city < state < country`
- **通过显式数据分组说明分层**
 - `{厄巴纳, 香槟, 芝加哥} < 伊利诺伊州`
- **只说明属性集**
 - 系统自动产生属性偏序, 根据 每个属性下不同值的数据
 - 启发式规则: 相比低层, 高层概念的属性通常有较少取值
 - E.g., `street < city < state < country`
- **只说明部分属性值**



自动产生概念分层

- Some concept hierarchies can be automatically generated based on the analysis of the number of distinct values per attribute in the given data set
 - 含不同值最多的属性放在层次的最低层
 - Note: Exception—weekday, month, quarter, year






Summary

- **Data preparation is a big issue for both warehousing and mining**
- **Data preparation includes**
 - **Data cleaning and data integration**
 - **Data reduction and feature selection**
 - **Discretization**
- **A lot a methods have been developed but still an active area of research**

Data Reduction, Transformation, Integration

- **Data Quality**
- **Major Tasks in Data Preprocessing**
- **Data Cleaning and Data Integration**
 - **Data Cleaning**
 - i. Missing Data and Misguided Missing Data
 - ii. Noisy Data
 - iii. Data Cleaning as a Process
 - **Data Integration Methods**
- **Data Reduction**
 - **Data Reduction Strategies**
 - **Dimensionality Reduction**
 - i. Principal Component analysis
 - ii. Feature Subset Selection
 - iii. Feature Creation
 - **Numerosity Reduction**
 - i. Parametric Data Reduction: Regression and Log-Linear Models
 - ii. Mapping Data to a New Space: Wavelet Transformation
- **Data Transformation and Data Discretization**
 - **Data Transformation: Normalization**
 - **Data Discretization Methods**
 - i. Binning
 - ii. Cluster Analysis
 - iii. Discretization Using Class Labels: Entropy-Based Discretization
 - iv. Discretization Without Using Class Labels: Interval Merge by $\hat{A}^2$ Analysis
 - **Concept Hierarchy and Its Formation**
 - i. Concept Hierarchy Generation for Numerical Data
 - ii. Concept Hierarchy Generation for Categorical Data
 - iii. Automatic Concept Hierarchy Generation
- **Data Cube aggregation**
- **Data Compression**
- **Histogram analysis**
- **Clustering**
- **Sampling: Sampling without Replacement, Stratified Sampling**



References

- E. Rahm and H. H. Do. Data Cleaning: Problems and Current Approaches. *IEEE Bulletin of the Technical Committee on Data Engineering*. Vol.23, No.4
- D. P. Ballou and G. K. Tayi. Enhancing data quality in data warehouse environments. *Communications of ACM*, 42:73-78, 1999.
- H.V. Jagadish et al., Special Issue on Data Reduction Techniques. *Bulletin of the Technical Committee on Data Engineering*, 20(4), December 1997.
- A. Maydanchik, Challenges of Efficient Data Cleansing (DM Review - Data Quality resource portal)
- D. Pyle. *Data Preparation for Data Mining*. Morgan Kaufmann, 1999.
- D. Quass. A Framework for research in Data Cleaning. (Draft 1999)
- V. Raman and J. Hellerstein. Potters Wheel: An Interactive Framework for Data Cleaning and Transformation, VLDB'2001.
- T. Redman. *Data Quality: Management and Technology*. Bantam Books, New York, 1992.
- Y. Wand and R. Wang. Anchoring data quality dimensions ontological foundations. *Communications of ACM*, 39:86-95, 1996.
- R. Wang, V. Storey, and C. Firth. A framework for analysis of data quality research. *IEEE Trans. Knowledge and Data Engineering*, 7:623-640, 1995.
- <http://www.cs.ucla.edu/classes/spring01/cs240b/notes/data-integration1.pdf>

谢谢