



机器学习

苏州大学计算机科学与技术学院

自然语言处理实验室

主讲：周夏冰

邮箱：zhouxiabing@suda.edu.cn




01

线性可分 支持向量 机




线性可分支持向量机

- 线性分类器：寻找一个超平面，将不同样本分开




线性可分支持向量机

- 线性分类器：寻找一个超平面，将不同样本分开



线性可分支持向量机



- 线性分类器：寻找一个超平面，将不同样本分开






支持向量机 (SVM)

- 支持向量机是90年代中期发展起来的基于统计学习理论的一种机器学习方法，通过寻求**结构化风险最小**来提高学习机的**泛化能力**，从而达到在统计样本量比较少的情况下，亦能获得良好统计规律的目的
- 二分类的模型
- **基本模型**：在特征空间上的**间隔最大**的线性分类器，即SVM的学习策略便是间隔最大化，最终转化为一个凸二次规划问题的求解



感知机学习策略

- 输入空间中任一点 x_0 到超平面 S 的距离



$$\frac{1}{\|w\|} |w \cdot x_0 + b|$$



间隔

- 函数间隔

- 一个点距离分离超平面的远近可以表示分类预测的确信程度




图 7.1 二类分类问题

- $|wx + b|$ 相对表示点 x 到超平面的远近;
- $wx + b$ 的符号与类标记 y 的符号是否一致能够表示分类是否正确
- 所以, 用 $y(wx + b)$ 来表示分类的正确性及确信度



间隔

• 函数间隔

定义 7.2 (函数间隔) 对于给定的训练数据集 T 和超平面 (w, b) , 定义超平面 (w, b) 关于样本点 (x_i, y_i) 的函数间隔为

$$\hat{\gamma}_i = y_i(w \cdot x_i + b) \quad (7.3)$$

定义超平面 (w, b) 关于训练数据集 T 的函数间隔为超平面 (w, b) 关于 T 中所有样本点 (x_i, y_i) 的函数间隔之最小值, 即

$$\hat{\gamma} = \min_{i=1, \dots, N} \hat{\gamma}_i \quad (7.4)$$





间隔

• 几何间隔

定义 7.3 (几何间隔) 对于给定的训练数据集 T 和超平面 (w, b) ，定义超平面 (w, b) 关于样本点 (x_i, y_i) 的几何间隔为


$$\gamma_i = y_i \left(\frac{w}{\|w\|} \cdot x_i + \frac{b}{\|w\|} \right) \quad (7.5)$$

定义超平面 (w, b) 关于训练数据集 T 的几何间隔为超平面 (w, b) 关于 T 中所有样本点 (x_i, y_i) 的几何间隔之最小值，即



$$\gamma = \min_{i=1, \dots, N} \gamma_i \quad (7.6)$$



间隔最大化



- 支持向量在确定分离超平面中起着**决定性作用**（很少，但很重要），所以将这种分类模型称为支持向量机



线性可分支持向量机


• 间隔最大化：硬间隔最大化

- 以充分大的确信度对训练数据进行分类
- 泛化能力强；对新实例有很好的预测性

- $w x_1 + b = 1$; $w x_2 + b = -1$

- 两式子相减： $w \cdot \overrightarrow{x_1 x_2} = 2 = \|w\| \|x_1 x_2\| \cos \theta$

- 等价于： $\|w\| \times \gamma = 2 \quad \gamma = \frac{2}{\|w\|}$







线性可分支持向量机

- 支持向量机学习的最优化问题:

- $\min_{w,b} \frac{1}{2} \|w\|^2$

- $s. t. \quad y_i(w x_i + b) - 1 \geq 0, \quad i = 1, 2, \dots, N$

- 最大间隔分离超平面的存在唯一性





求解最优化

- 线性可分支持向量机的对偶算法

- 优点：对偶问题往往更容易求解

自然引入核函数

样本的可解释性

- 对偶问题

- 对偶问题的对偶是原问题；
 - 无论原始问题是否是凸的，拉格朗日对偶可以转化为凸优化问题；
 - 对偶问题可以给出原始问题一个下界；
 - 当满足一定条件时，原始问题与对偶问题的解是完全等价的；





对偶问题

- 原问题

$$\min f(\theta)$$

$$s. t. h_i(\theta) = 0 \quad i = 1, 2, \dots, p$$

$$g_j(\theta) \leq 0 \quad j = 1, 2, \dots, q$$

- 拉格朗日函数

$$L(\theta, \alpha, \beta) = f(\theta) + \sum \alpha_i g_i(\theta) + \sum \beta_j h_j(\theta)$$

- 原函数等价于: $f(\theta) = \max_{\alpha, \beta} L(\theta, \alpha, \beta)$

- 因此原问题: $\min f(\theta) = \min_{\theta} \max_{\alpha, \beta} L(\theta, \alpha, \beta)$





SVM



- $\min_{w,b} \frac{1}{2} \|w\|^2$
- *s. t.* $y_i(wx_i + b) - 1 \geq 0, \quad i = 1, 2, \dots, N$



$$1 - y_i(wx_i + b) \leq 0$$







SVM的对偶问题

- 定义拉格朗日函数

$$\bullet L = \frac{1}{2} ||w||^2 + \sum_{i=1}^N \alpha_i (1 - y^i (w \cdot x^i + b)) \quad \alpha_i \geq 0$$

- 与原始问题等价





SVM的对偶问题

- 定义拉格朗日函数

$$f = \min_{w,b} \left(\max_{\alpha} L(w, b, \alpha) \right)$$

$$f = \min_{w^*, b^*} \{ g(w_1, b_1), g(w_2, b_2), g(w_3, b_3), \dots \}$$

$$g(w_i, b_i) = \max_{\alpha^*} \{ L(w_i, b_i, \alpha_1), L(w_i, b_i, \alpha_2), \dots \}$$

- $L = \frac{1}{2} ||w||^2 + \sum_{i=1}^N \alpha_i (1 - y^i (w \cdot x^i + b)) \quad \alpha_i \geq 0$

- 与原始问题等价

- $\min_{b,w} (\max_{\alpha_i \geq 0} L(w, b, \alpha))$

- 针对每一组 (w, b) 来调节 α

- $g(w, b) = \max_{\alpha_i \geq 0} L(w, b, \alpha)$

- 无穷大

- $\frac{1}{2} ||w||^2$

$$\min_{w,b} g(w, b)$$



$$\min_{w,b} \frac{1}{2} ||w||^2$$

➤ 如果 (w, b) 不好: 在 N 个约束中至少有一条不满足, 即 $y^i (w \cdot x^i + b) < 1$, 也就是 $1 - y^i (w \cdot x^i + b) > 0$ 。此时, α_i 无穷大即可

➤ 如果 (w, b) 好: 满足所有约束, 即 $y^i (w \cdot x^i + b) \geq 1$, 也就是 $1 - y^i (w \cdot x^i + b) \leq 0$ 。此时, α_i 最好取 0, 那么最大化的结果就是 $\frac{1}{2} ||w||^2$



对偶问题



- 定义对偶函数(dual function)

- $D(\alpha, \beta) = \min_{\theta} L(\theta, \alpha, \beta)$

- 对偶问题: $\max_{\alpha, \beta} \min_{\theta} L(\theta, \alpha, \beta)$

- 假设原问题解 p^* , 对偶问题解 d^*
- 有 $d^* \leq p^*$
- 对偶问题是原问题解的一个下界

$$D(\alpha, \beta) = \min_{\theta^*} L(\theta^*, \alpha, \beta) \leq L(\hat{\theta}, \alpha, \beta) \leq \max_{\alpha^*, \beta^*} L(\theta, \alpha^*, \beta^*) = f(\theta)$$




对偶函数一定凸（凹）函数

$$D(\alpha, \beta) = \min_{\theta} L(\theta, \alpha, \beta)$$

$L(x, \alpha, \beta)$ 看成一个函数集合，每个元素由 $L(x_i, \alpha, \beta)$ 组成

$$D(\alpha, \beta) = \inf\{D_1(\alpha, \beta), D_2(\alpha, \beta), \dots, D_{\infty}(\alpha, \beta)\}$$

$$L(x, \alpha, \beta) = f(x) + \sum \alpha_i g_i(x) + \sum \beta_j h_j(x) \quad \text{关于 } \alpha, \beta \text{ 的仿射函数}$$



求解最优化

• 拉格朗日乘子法 (Lagrange Multiplier)

• 不等式情况

$$\min f(\theta)$$

$$\text{s.t. } h_i(\theta) = 0 \quad i = 1, 2, \dots, p$$

$$g_j(\theta) \leq 0 \quad j = 1, 2, \dots, q$$



$$L(\theta, \alpha, \beta) = f(\theta) + \sum \alpha_i g_i(\theta) + \sum \beta_j h_j(\theta)$$

• KKT条件 (Karush Kuhn Tucker)

$$1. \quad \frac{\partial L}{\partial \theta} = 0$$

$$2. \quad \alpha_j g_j = 0$$

$$3. \quad h_i = 0$$


$$4. \quad g_j(\theta) \leq 0$$

$$5. \quad \alpha_j \geq 0$$

$$L(x, \alpha) = f(x) + \sum \alpha_i g_i(x)$$





不等式情况

$$\begin{aligned} \min_x \quad & f(x) \\ \text{s.t.} \quad & g(x) \leq 0 \end{aligned}$$



$$\alpha g(x) = 0$$

$$\begin{aligned} \frac{\partial L}{\partial x} &= 0 \\ \alpha_j g_j &= 0 \\ \alpha_j &\geq 0 \end{aligned}$$



SVM的对偶问题

- $\min_{bw} L = \frac{1}{2} ||w||^2 + \sum_{i=1}^N \alpha_i (1 - y^i (w \cdot x^i + b))$




$$\frac{\partial L}{\partial w_j} = w_j - \sum_{i=1}^N \alpha_i y^i x_j^i = 0 \quad \mathbf{w_j = \sum_{i=1}^N \alpha_i y^i x_j^i}$$

$$\frac{\partial L}{\partial b} = \sum_{i=1}^N \alpha_i y^i = 0$$

- 带入

$$\max_{\alpha} L = -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y^i y^j (x^i \cdot x^j) + \sum_{i=1}^N \alpha_i$$

$$\sum_{i=1}^N \alpha_i y^i = 0 \quad \alpha_i \geq 0$$



解的等价

原函数: $f(\theta) = \max_{\alpha, \beta} L(\theta, \alpha, \beta)$

对偶函数: $D(\alpha, \beta) = \min_{\theta} L(\theta, \alpha, \beta)$

$$f(\theta^*) = D(\alpha^*, \beta^*)$$

$$\begin{aligned} D(\alpha^*, \beta^*) &= \min_{\theta} f(\theta) + \sum \alpha^* g(\theta) + \sum \beta^* h(\theta) \\ &\leq f(\theta^*) + \sum \alpha^* g(\theta^*) + \boxed{0} \\ &\leq f(\theta^*) \end{aligned}$$

等号成立

θ^* 是一个极大值点

$$\nabla_{\theta^*} L(\theta, \alpha, \beta) = 0$$

等号成立

$\alpha_j^* g_j(\theta^*)$ 都是非正

$$\alpha_j^* g_j(\theta^*) = 0$$

$$\begin{aligned} \alpha^* &\geq 0 \\ g(x^*) &\leq 0 \end{aligned}$$

- $\frac{\partial L}{\partial \theta} = 0$
- $\alpha_j g_j = 0$
- $h_i = 0$
- $g_j(\theta) \leq 0$
- $\alpha_j \geq 0$

满足KKT条件

SVM对偶问题解

- 根据KKT条件:

$$\nabla_w L(w^*, b^*, \alpha^*) = w^* - \sum_{i=1}^N \alpha_i^* y_i x_i = 0 \quad \longrightarrow \quad w^* = \sum_{i=1}^N \alpha_i^* y_i x_i$$

$$\nabla_b L(w^*, b^*, \alpha^*) = -\sum_{i=1}^N \alpha_i^* y_i = 0 \quad b^* = y_j - \sum_{i=1}^N \alpha_i^* y_i (x_i \cdot x_j)$$

$$\alpha_i^* (y_i (w^* \cdot x_i + b^*) - 1) = 0, \quad i = 1, 2, \dots, N$$

$$y_i (w^* \cdot x_i + b^*) - 1 \geq 0, \quad i = 1, 2, \dots, N$$

$$\alpha_i^* \geq 0, \quad i = 1, 2, \dots, N$$

对于正分量 $\alpha_j > 0$

$$y_j (w^* \cdot x_j + b^*) = 1$$





SVM对偶问题



- SVM目标函数:

- $\max_{\alpha} L = -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y^i y^j (\mathbf{x}^i \cdot \mathbf{x}^j) + \sum_{i=1}^N \alpha_i$

- $\min_{\alpha} L = \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y^i y^j (\mathbf{x}^i \cdot \mathbf{x}^j) - \sum_{i=1}^N \alpha_i$

- $\sum_{i=1}^N \alpha_i y^i = 0$

- $\alpha_i \geq 0$



例7.2

$$\begin{aligned} \min_{\alpha} L &= \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y^i y^j (x^i \cdot x^j) - \sum_{i=1}^N \alpha_i \\ \sum_{i=1}^N \alpha_i y^i &= 0 \\ \alpha_i &\geq 0 \end{aligned}$$

- 正实例 $x_1 = (3, 3)^T$, $x_2 = (4, 3)^T$, 负实例 $x_3 = (1, 1)^T$

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i && = \alpha_1^2 y_1^2 (3,3) \cdot (3,3) + 2\alpha_1 \alpha_2 y_1 y_2 (3,3) \cdot (4,3) \\ &&& + 2\alpha_1 \alpha_3 y_1 y_3 (3,3) \cdot (1,1) + 2\alpha_2 \alpha_3 y_2 y_3 (4,3) \cdot (1,1) \\ &&& + \alpha_2^2 y_2^2 (4,3) \cdot (4,3) + \alpha_3^2 y_3^2 (1,1) \cdot (1,1) \\ &&& = \frac{1}{2} (18\alpha_1^2 + 25\alpha_2^2 + 2\alpha_3^2 + 42\alpha_1 \alpha_2 - 12\alpha_1 \alpha_3 - 14\alpha_2 \alpha_3) - \alpha_1 - \alpha_2 - \alpha_3 \\ \text{s.t.} \quad & \alpha_1 + \alpha_2 - \alpha_3 = 0 \\ & \alpha_i \geq 0, \quad i = 1, 2, 3 \end{aligned}$$

$$\alpha_3 = \alpha_1 + \alpha_2 \longrightarrow s(\alpha_1, \alpha_2) = 4\alpha_1^2 + \frac{13}{2}\alpha_2^2 + 10\alpha_1 \alpha_2 - 2\alpha_1 - 2\alpha_2$$





例7.2

$$\frac{\partial s}{\partial \alpha_1} = 8\alpha_1 + 10\alpha_2 - 2 = 0$$
$$\frac{\partial s}{\partial \alpha_2} = 13\alpha_2 + 10\alpha_1 - 2 = 0$$

- $s(\alpha_1, \alpha_2) = 4\alpha_1^2 + \frac{13}{2}\alpha_2^2 + 10\alpha_1\alpha_2 - 2\alpha_1 - 2\alpha_2$

- 1. 两个均不为0, 可得: $\alpha_1 = \frac{3}{2}, \alpha_2 = -1$ **×**

- 2. $\alpha_1 = 0, \alpha_2 = 0$ **×**

- 3. $\alpha_1 = 0, \alpha_2 \neq 0$, 可得: $\alpha_2 = \frac{2}{13}$

$$s = -\frac{2}{13}$$

- 4. $\alpha_2 = 0, \alpha_1 \neq 0$, 可得: $\alpha_1 = \frac{1}{4}$

$$s = -\frac{1}{4}$$

$$\alpha_3 = \frac{1}{4}$$

$$\alpha_i(1 - y_i(wx_i + b)) = 0$$



$$y_i(wx_i + b) = 1$$



α_1, α_3 为支持向量

$$\frac{\partial s}{\partial \alpha_1} = 8\alpha_1 - 2 = 0$$

