



# 机器学习

苏州大学计算机科学与技术学院

自然语言处理实验室

主讲：周夏冰

邮箱：[zhouxiabing@suda.edu.cn](mailto:zhouxiabing@suda.edu.cn)

The background of the slide is a close-up photograph of pink cherry blossoms. The flowers are in various stages of bloom, with some showing yellow stamens. The image is slightly blurred, giving it a soft, dreamy appearance.

**EM**





# EM算法简介

- **期望最大化**(Expectation Maximization)算法。
  - **迭代算法**，在概率模型中寻找参数极大似然估计的算法，
  - 概率模型依赖于无法观测的**隐含变量**。
  - 主要用于从含有隐含变量的数据中计算极大似然估计，是解决存在隐含变量优化问题的有效方法。





# 回顾

- 极大似然估计

似然函数  $L(\theta) = \prod_{i=1}^n p(x_i; \theta)$  是

参数  $\theta$  的函数。显然随着  $\theta$  在参数空间  $\Theta$  的变化，似然函数的值也要发生变化。而极大似然估计的目的就是在样本点  $\{x_1, \dots, x_n\}$  固定的情况下，寻找最优的  $\theta$  来极大化似然函数，即

$$\theta^* = \arg \max_{\theta \in \Theta} L(\theta)$$





# 回顾

- 极大似然估计



想要求  $\theta^*$ ，只需要使  $\theta$  的似然函数  $L(\theta)$  极大化，极大值对应的  $\theta^*$  就是我们的估计值。

因  $L(\theta)$  与  $\ln L(\theta)$  在同一  $\theta$  处取到极值，所以对数化似然函数

$$\ln(L(\theta)) = \sum_{i=1}^n \ln p(x_i; \theta)$$

因此  $\theta$  的极大似然估计  $\theta^*$  也可从下述方程解得：

$$\frac{d}{d\theta} \ln L(\theta) = 0.$$







# 一个例子

- **例1-1:** 考虑投硬币的实验，现在我们有两枚硬币A和B，这两枚硬币和普通的硬币不一样，他们投掷出正面的概率和投掷出反面的概率不一定相同。我们将A和B投掷正面的概率分别设为 $\theta_A$ 和 $\theta_B$ 。独立地做5次试验，随机的从这两枚硬币抽1枚，投掷10次，统计出现正面的概率，得到结果

试验代号	投掷的硬币	出现正面的次数
1	B	5
2	A	9
3	A	8
4	B	4
5	A	7

有完整数据的参数估计



# 一个例子

- **例1-2:** 考虑投硬币的实验，现在我们有两枚硬币A和B，这两枚硬币和普通的硬币不一样，他们投掷出正面的概率和投掷出反面的概率不一定相同。我们将A和B投掷正面的概率分别设为  $\theta_A$  和  $\theta_B$ 。独立地做5次试验，随机的从这两枚硬币抽1枚，投掷10次，统计出现正面的概率，得到结果

试验代号	投掷的硬币	出现正面的次数
1	B	5
2	A	9
3	A	8
4	B	4
5	A	7

不完整数据的参数估计



# EM算法

$$P(Y|\theta) = \prod_{i=1}^n [\pi p^{y_i}(1-p)^{1-y_i} + (1-\pi)q^{y_i}(1-q)^{1-y_i}]$$

- **例2**：3枚硬币，A，B，C，这些硬币出现正面的概率 $\pi, p, q$ 。进行如下掷硬币试验：先掷A，如果正面，**选硬币B**，**反面选C**；然后投选出来的硬币，出现正面记为1，出现反面记为0；独立重复试验，求三枚硬币出现正面的概率

• **隐变量**：

观测变量

是

隐变量

先选择硬币

在硬币下表现出的正反面

$$P(y|\theta) = \sum_z P(y, z|\theta) = \sum_z P(z|\theta)P(y|z, \theta) =$$



$$\pi p^y(1-p)^{1-y} + (1-\pi)q^y(1-q)^{1-y}$$





# 最大似然估计—存在隐变量

- $P(Y|\theta) = \prod_{i=1}^n [\pi p^{y_i}(1-p)^{1-y_i} + (1-\pi)q^{y_i}(1-q)^{1-y_i}]$
- $\ln P(Y|\theta) = \sum_{i=1}^n \ln [\pi p^{y_i}(1-p)^{1-y_i} + (1-\pi)q^{y_i}(1-q)^{1-y_i}]$
- $\frac{\partial \ln P(Y|\theta)}{\partial \pi} = \sum_{i=1}^n \frac{p^{y_i}(1-p)^{1-y_i} - q^{y_i}(1-q)^{1-y_i}}{\pi p^{y_i}(1-p)^{1-y_i} + (1-\pi)q^{y_i}(1-q)^{1-y_i}}$







# 最大似然估计—不存在隐变量

- $P(Y|\theta) = [q^{y_1}(1-q)^{1-y_1}][p^{y_2}(1-p)^{1-y_2}] \dots$

明确知道仍的  
哪个硬币

- $\ln P(Y|\theta) = \sum_{i=1}^{n_1} \ln p^{y_i}(1-p)^{1-y_i} + \sum_{j=1}^{n_2} \ln q^{y_j}(1-q)^{1-y_j}$




- $\frac{\partial \ln P(Y|\theta)}{\partial p} = \sum_{i=1}^{n_1} \frac{(\cancel{1-p})^{1-y_j} \cdot \color{blue}{y_j \cdot \cancel{p}^{y_j} \cdot p^{-1}} + \cancel{p}^{y_j} \cdot (y_j-1) \cdot (\cancel{1-p})^{1-y_j} \cdot (\cancel{1-p})^{-1}}{\cancel{p}^{y_j} (\cancel{1-p})^{1-y_j}}$





# EM算法

- EM算法包含两步：
  - E: 求期望 (隐变量的条件概率分布的期望)  $Q(\theta, \theta^i)$
  - M: 求极大化  $\frac{Q}{\partial \theta} = 0$
- (E-step) 如果参数已知, 根据训练数据推断出最优隐变量的值
- (M-step) 如果隐变量已知, 对参数做极大似然估计





# EM算法过程



- EM算法包含两步:

- **E-step**: 记 $\theta^i$ 为第 $i$ 次迭代参数 $\theta$ 的估计值, 在第 $i + 1$ 次迭代的E步, 计算

$$Q(\theta, \theta^i) = E_Z[\log P(Y, Z|\theta) | Y, \theta^i] = \sum_Z P(Z|Y, \theta^i) \log P(Y, Z|\theta)$$

- **M-step**: 求使 $Q(\theta, \theta^i)$ 极大化的 $\theta$ , 确定第 $i+1$ 次迭代的参数的估计值 $\theta^{i+1}$ ,



$$\theta^{i+1} = \operatorname{argmax}_{\theta} Q(\theta, \theta^i)$$





# EM算法的导出

- 目的：求  $L(\theta) = \log P(Y|\theta)$ 
  - $L(\theta) = \log P(Y|\theta) = \log \sum_Z P(Y, Z|\theta)$ 
$$= \log \sum_Z P(Y|Z, \theta)P(Z|\theta)$$









# EM算法的导出

- 中心目标：极大化

$$P(Y|\theta) = \prod_{i=1}^n [\pi p^{y_i} (1-p)^{1-y_i} + (1-\pi) q^{y_i} (1-q)^{1-y_i}]$$
$$\theta = (\pi, p, q)$$

- $L(\theta) = \log \sum_Z P(Y|Z, \theta) P(Z|\theta)$
- 新的 $\theta$ ，希望能使 $L(\theta)$ 增加
  - 在第 $i$ 次的参数为 $\theta^i$
  - $L(\theta) - L(\theta^i) = \log \sum_Z P(Y|Z, \theta) P(Z|\theta) - \log P(Y|\theta^i)$
  - $= \log \sum_Z \mathbf{P(Z|Y, \theta^i)} \frac{P(Y|Z, \theta) P(Z|\theta)}{\mathbf{P(Z|Y, \theta^i)}} - \log P(Y|\theta^i)$





# EM算法的导出

$$\begin{aligned} & \bullet \log \left[ \sum_Z P(Z|Y, \theta^i) \frac{P(Y|Z, \theta) P(Z| \theta)}{P(Z|Y, \theta^i)} \right] \\ & \bullet \geq \sum_Z P(Z|Y, \theta^i) \log \frac{P(Y|Z, \theta) P(Z| \theta)}{P(Z|Y, \theta^i)} \end{aligned}$$

Jesen不等式:  $\log \sum_j \lambda_j y_j \geq \sum_j \lambda_j \log y_j, \sum_j \lambda_j = 1$





# EM算法的导出

- 中心目标：极大化

- $L(\theta) = \log \sum_Z P(Y|Z, \theta)P(Z|\theta)$

- 新的 $\theta$ ，希望能使 $L(\theta)$ 增加

- 在第 $i$ 次的参数为 $\theta^i$

- $L(\theta) - L(\theta^i) = \log \sum_Z P(Y|Z, \theta)P(Z|\theta) - \log P(Y|\theta^i)$

- $= \log \sum_Z P(Z|Y, \theta^i) \frac{P(Y|Z, \theta)P(Z|\theta)}{P(Z|Y, \theta^i)} - \log P(Y|\theta^i)$

- $\geq \sum_Z P(Z|Y, \theta^i) \log \frac{P(Y|Z, \theta)P(Z|\theta)}{P(Z|Y, \theta^i)P(Y|\theta^i)}$

令  $B(\theta, \theta^i) = L(\theta^i) + \sum_Z P(Z|Y, \theta^i) \log \frac{P(Y|Z, \theta)P(Z|\theta)}{P(Z|Y, \theta^i)P(Y|\theta^i)}$

$L(\theta) \geq B(\theta, \theta^i)$



# EM算法的导出

- $L(\theta) \geq B(\theta, \theta^i)$
- $B(\theta, \theta^i)$ 是一个下界
- 如果使 $B(\theta, \theta^i)$ 增大的 $\theta$ , 也可以使 $L(\theta)$ 增大
- 为了使 $L(\theta)$ 尽可能增大, 有 $\theta^{i+1} = \operatorname{argmax}_{\theta} B(\theta, \theta^i)$
- $\operatorname{argmax}_{\theta} L(\theta^i) + \sum_Z P(Z|Y, \theta^i) \log \frac{P(Y|Z, \theta)P(Z|\theta)}{P(Z|Y, \theta^i)P(Y|\theta^i)}$



# EM算法的导出

- $\operatorname{argmax}_{\theta} L(\theta^i) + \sum_Z P(Z|Y, \theta^i) \log \frac{P(Y|Z, \theta)P(Z|\theta)}{P(Z|Y, \theta^i)P(Y|\theta^i)}$
- $= \operatorname{argmax}_{\theta} \sum_Z P(Z|Y, \theta^i) \log P(Y|Z, \theta)P(Z|\theta)$
- $= \operatorname{argmax}_{\theta} \sum_Z P(Z|Y, \theta^i) \log P(Y, Z|\theta)$

$$\begin{aligned} Q(\theta, \theta^i) &= E_Z[\log P(Y, Z|\theta) | Y, \theta^i] \\ &= \sum_Z \log P(Y, Z|\theta) P(Z|Y, \theta^i) \end{aligned}$$



# EM算法

- EM算法包含两步:



- E-step: 记 $\theta^i$ 为第 $i$ 次迭代参数 $\theta$ 的估计值, 在第 $i + 1$ 次迭代的E步, 计算

$$Q(\theta, \theta^i) = E_Z[\log P(Y, Z|\theta) | Y, \theta^i] = \sum_Z P(Z|Y, \theta^i) \log P(Y, Z|\theta)$$

- M-step: 求使 $Q(\theta, \theta^i)$ 极大化的 $\theta$

$$\theta = \operatorname{argmax}_{\theta} Q(\theta, \theta^i)$$

给定当前观测变量和参数 $\theta^i$ ,  $Z$ 的条件概率分布








# EM算法

## • 说明:

- 对初值敏感
- 局部极值
- 停止迭代条件
  - $\|\theta^{i+1} - \theta^i\| < \varepsilon$
  - $\|Q(\theta^{i+1}, \theta^i) - Q(\theta^i, \theta^i)\| < \varepsilon$



# 例子—扔硬币

$$P(\text{事件}A|\text{观测}y_j) = \frac{P(\text{观测}y_j|\text{事件}A)P(\text{事件}A)}{P(\text{观测}y_j)}$$

- **例2**：3枚硬币，A，B，C，这些硬币出现正面的概率  $\pi, p, q$ 。进行如下掷硬币试验：先掷A，如果正面，选硬币B，反面选C；然后投选出来的硬币，出现正面记为1，出现反面记为0；独立反复做n次试验，求三枚硬币出现正面的概率

- **隐变量**：投掷的是B还是C

- 硬币来自B:  $\mu_j^k = P(Z = B|Y, \theta^{k-1})$

- 硬币来自C:  $1 - \mu_j^k$

K表示第几轮参数值

硬币来自B的概率

硬币来自B，  
观测 $y_j$ 的概率



$$= \frac{\pi^{k-1} (p^{k-1})^{y_j} (1 - p^{k-1})^{1-y_j}}{\pi^{k-1} (p^{k-1})^{y_j} (1 - p^{k-1})^{1-y_j} + (1 - \pi^{k-1}) (q^{k-1})^{y_j} (1 - q^{k-1})^{1-y_j}}$$

全概率

常数

# 例子—扔硬币

- $Q(\theta, \theta^i) = \sum_Z \mathbf{P}(\mathbf{Z}|\mathbf{Y}, \theta^k) \log P(\mathbf{Y}, \mathbf{Z}|\theta)$
- $= \sum_Z \mathbf{P}(\mathbf{Z}|\mathbf{Y}, \theta^k) \log P(\mathbf{Z}|\theta) \mathbf{P}(\mathbf{Y}|\mathbf{Z}, \theta)$
- $\sum_Z$  包含了两种情况（来自 $B$ 硬币 or 来自 $C$ 硬币）
- $\sum_{j=1}^N \{ \mu_j^k \log [\pi p^{y_j} (1-p)^{1-y_j}] + (1 - \mu_j^k) \log [(1-\pi) q^{y_j} (1-q)^{1-y_j}] \}$
- 最大化：对参数求导



# 例子—扔硬币

- $\sum_{j=1}^N \{ \mu_j^k \log [\pi p^{y_j} (1-p)^{1-y_j}] + (1-\mu_j^k) \log [(1-\pi) q^{y_j} (1-q)^{1-y_j}] \}$
- $\sum_{j=1}^N \{ \mu_j^k \log [\textcolor{red}{\pi} p^{y_j} (1-p)^{1-y_j}] + (1-\mu_j^k) \log [(1-\textcolor{red}{\pi}) q^{y_j} (1-q)^{1-y_j}] \}$
- $\frac{\sum_{j=1}^N \mu_j^k}{\pi} - \frac{\sum_{j=1}^N (1-\mu_j^k)}{1-\pi} = 0$
- $\sum_{j=1}^N \mu_j^k - \sum_{j=1}^N \mu_j^k \pi - n\pi + \sum_{j=1}^N \mu_j^k \pi = 0$
- $\textcolor{red}{\pi} = \frac{1}{n} \sum_{j=1}^N \mu_j^k$





# 例子—扔硬币



$$\bullet \sum_{j=1}^N \{ \mu_j^k \log [\pi \mathbf{p}^{y_j} (1 - \mathbf{p})^{1-y_j}] + (1 - \mu_j^k) \log [(1 - \pi) q^{y_j} (1 - q)^{1-y_j}] \}$$

$$\bullet \sum_{j=1}^N \mu_j^k \cdot \frac{\cancel{(1-p)^{1-y_j}} \cdot \mathbf{y_j} \cdot \cancel{p^{y_j}} \cdot \mathbf{p^{-1}} + \cancel{p^{y_j}} \cdot (y_j - 1) \cdot \cancel{(1-p)^{1-y_j}} \cdot \mathbf{(1-p)^{-1}}}{\cancel{p^{y_j}} \cdot \cancel{(1-p)^{1-y_j}}} = 0$$

$$\bullet \sum_{j=1}^N \mu_j^k \cdot \frac{y_j (1-p) + (y_j - 1)p}{p(1-p)} = 0$$

$$\bullet \sum_{j=1}^N \mu_j^k y_j = \sum_{j=1}^N \mu_j^k p$$

$$\bullet \mathbf{p} = \frac{\sum_{j=1}^N \mu_j^k y_j}{\sum_{j=1}^N \mu_j^k}$$



# 高斯混合模型


- 高斯混合模型 (Gaussian mixture model)

- 一个事物分解为若干的基于高斯概率密度函数（正态分布曲线）形成的模型


- 公式表达:  $P(y|\theta) = \sum_{k=1}^K \alpha_k \phi(y|\theta_k)$

- $\theta = (\alpha_1, \alpha_2, \dots, \alpha_k; \theta_1, \theta_2, \dots, \theta_k)$

- $\phi(y|\theta_k) = \frac{1}{\sqrt{2\pi}\sigma_k} \exp\left(-\frac{(y-\mu_k)^2}{2\sigma_k^2}\right)$



(a)



(b)

图1 高斯混合模型图示, (a)表示所有样本数据; (b)表示已经明确了样本的分类



# 高斯混合模型

$$P(\text{事件}A|\text{观测}y_j) = \frac{P(\text{观测}y_j|\text{事件}A)P(\text{事件}A)}{P(\text{观测}y_j)}$$

## • 定义隐变量

$$\theta^{i-1} = \{\theta_1^{i-1}, \theta_2^{i-1}, \dots, \theta_K^{i-1}\}$$

$$\theta_k^{i-1} = \{\alpha_k^{i-1}, \sigma_k^{i-1}, \mu_k^{i-1}\}$$

已知量

$$\gamma_{jk} = \begin{cases} 1, & \text{第}j\text{个观测来自第}k\text{个分模型} \\ 0, & \text{否则} \end{cases}$$

$$\hat{\gamma}_{jk} = P(\gamma_{jk} = 1 | y_j, \theta_k^{i-1}) \quad i-1 \text{ 表示第} i-1 \text{ 轮参数}$$

$$\begin{aligned} P(\gamma_{jk} = 1 | y_j, \theta_k^{i-1}) &= \frac{P(\gamma_{jk}=1, y_j | \theta_k^{i-1})}{P(y_j | \theta_k^{i-1})} = \frac{\overbrace{P(y_j | \gamma_{jk}=1, \theta_k^{i-1})}^{\phi(y|\theta_k)} \overbrace{P(\gamma_{jk}=1 | \theta_k^{i-1})}^{\alpha_k}}{\underbrace{P(y_j | \theta_k^{i-1})}_{P(y_j | \theta)}} = \frac{\phi(y_j | \theta_k^{i-1}) \cdot \alpha_k}{\sum_{k=1}^K \alpha_k \phi(y_j | \theta_k^{i-1})} \end{aligned}$$

$P(y_j | \theta) = \sum_{k=1}^K \alpha_k \phi(y_j | \theta_k)$

# 高斯混合模型

$$\sum_{k=1}^K \left\{ \sum_{j=1}^N \hat{y}_{jk} \log \left( \alpha_k \cdot \frac{1}{\sqrt{2\pi}\sigma_k} \exp\left(-\frac{(y_j - \mu_k)^2}{2\sigma_k^2}\right) \right) \right\}$$

- $Q(\theta, \theta^i) = \sum_Z \mathbf{P}(\mathbf{Z}|\mathbf{Y}, \theta^{i-1}) \log P(\mathbf{Y}, \mathbf{Z}|\theta)$

- $P(\mathbf{Z}|\mathbf{Y}, \theta^{i-1}) = P(\gamma_{jk}|\mathbf{y}_j, \theta_k^{i-1}) = \hat{\gamma}_{jk}$

- $\log P(\mathbf{Y}, \mathbf{Z}|\theta) = \log P(\mathbf{Z}|\theta)P(\mathbf{Y}|\mathbf{Z}, \theta)$

- $P(\mathbf{Z}|\theta) = P(\gamma_{jk}|\theta_k) = \alpha_k$



- $P(\mathbf{Y}|\mathbf{Z}, \theta) = P(\mathbf{y}_j|\gamma_{jk}, \theta_k) = \frac{1}{\sqrt{2\pi}\sigma_k} \exp\left(-\frac{(y_j - \mu_k)^2}{2\sigma_k^2}\right)$



# 高斯混合模型

$$\bullet \sum_{k=1}^K \left\{ \sum_{j=1}^N \hat{y}_{jk} \log \left( \alpha_k \cdot \frac{1}{\sqrt{2\pi}\sigma_k} \exp\left(-\frac{(y_j - \mu_k)^2}{2\sigma_k^2}\right) \right) \right\}$$

$$\bullet \sum_{k=1}^K \left\{ \sum_{j=1}^N \hat{y}_{jk} \log(\alpha_k) + \sum_{j=1}^N \hat{y}_{jk} \left( \log \frac{1}{\sqrt{2\pi}\sigma_k} - \frac{(y_j - \mu_k)^2}{2\sigma_k^2} \right) \right\}$$





# 高斯混合模型

$$\sum_{j=1}^N \hat{y}_{jk} \log(\alpha_k) + \lambda(\alpha_k - 1)$$

$$\bullet \sum_{k=1}^K \left\{ \sum_{j=1}^N \hat{y}_{jk} \log(\alpha_k) + \sum_{j=1}^N \hat{y}_{jk} \left( \log \frac{1}{\sqrt{2\pi}\sigma_k} - \frac{(y_j - \mu_k)^2}{2\sigma_k^2} \right) \right\}$$

$$\bullet \text{注意约束: } \sum_{k=1}^K \alpha_k = 1$$

$$\bullet J = \sum_{k=1}^K \sum_{j=1}^N \hat{y}_{jk} \log(\alpha_k) + \lambda(\sum_{k=1}^K \alpha_k - 1)$$

$$\bullet \frac{\partial J}{\partial \alpha_k} = \sum_{j=1}^N \hat{y}_{jk} + \lambda \alpha_k = 0$$



$$\sum_{k=1}^K \left( \sum_{j=1}^N \hat{y}_{jk} + \lambda \alpha_k \right) = 0$$



$$\lambda = -N$$

$$\bullet \alpha_k = \frac{\sum_{j=1}^N \hat{y}_{jk}}{N}$$

$$\sum_{k=1}^K \alpha_k = 1$$

$$\sum_{k=1}^K \hat{y}_{jk} = 1$$

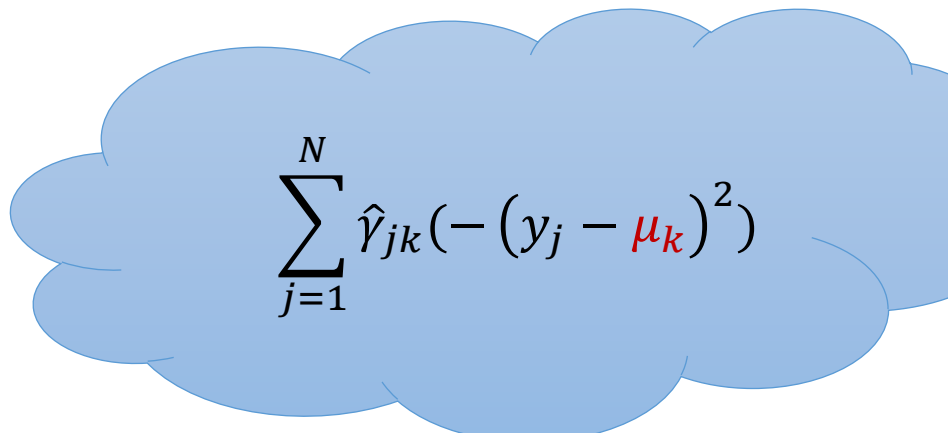
# 高斯混合模型

- $\sum_{k=1}^K \left\{ \sum_{j=1}^N \hat{y}_{jk} \log(\alpha_k) + \sum_{j=1}^N \hat{y}_{jk} \left( \log \frac{1}{\sqrt{2\pi}\sigma_k} - \frac{(y_j - \mu_k)^2}{2\sigma_k^2} \right) \right\}$

- $J = \sum_{k=1}^K \left\{ \sum_{j=1}^N \hat{y}_{jk} \left( -\frac{(y_j - \mu_k)^2}{2\sigma_k^2} \right) \right\}$

- $\frac{\partial J}{\partial \mu_k} = 2 \sum_{j=1}^N \hat{y}_{jk} (y_j - \mu_k) = 0$

- $\mu_k = \frac{\sum_{j=1}^N \hat{y}_{jk} y_j}{\sum_{j=1}^N \hat{y}_{jk}}$

A large, light blue cloud-like shape containing a mathematical expression.
$$\sum_{j=1}^N \hat{y}_{jk} (-(y_j - \mu_k)^2)$$



# 高斯混合模型

- $\sum_{k=1}^K \left\{ \sum_{j=1}^N \hat{y}_{jk} \log(\alpha_k) + \sum_{j=1}^N \hat{y}_{jk} \left( \log \frac{1}{\sqrt{2\pi}} - \frac{1}{2} \log \sigma_k^2 - \frac{(y_j - \mu_k)^2}{2\sigma_k^2} \right) \right\}$

- $J = \sum_{k=1}^K \left\{ \sum_{j=1}^N \hat{y}_{jk} \left( -\frac{1}{2} \log \sigma_k^2 - \frac{(y_j - \mu_k)^2}{2\sigma_k^2} \right) \right\}$

- $\frac{\partial J}{\partial \sigma_k^2} = \sum_{j=1}^N \hat{y}_{jk} \left( -\frac{1}{2} \cdot \frac{1}{\sigma_k^2} + \frac{1}{2} \cdot \frac{(y_j - \mu_k)^2}{(\sigma_k^2)^2} \right) = 0$

- $\sigma_k^2 = \frac{\sum_{j=1}^N \hat{y}_{jk} (y_j - \mu_k)^2}{\sum_{j=1}^N \hat{y}_{jk}}$

$$\sum_{j=1}^N \left( \hat{y}_{jk} - \frac{(y_j - \mu_k)^2}{\sigma_k^2} \right) = 0$$



# EM



- EM 算法可以用到朴素贝叶斯法的无监督学习。
- 考虑无监督文本二分类问题，即训练数据包含  $m$  个文档  $\{z^1, z^2, \dots, z^m\}$ ，无监督场景下每个文档的类别未知，已知词表总数为  $d$ ，每个文档数据均由  $d$  维向量表示

$$(z^i = \{x_1^i, x_2^i, \dots, x_d^i\}, \quad x_j^i = \begin{cases} 0 & z^i \text{ 内不包含第 } j \text{ 个词} \\ 1 & z^i \text{ 内包含第 } j \text{ 个词} \end{cases})$$

考虑朴素贝叶斯判断公式：  $p(c|x) \approx \prod_{j=1}^d p(x_j|c)p(c)$   
定义如下模型参数：

$\phi_{z^i} = p(z^i = 1)$ ，文档  $i$  属于第1类

$\varphi_{j|z^i=1} = p(x_j^i = 1|z^i = 1)$ ，当  $i$  文档属于第1类时，第  $j$  个特征出现

$\varphi_{j|z^i=0} = p(x_j^i = 1|z^i = 0)$ ，当  $i$  文档属于第2类时，第  $j$  个特征出现