



机器学习

苏州大学计算机科学与技术学院

自然语言处理实验室



主讲：周夏冰

邮箱：zhouxiabing@suda.edu.cn



条件随机场模型

- **条件随机场** (conditional random field, CRF) 是给定一组输入随机变量 **条件下** 另一组输出随机变量的条件概率分布模型，其特点是假设 **输出** 随机变量构成 **马尔可夫随机场** $P(y|x)$
- 马尔可夫随机场：无向图模型



马尔可夫随机场


- 无向图概率图模型：利用无向图结构来表示变量间概率依赖关系

- 无向图 $G = (V, E)$

- 结构：模型由一组节点（代表随机变量）和连接节点的无向边组成。边表示节点之间存在某种依赖关系，但方向性未定义。

- 任何结点 $v \in V$ ，表示一个随机变量 Y_v

- 边 $e \in E$ 表示随机变量之间的依赖关系



- 联合概率密度 $P(Y)$



- 通过定义无向图上的势函数（Potential Functions）来描述变量间的联合概率分布





马尔可夫随机场


- 如果联合概率分布 $P(Y)$ 满足成对、局部或全局马尔可夫性，就称此联合概率分布为概率无向图模型(probability undirected graphical model)，或马尔可夫随机场(Markov random field)
 - 描述随机变量间条件独立性关系
 - 从不同层面刻画了变量间的依赖结构



马尔可夫随机场

成对马尔可夫性


- 设 u 和 v 是无向图 G 中任意两个没有边连接的结点，结点 u 和 v 分别对应随机变量 Y_u 和 Y_v ，其他所有结点为 O ，对应的随机变量组是 Y_O
- $P(Y_u, Y_v | Y_O) = P(Y_u | Y_O)P(Y_v | Y_O)$



关注非相邻节点的独立性，是局部性质的体现

局部马尔可夫性


- W 是与 v 有边相连的所有结点， O 为其它结点
- $P(Y_v, Y_O | Y_W) = P(Y_v | Y_W)P(Y_O | Y_W)$



强调整节点与邻居的依赖关系，是模型推断的基础

全局马尔可夫性

- A 和 B 在无向图中被结点 C 分隔开
- $P(Y_A, Y_B | Y_C) = P(Y_A | Y_C)P(Y_B | Y_C)$




提供最一般的条件独立性描述，是图模型理论的核心

马尔可夫随机场



- 无向图的因子分解

- 团



- 最大团


- $\{x_1, x_2\}, \{x_1, x_3\}, \{x_2, x_4\}, \{x_3, x_5\}, \{x_2, x_5, x_6\}$



马尔可夫随机场



- 无向图的因子分解

- 团&最大团



- 势函数

- 相关关系度量：比如 x_2 与 x_4 相连，则它们具有相关关系 $\varphi(x_2, x_4) = \begin{cases} 1.5 & \text{if } x_2 = x_4 \\ 0.1 & \text{if otherwise} \end{cases}$



马尔可夫随机场

• 联合概率

- Hammersley-Clifford定理保证





- $P(Y) = \frac{1}{Z} \prod_c \psi_c(Y_c)$

- $Z = \sum_Y \prod_c \psi_c(Y_c)$

- 基于团分解为多个因子成积

- $P(x) = \frac{1}{Z} \prod_{Q \in \mathcal{C}} \psi_Q(x_Q)$

- $P(x) = \frac{1}{Z} \psi_{12}(x_1, x_2) \psi_{13}(x_1, x_3) \psi_{24}(x_2, x_4) \psi_{35}(x_3, x_5) \psi_{256}(x_2, x_5, x_6)$



条件随机场模型

- 条件随机场试图对多个变量在给定观测之后的条件概率进行建模
- $\mathbf{x} = \{x_1, x_2, \dots, x_n\}$ 观测序列
- $\mathbf{y} = \{y_1, y_2, \dots, y_n\}$ 为对应的标记序列
- 目标：构建条件概率 $P(\mathbf{y}|\mathbf{x})$
- 图 $G = \langle V, E \rangle$ 表示结点与标记变量 \mathbf{y} 中元素一一对应的无向图， y_v 表示与结点 v 对应的标记变量， $n(v)$ 表示 v 的邻接结点，如果有：


马尔可夫性确保 \mathbf{y} 的依赖关系仅通过图结构表达，避免全连接导致的计算复杂度爆炸

$P(y_v | \mathbf{x}, \mathbf{y}_{V \setminus \{v\}}) = P(y_v | \mathbf{x}, \mathbf{y}_{n(v)})$ ，则 \mathbf{x}, \mathbf{y} 就构成了一个条件随机场

条件随机场模型


• 条件随机场：

- 状态 y 只和相邻状态有关， X 不具有马尔科夫性质，作为一个整体影响 Y




• 线性条件随机场：

- $X = \{X_1, X_2, \dots, X_n\}$, $Y = \{Y_1, Y_2, \dots, Y_n\}$ 线性链表示的随机变量序列
- $P(Y_i | X, Y_1, \dots, Y_{i-1}, Y_{i+1}, \dots, Y_n) = P(Y_i | X, Y_{i-1}, Y_{i+1})$



(a)



(b)

条件随机场模型

• 参数化形式

转移特征函数

状态特征函数

- $P(y|x) = \frac{1}{Z} \exp(\sum_j \sum_{i=1}^{n-1} \lambda_j t_j(y_{i+1}, y_i, x, i) + \sum_k \sum_{i=1}^n \mu_k s_k(y_i, x, i))$
- $Z = \sum_y \exp(\sum_j \sum_{i=1}^{n-1} \lambda_j t_j(y_{i+1}, y_i, x, i) + \sum_k \sum_{i=1}^n \mu_k s_k(y_i, x, i))$

y $\{y_1$ y_2 y_3 y_4 y_5 $y_6\}$

| | | | | | |
|---|---|---|---|---|---|
| D | N | V | P | D | N |
|---|---|---|---|---|---|

$t_j(y_{i+1}, y_i, x, i)$

$$= \begin{cases} 1, & \text{if } y_{i+1} = P, y_i = V \text{ and } x_i = \text{"knock"} \\ 0, & \text{otherwise} \end{cases}$$

x $\{x_1$ x_2 x_3 x_4 x_5 $x_6\}$

$$s_k(y_i, x, i) = \begin{cases} 1, & \text{if } y_i = V \text{ and } x_i = \text{"knock"} \\ 0, & \text{otherwise} \end{cases}$$

条件随机场模型

$$P(y|x) = \frac{1}{Z} \exp\left(\sum_j \sum_{i=1}^{n-1} \lambda_j t_j(y_{i-1}, y_i, x, i) + \sum_k \sum_{i=1}^n \mu_k s_k(y_i, x, i)\right)$$

$$f_k(y_{i-1}, y_i, x, i) = \begin{cases} t_k(y_{i-1}, y_i, x, i), & k = 1, 2, \dots, K_1 \\ s_k(y_i, x, i), & k = K_1 + l, l = 1, 2, \dots, K_2 \end{cases}$$

$$w_k = \begin{cases} \lambda_k, & k = 1, 2, \dots, K_1 \\ \mu_k, & k = K_1 + l, l = 1, 2, \dots, K_2 \end{cases}$$

$$w = \begin{bmatrix} w^1 \\ w^2 \\ \dots \\ w^K \end{bmatrix} \quad F = [f_1, f_2, \dots, f_K]$$

$$p(y|x) = \frac{1}{Z} \exp \sum_{k=1}^K w_k f_k(y, x)$$



$$p(y|x) = \frac{\exp(w \cdot F(y, x))}{Z}$$

向量内积形式

$$Z = \sum_y \exp \sum_k w_k f_k$$

$$Z = \sum_y \exp w \cdot F(y, x)$$

简化形式




条件随机场模型

• 矩阵形式

序列长度

- 引进起点标记 $y_0 = \text{start}$ 和终点标记 $y_{n+1} = \text{stop}$
- 定义 m 阶矩阵随机变量: $M_i(x) = [M_i(y_{i-1}, y_i | x)] \in R^{m \times m}$ (假设 y 有 m 个取值)
m 个状态
- $M_i(y_{i-1}, y_i | x) = \exp(\sum_{k=1}^K w_k f_k(y_{i-1}, y_i, x, i))$



$$M_1(x) = \begin{bmatrix} a_{01} & a_{02} \\ 0 & 0 \end{bmatrix}, \quad M_2(x) = \begin{bmatrix} b_{11} & b_{12} \\ b_{21} & b_{22} \end{bmatrix}$$

$$M_3(x) = \begin{bmatrix} c_{11} & c_{12} \\ c_{21} & c_{22} \end{bmatrix}, \quad M_4(x) = \begin{bmatrix} 1 & 0 \\ 1 & 0 \end{bmatrix}$$

条件随机场模型

• 矩阵形式


• 条件概率矩阵形式:

$$M_1(start, 1|x)M_2(1,2|x)M_3(2,1|x)M_4(1, stop|x)$$

 a_{01}
 b_{12}
 c_{21}
 1

$$P(y|x) = \frac{1}{Z} \prod_{i=1}^{n+1} M_i(y_{i-1}, y_i|x)$$

$$Z = [M_1(x)M_2(x) \cdots M_{n+1}(x)]_{start, stop} \quad \text{从start到stop的所有路径}$$



$$M_1(x) = \begin{bmatrix} a_{01} & a_{02} \\ 0 & 0 \end{bmatrix}, \quad M_2(x) = \begin{bmatrix} b_{11} & b_{12} \\ b_{21} & b_{22} \end{bmatrix}$$

$$M_3(x) = \begin{bmatrix} c_{11} & c_{12} \\ c_{21} & c_{22} \end{bmatrix}, \quad M_4(x) = \begin{bmatrix} 1 & 0 \\ 1 & 0 \end{bmatrix}$$



条件随机场模型


• 矩阵形式

- $Z = [M_1(x)M_2(x) \cdots M_{n+1}(x)]_{start, stop}$ 从start到stop的所有路径

$$M_1 M_2 = \begin{bmatrix} a_{01}b_{11} + a_{02}b_{21} & a_{01}b_{12} + a_{02}b_{22} \\ 0 & 0 \end{bmatrix}$$



$$M_1 M_2 M_3 = \begin{bmatrix} a_{01}b_{11}c_{11} + a_{02}b_{21}c_{11} + a_{01}b_{12}c_{21} + a_{02}b_{22}c_{21} & a_{01}b_{11}c_{12} + a_{02}b_{21}c_{12} + a_{01}b_{12}c_{22} + a_{02}b_{22}c_{22} \\ 0 & 0 \end{bmatrix}$$

$$M_1 M_2 M_3 M_4 = \begin{bmatrix} a_{01}b_{11}c_{11} + a_{02}b_{21}c_{11} + a_{01}b_{12}c_{21} + a_{02}b_{22}c_{21} + a_{01}b_{11}c_{12} + a_{02}b_{21}c_{12} + a_{01}b_{12}c_{22} + a_{02}b_{22}c_{22} & 0 \\ 0 & 0 \end{bmatrix}$$



$$M_1(x) = \begin{bmatrix} a_{01} & a_{02} \\ 0 & 0 \end{bmatrix}, \quad M_2(x) = \begin{bmatrix} b_{11} & b_{12} \\ b_{21} & b_{22} \end{bmatrix}$$

$$M_3(x) = \begin{bmatrix} c_{11} & c_{12} \\ c_{21} & c_{22} \end{bmatrix}, \quad M_4(x) = \begin{bmatrix} 1 & 0 \\ 1 & 0 \end{bmatrix}$$



三个问题



概率计算

- $P(Y_i = y_i | x)$
- $P(Y_i = y_i, Y_{i-1} = y_{i-1} | x)$



学习算法

- 参数估计



预测算法

- 求最大概率的输出序列






概率计算

• 计算

$$[\alpha_1(y_2 = 1), \alpha_1(y_2 = 2), \alpha_1(y_2 = 3)]$$

$$M_2 = \begin{bmatrix} M_2(1,1) & M_2(1,2) & M_2(1,3) \\ M_2(2,1) & M_2(2,2) & M_2(2,3) \\ M_2(3,1) & M_2(3,2) & M_2(3,3) \end{bmatrix}$$



$$\begin{aligned} \alpha_2(y_2 = 1|x) \\ \alpha_2(y_2 = 2|x) \\ \alpha_2(y_2 = 3|x) \end{aligned}$$

$\alpha_2^T(x)$

- 给定条件随机场 $P(Y|X)$, 输入序列 x 和输出序列 y ,
- 计算条件概率: $P(Y_i = y_i|x)$, $P(Y_i = y_i, Y_{i-1} = y_{i-1}|x)$

• 前向向量 $\alpha_i(x)$:



$$\alpha_2^T(y_2 = 2|x) = \sum_j \alpha_1^T(y_1 = j|x) M_i(j, 2|x)$$

- 初始: $\alpha_0(y|x) = \begin{cases} 1, & y = start \\ 0, & otherwise \end{cases}$

m维向量 (m个状态)

- 递推: $\alpha_i^T(x) = \alpha_{i-1}^T(x) M_i(x)$

m*m的矩阵







概率计算

- 后向向量 $\beta_i(x)$:

- 初始: $\beta_{n+1}(y_{n+1}|x) = \begin{cases} 1, & y_{n+1} = stop \\ 0, & otherwise \end{cases}$

- 递推: $\beta_i(x) = M_{i+1}(x)\beta_{i+1}(x)$

- $\beta_i(y_i = k|x) = \sum_j [M_{i+1}(k, j|x)] \beta_{i+1}(y_{i+1} = j|x), i = 1, 2, \dots, n$



概率计算

- 位置是 i 标记为 \mathbf{y}_i 的条件概率

- $P(Y_i = y_i | x) = \frac{\alpha_i^T(y_i | x) \beta_i(y_i | x)}{Z(x)}$

- 位置 $i-1$ 标记为 \mathbf{y}_{i-1} ，位置 i 标记是 \mathbf{y}_i 的条件概率

- $P(Y_{i-1} = y_{i-1}, Y_i = y_i | x) = \frac{\alpha_{i-1}^T(y_{i-1} | x) M_i(y_{i-1}, y_i | x) \beta_i(y_i | x)}{Z(x)}$

- $Z(x) = \alpha_n^T(x) \mathbf{1} = \mathbf{1} \beta_1(x)$





概率计算

- 特征函数 f_k 关于条件分布 $P(Y|X)$ 的数学期望是：

- $E_{P(Y|X)}[f_k] = \sum_y P(y|x) f_k(y, x)$

$$= \sum_{i=1}^{n+1} \sum_{y_{i-1}, y_i} f_k(y_{i-1}, y_i, x, i) \frac{\alpha_{i-1}^T(y_{i-1}|x) M_i(y_{i-1}, y_i|x) \beta_i(y_i|x)}{Z(x)}$$



- $Z(x) = \alpha_n^T(x) \mathbf{1}$





期望

- 设随机变量 X 可以取值为 x_1, x_2, x_3, \dots , 对应的概率分别为 p_1, p_2, p_3, \dots , 那么, X 的数学期望 $E(X)$ 定义为:
 - $E(X) = \sum_i x_i p_i$
 - 描述随机变量在大量重复实验中可能取得的平均值
 - 对随机变量长期表现的一种度量, 反映了随机事件在大量重复发生时的“平均结果”



概率计算

- 特征函数 f_k 关于条件分布 $P(Y|X)$ 的数学期望是:

- $E_{P(Y|X)}[f_k] = \sum_y P(y|x) f_k(y, x)$

$$= \sum_{i=1}^{n+1} \sum_{y_{i-1}, y_i} f_k(y_{i-1}, y_i, x, i) \frac{\alpha_{i-1}^T(y_{i-1}|x) M_i(y_{i-1}, y_i|x) \beta_i(y_i|x)}{Z(x)}$$

- 衡量该特征在模型预测分布中“平均活跃程度”
- 反映了在给定 $P(Y|X)$ 下, 该特征函数在所有可能的 \mathbf{y} 上的平均“激活程度”

假设 \mathbf{x} =[“我”, “爱”, “自然语言处理”], \mathbf{y} 是词性标签序列。
 $f_k(y_{i-1}, y_i, x, i) = I(y_{i-1} = n, y_i = v, x_i = \text{爱})$



- 通过前向-后向算法计算 $P(y_{i-1} = n, y_i = v | \mathbf{x})$ 。
- 期望为 $\sum_i P(y_{i-1} = n, y_i = v | \mathbf{x}) \times 1$ (若 $x_i = \text{“爱”}$)。

若期望较高, 说明模型认为“名词→动词”的转移在“爱”附近很常见



概率计算

- 特征函数 f_k 关于联合分布 $P(X, Y)$ 的数学期望是：
 - $E_{P(X,Y)}[f_k] = \sum_{x,y} P(x, y) f_k$
 - 假设 X 是图像， Y 是类别标签。特征函数 $f_k = I[\mathbf{y} = \text{“猫”} \wedge \text{图像中有胡须}]$ 。
 - 联合期望 $E_{P(X,Y)}[f_k]$ 表示 “图像中有胡须且类别是猫” 的平均概率。
 - 若期望较高，说明模型认为 “胡须” 是 “猫” 类别的重要特征。



概率计算

- 特征函数 f_k 关于联合分布 $P(X, Y)$ 的数学期望是：

- $P(X, Y) = P(Y|X)\tilde{P}(x)$

- $E_{P(X,Y)}[f_k] = \sum_{x,y} P(x, y) \sum_{i=1}^{n+1} f_k(y_{i-1}, y_i, x, i)$

$$= \sum_x \tilde{P}(x) \sum_y P(y|x) \sum_{i=1}^{n+1} f_k(y_{i-1}, y_i, x, i)$$

$$= \sum_x \tilde{P}(x) \sum_{i=1}^{n+1} \sum_{y_{i-1}, y_i} f_k(y_{i-1}, y_i, x, i) \frac{\alpha_{i-1}^T(y_{i-1}|x) M_i(y_{i-1}, y_i|x) \beta_i(y_i|x)}{Z(x)}$$

- $Z(x) = \alpha_n^T(x) \mathbf{1}$



学习算法

- 条件随机场

- $p(y|x) = \frac{1}{Z} \exp \sum_{k=1}^K w_k f_k(y, x)$

- $Z = \sum_y \exp \sum_{k=1}^K w_k f_k(y, x)$

- 学习目标是最大化训练数据上的条件对数似然函数

- $\log P(y|x) = \sum_{j=1}^n [\sum_{k=1}^K w_k f_k(y_j, x_j) - \log Z(x_j)]$





学习算法

- 条件随机场

- $p(y|x) = \frac{1}{Z} \exp \sum_{k=1}^K w_k f_k(y, x)$

- $Z = \sum_y \exp \sum_{k=1}^K w_k f_k(y, x)$

- 学习目标是最大化训练数据上的条件对数似然函数

- $\log P(y|x) = \sum_{j=1}^n [\sum_{k=1}^K w_k f_k(y_j, x_j) - \log Z(x_j)]$

- 定义训练数据的经验分布为: $\tilde{p}(x, y)$

- $L(w) = \sum_{x,y} \tilde{P}(x, y) \sum_{i=1}^n w_i f_i(x, y) - \sum_{x,y} \tilde{P}(x, y) \log Z_w(x)$





学习算法

- 条件随机场

$$\sum_{x,y} \tilde{P}(x,y) = \sum_x \tilde{P}(x)$$

- $\max L(w) = \sum_{x,y} \tilde{P}(x,y) \sum_{i=1}^n w_i f_i(x,y) - \sum_x \tilde{P}(x) \log Z_w(x)$

- 梯度下降法:

- $loss = -\log P(y|x)$

- 改进的迭代尺度法

- 显示使用了训练数据的经验分布 $\max L(w) = \max \sum_{x,y} \tilde{P}(x,y) \log P(y|x)$

- 基本想法: 基于当前参数向量, 寻找新向量, 使得模型的对数似然函数值增大

$$L(w + \delta) - L(w) \geq A(\delta|w) \geq B(\delta|w)$$





学习算法

- 条件随机场

| | 梯度下降 | 改进的迭代尺度法 (IIS) |
|-------------|---------------------|--------------------------|
| 优化目标 | 最大化对数条件似然函数 | 最大化对数条件似然 + 保持特征期望等于经验分布 |
| 使用方法 | 基于梯度信息直接更新参数 (一阶导数) | 基于约束优化, 逐特征更新参数 |
| 特征期望 | 通过梯度差进行调整 | 显式强制匹配经验分布 |
| 是否使用显式的经验分布 | 隐式体现在梯度中 | 显式作为迭代中的约束 |





学习算法

- 条件随机场

- $\max L(w) = \sum_{x,y} \tilde{P}(x,y) \sum_{i=1}^n w_i f_i(x,y) - \sum_x \tilde{P}(x) \log Z_w(x)$

- 梯度下降法 $\theta^{t+1} = \theta^t - \eta \nabla L(\theta^t)$

- 改进的迭代尺度法

- 拟牛顿法

- $loss = -\log P(y|x)$

- 一种高效的二阶优化方法，使用近似的Hessian矩阵信息，提高收敛速度

- $\theta^{t+1} = \theta^t - \eta H^{-1} \nabla L(\theta^t)$, H^{-1} 是梯度变化和参数变化构造出的近似Hessian逆





学习算法

- 条件随机场

- 小规模: **IIS**
- 中等规模、精度优先: **L-BFGS**
- 大数据、在线训练: **SGD / Adam**

| | 梯度下降 | 改进的迭代尺度法 (IIS) | 拟牛顿法 |
|-------------|---------------------|--------------------------|------------------------|
| 优化目标 | 最大化对数条件似然函数 | 最大化对数条件似然 + 保持特征期望等于经验分布 | 最大化对数条件似然函数 |
| 使用方法 | 基于梯度信息直接更新参数 (一阶导数) | 基于约束优化, 逐特征更新参数 | 一阶导数 + 拟合二阶导数 (近似海森矩阵) |
| 特征期望 | 通过梯度差进行调整 | 显式强制匹配经验分布 | 通过梯度差进行调整 |
| 是否使用显式的经验分布 | 隐式体现在梯度中 | 显式作为迭代中的约束 | 隐式使用 |





预测算法

- 目标: $\mathbf{y}^* = \operatorname{argmax}_y \mathbf{P}_w(\mathbf{y}|\mathbf{x})$

$$= \operatorname{argmax}_y \frac{\exp(w \cdot F(\mathbf{y}, \mathbf{x}))}{Z_w(\mathbf{x})}$$

- **维特比算法**: 求**非规范化**概率最大的最优路径问题 $\max_y (w \cdot F(\mathbf{y}, \mathbf{x}))$
- $\max_y (w \cdot F(\mathbf{y}, \mathbf{x})) = \max_y \sum_{i=1}^n w \cdot F_i(y_{i-1}, y_i, \mathbf{x})$





预测算法

- 输入：特征向量 $F(y, x)$ ，权值向量 w ，观测序列： $x = (x_1, x_2, \dots, x_n)$
- 输出：最优路径 $y^* = (y_1^*, y_2^*, \dots, y_n^*)$
- 初始
 - $\delta_1(j) = w \cdot F_1(y_0 = start, y_1 = j, x), \quad j = 1, 2, \dots, m$
- 递推
 - $\delta_i(l) = \max_{1 \leq j \leq m} \{\delta_{i-1}(j) + w \cdot F_i(y_{i-1} = j, y_i = l, x)\}, \quad l = 1, 2, \dots, m$
 - $\psi_i(l) = \arg \max_{1 \leq j \leq m} \{\delta_{i-1}(j) + w \cdot F_i(y_{i-1} = j, y_i = l, x)\}, \quad l = 1, 2, \dots, m$



预测算法

- 终止



- $\max_y (w \cdot F(y, x)) = \max_{1 \leq j \leq m} \delta_n(j)$

- $y_n^* = \arg \max_{1 \leq j \leq m} \delta_n(j)$

- 返回路径

- $y_n^* = \psi_{i+1}(y_{i+1}^*), i = n - 1, n - 2, \dots, 1$

- 最优路径: $y^* = (y_1^*, y_2^*, \dots, y_n^*)$



预测算法

- 例 设有一标注问题，输入观测序列为 $X = (X_1, X_2, X_3)$ ，输出标记序列为 $Y = (Y_1, Y_2, Y_3)$ ， $Y_1, Y_2, Y_3 \in \{1, 2\}$
- 特征定义：

$$t_1(y_{i-1} = 1, y_i = 2, x, i) = 1 \quad (i = 2, 3)$$

$$t_2(y_1 = 1, y_2 = 1, x, 2) = 1$$

$$t_3(y_2 = 2, y_3 = 1, x, 3) = 1$$

$$t_4(y_1 = 2, y_2 = 1, x, 2) = 1$$

$$t_5(y_2 = 2, y_3 = 2, x, 3) = 1$$

$$\lambda_1 = 1$$

$$\lambda_2 = 0.6$$

$$\lambda_3 = 1$$

$$\lambda_4 = 1$$

$$\lambda_5 = 0.2$$

$$s_1(y_1 = 1, x, 1) = 1$$

$$s_2(y_i = 2, x, i) = 1, i = 1, 2$$

$$s_3(y_i = 1, x, i) = 1, i = 2, 3$$

$$s_4(y_3 = 2, x, 3) = 1$$

$$\mu_1 = 1$$

$$\mu_2 = 0.5$$

$$\mu_3 = 0.8$$

$$\mu_4 = 0.5$$

预测算法

• 初始

$$\bullet \delta_1(j) = w \cdot F_1(y_0 = start, y_1 = j, x), \quad j = 1, 2, \dots, m$$

| | |
|--|-------------------|
| $t_1(y_{i-1} = 1, y_i = 2, x, i) = 1 \quad (i = 2, 3)$ | $\lambda_1 = 1$ |
| $t_2(y_1 = 1, y_2 = 1, x, 2) = 1$ | $\lambda_2 = 0.6$ |
| $t_3(y_2 = 2, y_3 = 1, x, 3) = 1$ | $\lambda_3 = 1$ |
| $t_4(y_1 = 2, y_2 = 1, x, 2) = 1$ | $\lambda_4 = 1$ |
| $t_5(y_2 = 2, y_3 = 2, x, 3) = 1$ | $\lambda_5 = 0.2$ |

| | |
|------------------------------------|---------------|
| $s_1(y_1 = 1, x, 1) = 1$ | $\mu_1 = 1$ |
| $s_2(y_i = 2, x, i) = 1, i = 1, 2$ | $\mu_2 = 0.5$ |
| $s_3(y_i = 1, x, i) = 1, i = 2, 3$ | $\mu_3 = 0.8$ |
| $s_4(y_3 = 2, x, 3) = 1$ | $\mu_4 = 0.5$ |

$$\bullet \delta_1(1) = w \cdot F_1(y_0 = start, y_1 = 1, x) = 1 \times 1 = 1$$

$$\bullet \delta_1(2) = w \cdot F_1(y_0 = start, y_1 = 2, x) = 1 \times 0.5 = 0.5$$



预测算法

递推

| | |
|--|-------------------|
| $t_1(y_{i-1} = 1, y_i = 2, x, i) = 1 \quad (i = 2, 3)$ | $\lambda_1 = 1$ |
| $t_2(y_1 = 1, y_2 = 1, x, 2) = 1$ | $\lambda_2 = 0.6$ |
| $t_3(y_2 = 2, y_3 = 1, x, 3) = 1$ | $\lambda_3 = 1$ |
| $t_4(y_1 = 2, y_2 = 1, x, 2) = 1$ | $\lambda_4 = 1$ |
| $t_5(y_2 = 2, y_3 = 2, x, 3) = 1$ | $\lambda_5 = 0.2$ |

| | |
|------------------------------------|---------------|
| $s_1(y_1 = 1, x, 1) = 1$ | $\mu_1 = 1$ |
| $s_2(y_i = 2, x, i) = 1, i = 1, 2$ | $\mu_2 = 0.5$ |
| $s_3(y_i = 1, x, i) = 1, i = 2, 3$ | $\mu_3 = 0.8$ |
| $s_4(y_3 = 2, x, 3) = 1$ | $\mu_4 = 0.5$ |

$$\delta_i(l) = \max_{1 \leq j \leq m} \{ \delta_{i-1}(j) + w \cdot F_i(y_{i-1} = j, y_i = l, x) \}, \quad l = 1, 2, \dots, m$$

➤ $i = 2$

$$\{ \mathbf{1} + \mathbf{0.6} + \mathbf{0.8}, \mathbf{0.5} + \mathbf{1} + \mathbf{0.8} \}$$

$$\begin{aligned} &\delta_1(1) + wF_2(y_1 = 1, y_2 = 1, x) \\ &\delta_1(2) + wF_2(y_1 = 2, y_2 = 1, x) \end{aligned}$$

$$\delta_2(1) = \max_{1 \leq j \leq 2} \{ \delta_1(j) + w \cdot F_2(y_1 = j, y_2 = 1, x) \} = 2.4$$

$$\psi_2(1) = 1$$

$$\delta_2(2) = \max_{1 \leq j \leq 2} \{ \delta_1(j) + w \cdot F_2(y_1 = j, y_2 = 2, x) \} = 2.5$$

$$\psi_2(2) = 1$$

$$\begin{aligned} &\delta_1(1) + wF_2(y_1 = 1, y_2 = 2, x) \\ &\delta_1(2) + wF_2(y_1 = 2, y_2 = 2, x) \end{aligned}$$

$$\{ \mathbf{1} + \mathbf{1} + \mathbf{0.5}, \mathbf{0.5} + \mathbf{0.5} \}$$

$$\{ \mathbf{2.4} + \mathbf{0.8}, \mathbf{2.5} + \mathbf{1} + \mathbf{0.8} \}$$

$$\begin{aligned} &\delta_2(1) + wF_3(y_2 = 1, y_3 = 1, x) \\ &\delta_2(2) + wF_3(y_2 = 2, y_3 = 1, x) \end{aligned}$$

➤ $i = 3$

$$\delta_3(1) = \max_{1 \leq j \leq 2} \{ \delta_2(j) + w \cdot F_3(y_2 = j, y_3 = 1, x) \} = 4.3$$

$$\psi_3(1) = 2$$

$$\delta_3(2) = \max_{1 \leq j \leq 2} \{ \delta_2(j) + w \cdot F_3(y_2 = j, y_3 = 2, x) \} = 3.9$$

$$\{ \mathbf{2.4} + \mathbf{1} + \mathbf{0.5}, \mathbf{2.5} + \mathbf{0.2} + \mathbf{0.5} \} \quad \psi_3(2) = 1$$

$$\begin{aligned} &\delta_2(1) + wF_3(y_2 = 1, y_3 = 3, x) \\ &\delta_2(2) + wF_3(y_2 = 2, y_3 = 3, x) \end{aligned}$$

预测算法

- 终止

- $\delta_3(1) = \max_{1 \leq j \leq 2} \{\delta_2(j) + w \cdot F_3(y_2 = j, y_3 = 1, x)\} = 4.3$

$$\psi_3(1) = 2$$

- $\delta_3(2) = \max_{1 \leq j \leq 2} \{\delta_2(j) + w \cdot F_3(y_2 = j, y_3 = 2, x)\} = 3.9$

$$\psi_3(2) = 1$$



- $y_3^* = 1$

- 最优路径

- $y_2^* = \psi_3(1) = 2$

- $y_1^* = \psi_2(2) = 1$

- $y^* = (1, 2, 1)$





课堂练习

利用条件随机场进行词性标注。假设词性有名词n，动词v，代词p，定义特征函数及相应权重如下：

| | 函数条件 | 权重 |
|----|--|-----|
| t1 | =1 ($y_{t-1} = n, y_t = v$) =0 其它 | 0.6 |
| t2 | =1 ($y_{t-1} = p, y_t = n$) =0 其它 | 0.8 |
| t3 | =1 ($y_{t-1} = v, y_t = n$) =0 其它 | 0.5 |
| s1 | =1 ($y_t = n, x_t = \text{人名}$) =0 其它 | 0.9 |
| s2 | =1 ($y_t = n, x_t = \text{地点}$) =0 其它 | 0.9 |
| s3 | =1 ($y_t = p, x_t = at$) =0 其它 | 0.7 |

请对 “Bob drank coffee at Starbucks”
进行词性标注（给出具体计算过程）

