



期中复习

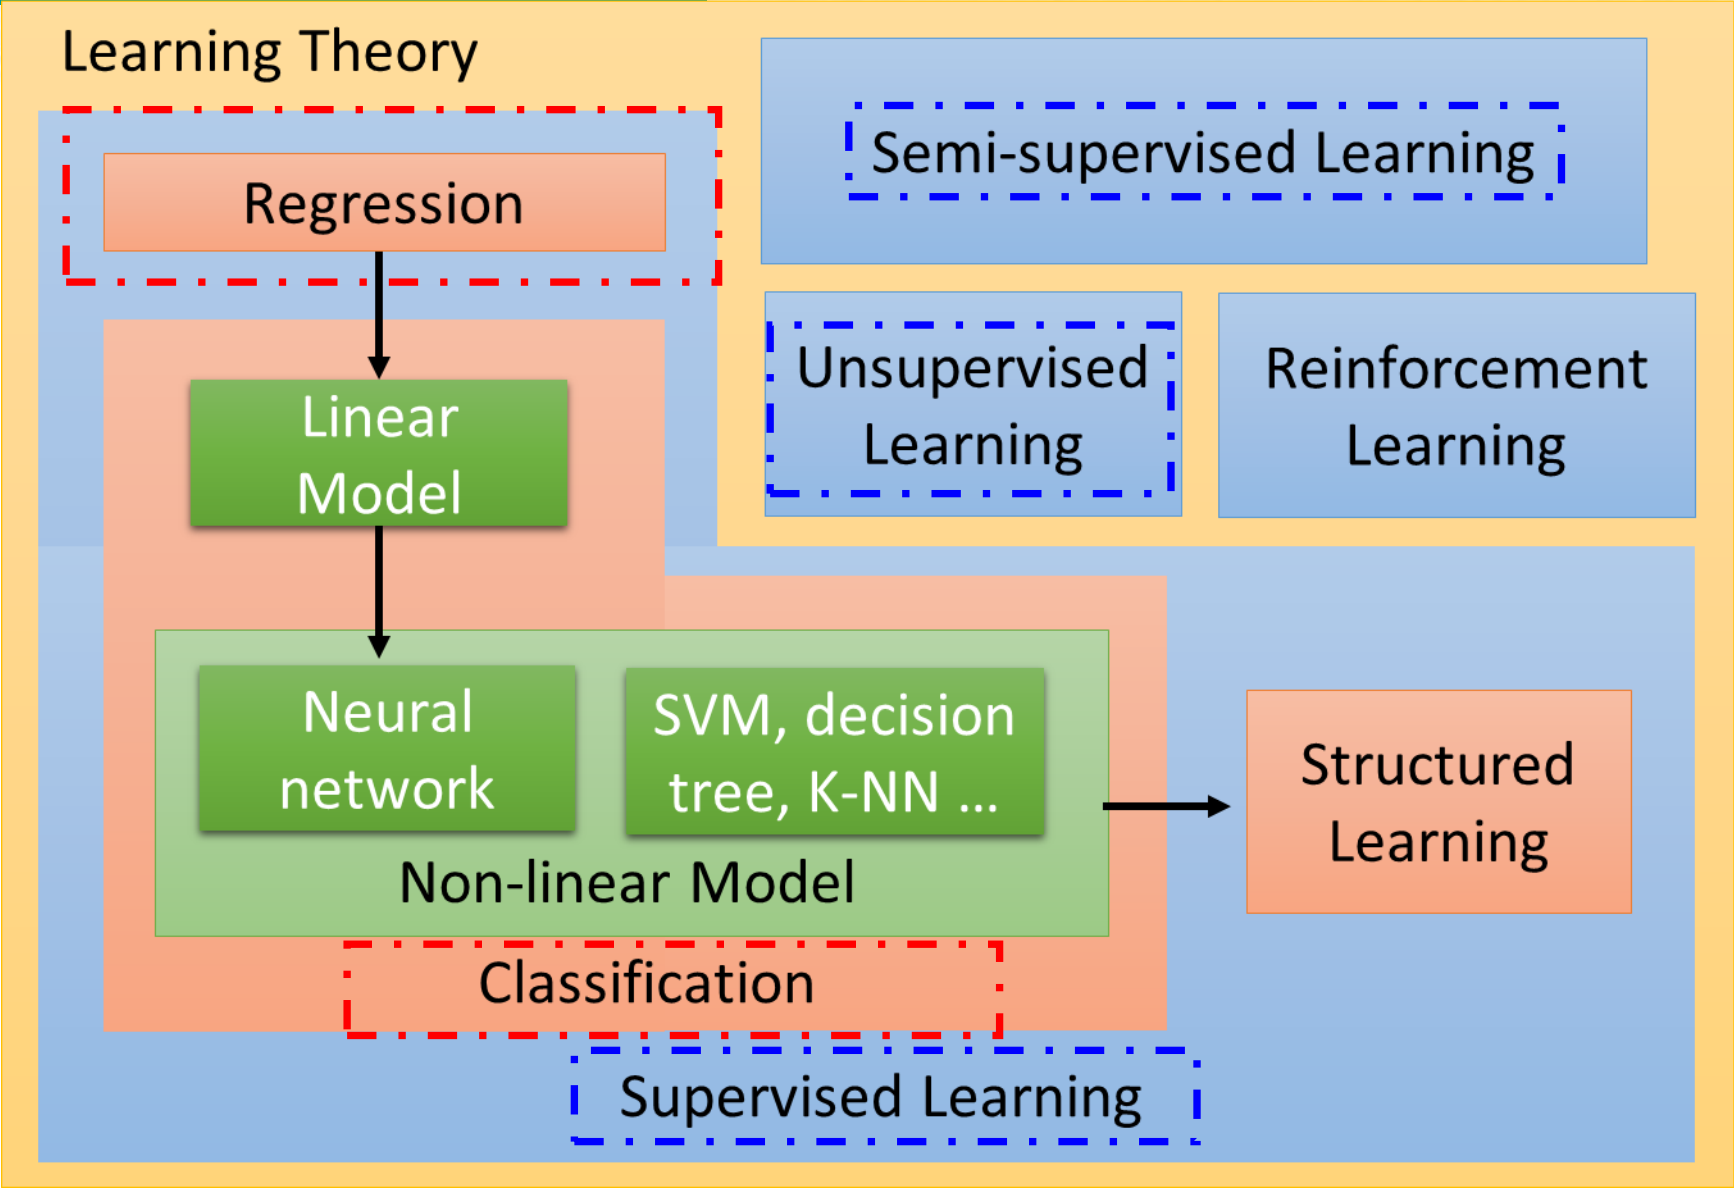
2025年4月11日

期中考试

- 时间：4月18日 9:55-11:30
- 题型：
 - 填空（30分）
 - 简单（10分）
 - 综合题（60分）
- 闭卷，允许带计算器
- 考试范围：
 - 以下ppt提到的相关内容

机器学习

scenario task method



回归/预测



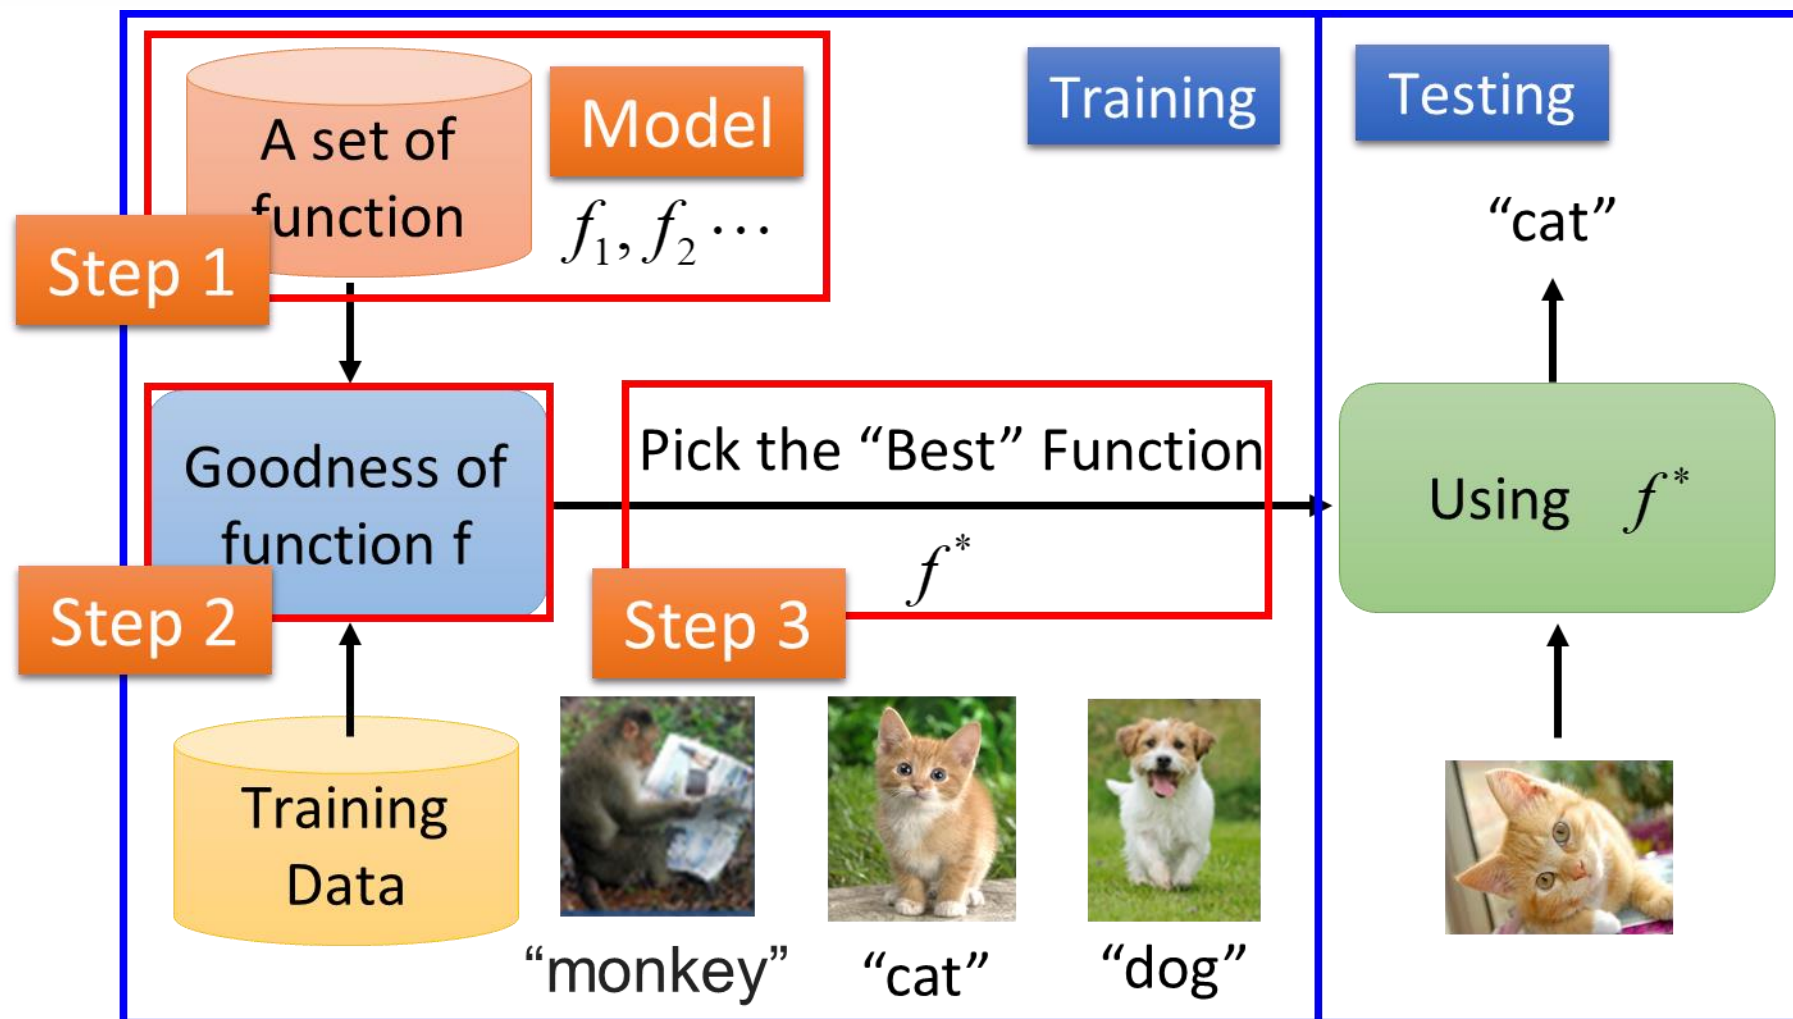
路段流量预测
空气质量预测
生成产量预测
股票、房价预测
.....

分类



文本分类
情感分类
图像分类
序列标注
.....

机器学习



基本要素

- 方法 = 模型 + 策略 + 算法
- 模型：学习什么样的模型？
- 策略：按照什么准则学习或选择最优的模型？
 - 定义损失函数：
 - $L = \frac{1}{N} \sum_{i=1}^N (f(x_i) - y_i)^2$
 - $L = \frac{1}{N} \sum_{i=1}^N \sum_{k=1}^C y_{i,k} \log f_k(x_i)$
- 算法：学习模型的具体计算方法

基本要素

- 算法：学习模型的具体计算方法

- 梯度下降 $w^*, b^* = \arg \min_{w, b} L(w, b)$

- (Randomly) Pick an initial value w^0, b^0

- Compute $\frac{\partial L}{\partial w} \big|_{w=w^0, b=b^0}, \frac{\partial L}{\partial b} \big|_{w=w^0, b=b^0}$

$$w^1 \leftarrow w^0 - \eta \frac{\partial L}{\partial w} \big|_{w=w^0, b=b^0} \quad b^1 \leftarrow b^0 - \eta \frac{\partial L}{\partial b} \big|_{w=w^0, b=b^0}$$

- Compute $\frac{\partial L}{\partial w} \big|_{w=w^1, b=b^1}, \frac{\partial L}{\partial b} \big|_{w=w^1, b=b^1}$

$$w^2 \leftarrow w^1 - \eta \frac{\partial L}{\partial w} \big|_{w=w^1, b=b^1} \quad b^2 \leftarrow b^1 - \eta \frac{\partial L}{\partial b} \big|_{w=w^1, b=b^1}$$

过拟合

- 模型对已知数据预测很好，对未知数据预测很差

- 增加训练集数量

- 正则化


$$L(w) = \frac{1}{2} \sum_{i=1}^N (f(x_i, w) - y_i)^2 + \frac{\lambda}{2} \|w\|_2^2$$

$$L(w) = \frac{1}{2} \sum_{i=1}^N (f(x_i, w) - y_i)^2 + \lambda \|w\|_1$$

控制模型预测准确性

控制模型复杂度

l2范式: $\|w\|_2^2 = w_1^2 + w_2^2 + \dots + w_d^2$
l1范式: $\|w\|_1 = |w_1| + |w_2| + \dots + |w_d|$



Model

线性回归

感知机

逻辑回归

支持向量机

K近邻&聚类

PCA

贝叶斯方法

Model

线性回归

$$Y = w^T X + b$$
$$Y \in R^{1 \times N} \quad w \in R^{d \times 1}$$
$$X \in R^{d \times N} \quad b \in R^{1 \times N}$$

$$L(w, b) = \sum_{i=1}^N \left((w^T x^i + b) - y^i \right)^2$$

梯度下降

Model

感知机

决策函数

$$f(x) = \text{sign}(w^T x + b)$$

线性可分数据集

误分类点驱动

随机梯度下降

输入：特征向量

输出：实例的类别，取+1和-1二值

误分类点到超平面的距离

$$L(w, b) = - \sum_{x_i \in M} y_i (w^T x_i + b)$$

$$y_i (w^T x_i + b) \leq 0$$

感知机学习算法

- 已知训练数据集，正实例点是 $x_1=(3,3)^T$, $x_2=(4,2)^T$, 负实例点是 $x_3=(1,1)^T$, $x_4=(2,0)^T$, 用原始形式求出感知机模型决策函数 $f=\text{sign}(wx+b)$, 按照例题形式给出过程

$$\begin{aligned} (0,0) + 1 \times 1 \times (3,3) &= (3,3) \\ 0 + 1 \times 1 &= 1 \\ f(x) &= 3x_1 + 3x_2 + 1 \\ \text{对于 } x_3: \quad 3 \times 1 + 3 \times 1 + 1 &= 7 > 0 \quad \text{误分} \\ (3,3) - 1 \times 1 \times (1,1) &= (2,2) \\ 1 - 1 \times 1 &= 0 \\ f(x) &= 2x_1 + 2x_2 + 0 \\ \text{对于 } x_3: \quad 2 \times 1 + 2 \times 1 + 0 &= 4 > 0 \quad \text{误分} \\ (2,2) - 1 \times 1 \times (1,1) &= (1,1) \\ 0 - 1 \times 1 &= -1 \\ f(x) &= x_1 + x_2 - 1 \\ &\vdots \end{aligned}$$

$$\begin{array}{cccc} & & +1 & -1 \\ & (3,3) & (4,2) & (1,1) & (2,0) \\ y=1 & & & & \\ x_1 & (3,3) & 1 & 3x_1+3x_2+1 \\ x_2 & (2,2) & 0 & 2x_1+2x_2+0 \\ x_3 & (1,1) & -1 & x_1+x_2-1 \\ x_4 & (0,0) & -2 & -2 \\ x_1 & (3,3) & -1 & 3x_1+3x_2-1 \\ x_2 & (2,2) & -2 & 2x_1+2x_2-2 \\ x_3 & (1,1) & -3 & x_1+x_2-3 \end{array}$$

Model

~~线性回归~~


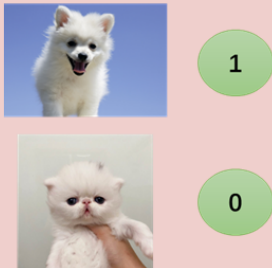
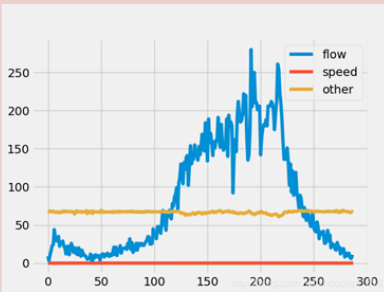
逻辑

$$Y = \mathbf{w}^T \mathbf{X} + b \quad \Rightarrow \quad f_{\mathbf{w},b}(\mathbf{X}) = \frac{1}{1 + \exp(-(\mathbf{w}^T \mathbf{X} + b))}$$

$$L(\mathbf{w}, b) = \sum_{i=1}^N \left((\mathbf{w}^T \mathbf{x}^i + b) - y^i \right)^2 \quad \Rightarrow \quad L(\mathbf{w}, b) = \sum_n - \left[y^i \ln f_{\mathbf{w},b}(\mathbf{x}^i) + (1 - y^i) \ln (1 - f_{\mathbf{w},b}(\mathbf{x}^i)) \right]$$

梯度下降

Model

	感知机	逻辑回归	线性回归
训练数据格式	<p>Dog recognition</p> 	<p>Dog recognition</p> 	
决策函数	$f = \text{sign}(wx + b)$	$f = \frac{1}{1 + e^{-(wx+b)}}$	$y = wx + b$
损失函数	$l = - \sum_{x_i \in M} y_i (wx_i + b)$	$l = - \sum_{i=1}^N [y_i \ln f(x_i) + (1 - y_i) \ln(1 - f(x_i))]$	$l = \sum_{i=1}^N [f(x_i) - y_i]^2$
训练结果	模型输出为+1/-1 直接给出类别标签	模型输出为(0,1) 根据阈值0.5进行判断， 大于0.5属于类别1，小 于0.5属于类别0	模型输出预测值

Model

支持向量机

决策函数

$$f(x) = \text{sign}(w^T x + b)$$

通过寻求结构化风险最小来提高学习机的泛化能力

在特征空间上的间隔最大的线性分类器

$$\min_{w,b} \frac{1}{2} \|w\|^2$$

$$\text{s.t. } y_i(w x_i + b) - 1 \geq 0, \quad i = 1, 2, \dots, N$$



$$L = \frac{1}{2} \|w\|^2 + \sum_{i=1}^N \alpha_i (1 - y^i(w \cdot x^i + b)), \quad \alpha_i \geq 0$$

原问题 $\min_x \max_{\alpha, \beta} L(x, \alpha, \beta)$



对偶问题 $\max_{\alpha_i \geq 0} (\min_{b, w} L(w, b, \alpha))$

Model

支持向量机

$$L = \frac{1}{2} ||\mathbf{w}||^2 + \sum_{i=1}^N \alpha_i (1 - y^i (\mathbf{w} \cdot \mathbf{x}^i + b)), \quad \alpha_i \geq 0$$

对偶问题 $\max_{\alpha_i \geq 0} (\min_{b, \mathbf{w}} L(\mathbf{w}, b, \alpha))$

$$\frac{\partial L}{\partial w_j} = w_j - \sum_{i=1}^N \alpha_i y^i x_j^i = 0 \quad w_j = \sum_{i=1}^N \alpha_i y^i x_j^i$$

$$\frac{\partial L}{\partial b} = \sum_{i=1}^N \alpha_i y^i = 0$$

$$\min_{\alpha} L = \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y^i y^j (\mathbf{x}^i \cdot \mathbf{x}^j) - \sum_{i=1}^N \alpha_i$$
$$\sum_{i=1}^N \alpha_i y^i = 0, \quad \alpha_i \geq 0$$

Model

支持向量机

线性可分支持向量

线性支持向量

非线性支持向量

$$\min_{w,b} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i$$

$$\text{s.t. } y_i(wx_i + b) \geq 1 - \xi_i, \\ i = 1, 2, \dots, N$$

决策函数

$$f(x) = \text{sign}(w^T \Phi(x) + b)$$

$$f(x) = \text{sign} \left(\sum_{i=1}^N \alpha^* y_i K(x, x_i) + b^* \right)$$

$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j K(x_i, x_j) - \sum_{i=1}^N \alpha_i$$
$$\text{s.t. } \sum_{i=1}^N \alpha_i y_i = 0 \\ 0 \leq \alpha_i \leq C$$

支持向量机

- 求解
- 参见例题7.2
 - 正实例 $\mathbf{x}_1 = (3, 3)^T$, $\mathbf{x}_2 = (4, 3)^T$, 负实例 $\mathbf{x}_3 = (1, 1)^T$, 求线性支持向量机

K近邻

➤ KNN的学习过程

- Lazing learning
- 投票原则
- 距离度量

欧氏距离:

$$L_2(x_i, x_j) = \left(\sum_{l=1}^d |x_i^{(l)} - x_j^{(l)}|^2 \right)^{\frac{1}{2}}$$

聚类

对大量未标注的数据集，按数据的内在相似性将数据集进行划分，形成多个簇，使得内部数据相似度尽可能大而类别间的数据相似度尽可能小

K-means

通过迭代把数据集划分为不同的类别，使得评价聚类性能的准则函数达到最优，使得每个聚类类内紧凑，类间独立

层次聚类



层次对数据集进行划分，从而形成树形的聚类结构
参见例题14.1

Model

PCA

用于高维数据的降维。提取数据的主要特征分量

通过正交变换将原始数据转换到新的坐标系中



最大可分性——方差最大

目标：方差最大化

通过选择方差最大的方向作为第一主成分

—— 通过特征分解，找到特征向量

—— 每一个特征向量均为一个一维基

Model

$$\text{后验概率计算: } P(B_i|A) = \frac{P(A|B_i)P(B_i)}{P(A)} = \frac{P(A|B_i)P(B_i)}{\sum_{j=1}^N P(A|B_j)P(B_j)}$$

贝叶斯方法

朴素贝叶斯

前提：贝叶斯定理和特征条件独立
 $f(x) = \operatorname{argmax} P(c) \prod_{i=1}^d P(x_i|c)$

参见课堂例题，例4.1

贝叶斯网络

有向无环图+条件概率表

参见课堂例题，课堂作业（提交有答案）

预测

推理