




第八节：图像分割

杨聪






目录

CONTENTS

1. 图像分割概述
2. K-means聚类
3. 语义分割
4. 实例分割
5. 全景分割



图像分割概述

什么是图像分割

顾名思义，这是将一个图像分割成多个片段的过程。在这个过程中，图像中的每个像素都与一个对象类型相关联。

图像分割分类

图像中的内容一般可以分为两类：**things**和**stuff**

- things是可计数的实例目标，有很多个，例如，人和车，每个实例都有一个唯一的id来区分
- stuff指的是无定形的区域，一般最多只有一个，如天空、草地和雪，没有实例id



Semantic Segmentation

语义分割



Instance Segmentation

实例分割



Panoptic Segmentation

全景分割

图像分割概述

什么是图像分割

顾名思义，这是将一个图像分割成多个片段的过程。在这个过程中，图像中的每个像素都与一个对象类型相关联。

图像分割分类

语义分割：同一类型的所有对象都使用一个类标签进行标记，如道路、天空、草地等，关注"stuff"部分

实例分割：相似的对象使用各自独立的标签，如人1，人2，车1，车2，关注"things"部分

全景分割：结合语义分割和实例分割的综合方法，为图像中每个像素分配一个语义标签和唯一的实例标识符



Semantic Segmentation

语义分割



Instance Segmentation

实例分割



Panoptic Segmentation

全景分割

图像分割概述

图像处理技术	方法简介	备注
语义分割	为图像中的每个像素分配特定类别标签	关注的是图像中的"stuff"部分
实例分割	在图像中检测并区分不同的物体实例	关注的是图像中的 thing 分
全景分割	结合了语义分割和实例分割的综合方法	同时关注"things"和"stuff"两部分



Semantic Segmentation

语义分割



Instance Segmentation

实例分割



Panoptic Segmentation

全景分割

K-means聚类

K-means聚类原理

K-Means聚类是最常用的聚类算法，最初起源于信号处理，其目标是**将数据点划分为K个类簇，找到每个簇的中心并使其度量最小化。**

优点：简单、便于理解，运算速度较快

缺点：只能应用于连续型数据，并且要在聚类前指定聚集的类簇数

第一步，确定K值，即将数据集聚集成K个类簇或小组。


第二步，从数据集中随机选择K个数据点作为质心（Centroid）或数据中心。

第三步，分别计算每个点到每个质心之间的距离，并将每个点划分到离最近质心的小组，跟定了那个质心。

第四步，当每个质心都聚集了一些点后，重新定义算法选出新的质心。

第五步，比较新的质心和老的质心，如果新质心和老质心之间的距离小于某一个阈值，则表示重新计算的质心位置变化不大，收敛稳定，则认为聚类已经达到了期望的结果，算法终止。

第六步，如果新的质心和老的质心变化很大，即距离大于阈值，则继续迭代执行第三步到第五步，直到算法终止。



K-means聚类

在图像处理中，通过K-Means聚类算法可以实现图像分割、图像聚类、图像识别等操作，本小节主要用来进行图像颜色分割。

假设存在一张 100×100 像素的灰度图像，它由10000个RGB灰度级组成，我们通过K-means可以将这些像素点聚类成K个簇，然后使用每个簇内的质心点来替换簇内所有的像素点，这样就能实现在不改变分辨率的情况下量化压缩图像颜色，实现图像颜色层级分割。

在OpenCV中，kmeans()函数原型如下所示：

retval, bestLabels, centers = kmeans(data, K, bestLabels, criteria, attempts, flags[, centers])

- **data**表示聚类数据，最好是np.float32类型的N维点集
- **K**表示聚类类簇数
- **bestLabels**表示输出的整数数组，用于存储每个样本的聚类标签索引
- **criteria**表示算法终止条件，即最大迭代次数或所需精度。在某些迭代中，一旦每个簇中心的移动小于criteria.epsilon，算法就会停止
- **attempts**表示重复试验kmeans算法的次数，算法返回产生最佳紧凑性的标签
- **flags**表示初始中心的选择，两种方法是cv2.KMEANS_PP_CENTERS；cv2.KMEANS_RANDOM_CENTERS
- **centers**表示集群中心的输出矩阵，每个集群中心为一行数据

下面一起来看：k_means_gray.py以及k_means_rgb.py



语义分割 (Semantic Segmentation)

语义分割研究图像中的无法计数的物体。它分析每个图像像素，并根据它所代表的纹理分配一个唯一的类别标签。例如，在下图中，一张图像包含1辆小汽车、1辆估公交车、2个骑自行车的行人、一条道路和天空。这2个骑自行车的行人代表相同的纹理。




相同的物体具有相同的类别标签

语义分割会为每个纹理或类别分配唯一的类别标签。然而，语义分割的输出不能将这两辆汽车或两个行人分开区分或计数。

语义分割 (Semantic Segmentation)

常用的语义分割技术包括SegNet、U-Net、DeconvNet, FCNs, DeepLab





语义分割 (Semantic Segmentation) - SegNet

IEEE TRANSACTIONS ON PATTERN ANALYSIS AND MACHINE INTELLIGENCE, VOL. 39, NO. 12, DECEMBER 2017

2481

SegNet: A Deep Convolutional Encoder-Decoder Architecture for Image Segmentation

Vijay Badrinarayanan, Alex Kendall^{ID}, and Roberto Cipolla, *Senior Member, IEEE*

Abstract—We present a novel and practical deep fully convolutional neural network architecture for semantic pixel-wise segmentation termed SegNet. This core trainable segmentation engine consists of an encoder network, a corresponding decoder network followed by a pixel-wise classification layer. The architecture of the encoder network is topologically identical to the 13 convolutional layers in the VGG16 network [1]. The role of the decoder network is to map the low resolution encoder feature maps to full input resolution feature maps for pixel-wise classification. The novelty of SegNet lies in the manner in which the decoder upsamples its lower resolution input feature map(s). Specifically, the decoder uses pooling indices computed in the max-pooling step of the corresponding encoder to perform non-linear upsampling. This eliminates the need for learning to unsample. The unsampled maps are sparse and are then

Segnet: A deep convolutional encoder-decoder architecture for image segmentation


[PDF] [ieee.org](#)

[V Badrinarayanan, A Kendall...](#) - IEEE transactions on ..., 2017 - [ieeexplore.ieee.org](#)

... Our motivation to design **SegNet** arises from this need to map low resolution ... **SegNet** architecture and its analysis in Section 3. In Section 4 we evaluate the performance of **SegNet** ...

☆ Save 99 Cite Cited by 16817 Related articles All 12 versions


语义分割（Semantic Segmentation） - SegNet



SegNet是一种用于图像语义分割的深度卷积神经网络，其网络结构主要由编码器（Encoder）和解码器（Decoder）组成。

该网络改编了VGG16，去掉了最后的全连接层，保留了13个卷积层，正好组成了编码器网络，也就是说左侧有5个编码块（蓝色卷积层）。每个块经过最大池化层（绿色池化层）进行降采样，输送到右边，然后对特征图进行上采样（红色反池化层），经过上采样后再经过解码块（右侧的蓝色卷积层），也就是再通过卷积层进行解码，最后解码器输出特征映射被送入Softmax分类器进行像素级分类，形成了一个完全对称的编码-解码结构。


语义分割（Semantic Segmentation） - SegNet



编码器（Encoder）部分：

- 编码器由多个卷积层和池化层交替堆叠而成。每个卷积层通常包括卷积操作、激活函数（如ReLU）和批量归一化（Batch Normalization）。
- 卷积层的作用是逐渐提取图像的特征信息。随着网络的深入，特征图的尺寸逐渐减小，通道数逐渐增加。
- 池化层用于降低特征图的空间尺寸，并提取更加抽象的特征。SegNet使用最大池化（Max Pooling）来保留主要的特征，并记录池化区域的最大值索引（pooling indices）。


语义分割（Semantic Segmentation） - SegNet



解码器（Decoder）部分：

- 解码器部分与编码器相对应，由多个反池化层和卷积层堆叠而成。
- 反池化层（unpooling）用于进行上采样操作，将低分辨率的特征图映射回原始输入图像的分辨率。SegNet使用pooling indices来进行上采样操作，根据索引将池化区域的最大值插入到相应的位置上。
- 解码器中的卷积层通过学习卷积核权重，进一步提取特征并减少通道数。


语义分割（Semantic Segmentation） - SegNet



解码器（Decoder）部分：

- 解码器部分与编码器相对应，由多个反池化层和卷积层堆叠而成。
- 反池化层（unpooling）用于进行上采样操作，将低分辨率的特征图映射回原始输入图像的分辨率。SegNet使用pooling indices来进行上采样操作，根据索引将池化区域的最大值插入到相应的位置上。
- 解码器中的卷积层通过学习卷积核权重，进一步提取特征并减少通道数。

语义分割 (Semantic Segmentation) - UNet



[Home](#) > [Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015](#) > [Conference paper](#)

U-Net: Convolutional Networks for Biomedical Image Segmentation

[Olaf Ronneberger](#) [Philipp Fischer](#) & [Thomas Brox](#)

Conference paper | [First Online: 18 November 2015](#)

128k Accesses | **18035** Citations | **80** Altmetric

Part of the [Lecture Notes in Computer Science](#) book series (LNIP, volume 9351)


U-net: Convolutional networks for biomedical image segmentation

[O Ronneberger](#), [P Fischer](#), [T Brox](#) - ... [Image Computing and Computer ...](#), 2015 - Springer

... We demonstrate the application of the **u-net** to three different **segmentation** tasks. The first task is the **segmentation** of neuronal structures in electron microscopic recordings. An ...

☆ Save Cite Cited by **73592** [Related articles](#) [All 31 versions](#)

语义分割 (Semantic Segmentation) - UNet



U-Net是最初用于分割生物医学图像的卷积神经网络。可视化时，其架构看起来像字母U，因此名称为U-Net。

它的体系结构由两部分组成，左边部分是收缩路径，右边部分是扩展路径。收缩路径的目的是捕获上下文，而扩展路径的作用是帮助精确定位。



语义分割 (Semantic Segmentation) - DeconvNet

Learning Deconvolution Network for Semantic Segmentation

Hyeonwoo Noh Seunghoon Hong Bohyung Han
Department of Computer Science and Engineering, POSTECH, Korea
{hyeonwoonoh, maga33, bhhan}@postech.ac.kr

[Learning deconvolution network for semantic segmentation](#)

[\[PDF\] thecvf.com](#)

[H Noh](#), [S Hong](#), [B Han](#)

Proceedings of the IEEE international conference on computer ..., 2015 - [openaccess.thecvf.com](#)


Abstract

We propose a novel semantic segmentation algorithm by learning a deep deconvolution network. We learn the network on top of the convolutional layers adopted from VGG 16-layer net. The deconvolution network is composed of deconvolution and unpooling layers, which identify pixelwise class labels and predict segmentation masks. We apply the trained network to each proposal in an input image, and construct the final semantic segmentation map by combining the results from all proposals in a simple manner. The

SHOW MORE ▾

☆ Save 99 Cite **Cited by 5218** Related articles All 20 versions 99

语义分割 (Semantic Segmentation) - DeconvNet




该网络包括两个部分，卷积网络和反卷积网络两部分：

- 卷积网络部分将输入图片转变为多维度的特征表示，用作提取特征
- 反卷积用于从提取的特征生成分割物体的形状。网络的最后一层输出是一张概率map，与输入图片的大小相同，表示每个像素代表属于某个类别的概率

该网络基于VGG16网络中卷积部分，有13层卷积，非线性，池化等操作参杂在卷积层中，卷积网络部分后面接着两层全连接层用于增强类别的分类，反卷积部分是卷积部分的镜像，反卷积网络结合反卷积，反池化，及非线性处理层等几个部分，通过反卷积与上采样操作扩大响应区域。

语义分割 (Semantic Segmentation) - DeconvNet



反卷积部分

- 反池化模块：卷积网络中的池化操作用于在较低层网络，通过抽象一定感受野范围的特征值来过滤部分噪声，虽然，池化操作得到的抽象信息对上层网络中有助于提高分类效果，但池化操作后，**图像的位置信息会有所损失**，不利于分割这种对位置信息要求高的任务。针对池化操作中位置信息的损失，反池化将池化操作中最大值变量的位置保存，在反池化的过程中进行恢复其在原图中的对应位置。
- 反卷积模块：反池化输出结果的尺寸虽然变大了，但特征值仍比较稀疏，通过引入反卷积来是特征变得密集。反卷积引入类似于卷积的卷积核，卷积是将多个输入通过一个滤波器输出一个值，**反卷积层的作用是捕捉不同层的形状信息**。较低层的卷积核捕捉整体的形状，而对于物体类别细节信息在较高层的网络中进行编码，**反卷积网络将类别细节信息，形状信息都考虑其中**。



语义分割 (Semantic Segmentation) - FCN



This CVPR2015 paper is the Open Access version, provided by the Computer Vision Foundation.
The authoritative version of this paper is available in IEEE Xplore.

Fully Convolutional Networks for Semantic Segmentation

Jonathan Long* Evan Shelhamer* Trevor Darrell
UC Berkeley
{jonlong, shelhamer, trevor}@cs.berkeley.edu

Fully convolutional networks for semantic segmentation


J Long, E Shelhamer, T Darrell - Proceedings of the IEEE ..., 2015 - openaccess.thecvf.com

... for per-pixel tasks like **semantic** segmentation. We show that a **fully convolutional network** (FCN) trained end-to-end, pixels-to-pixels on **semantic** segmentation exceeds the state-of-the-...

☆ Save ↀ Cite **Cited by 44580** Related articles All 52 versions ↀ

[PDF] thecvf.com

语义分割 (Semantic Segmentation) - FCN




神经网络结构只有卷积模块，在网络的尾端并没有全连接层。然后通过逐像素预测得到原图像中每个像素的预测结果。

对于一般的分类CNN网络，如VGG和ResNet，都会在网络的最后加入一些全连接层，经过 softmax后就可以获得类别概率信息。但是这个概率信息是1维的，即只能标识整个图片的类别，不能标识每个像素点的类别，所以这种全连接方法不适用于图像分割。

而FCN提出可以把后面几个全连接都换成卷积，这样就可以获得一张2维的feature map，后接 softmax层获得每个像素点的分类信息，从而解决了分割问题

语义分割 (Semantic Segmentation) - FCN



左图上半部分显示的是一个猫经过LeNet5神经网络，最终得到这张图像的分类结果，这是一种粗糙的图像检测/分类任务，全连接层1000个神经元，意味着有1000类。

要将全连接层换成卷积层很简单，例如原先网络最后一个卷积层是 $7 \times 7 \times \text{channel}$ ，将原本 $1 \times 1 \times 4096$ 的全连接层，转换成4096个 $7 \times 7 \times \text{channel}$ 卷积核即可，然后再接下来的两个全连接层替换成4096个 $1 \times 1 \times 4096$ 的卷积核、1000个 $1 \times 1 \times 4096$ 的卷积核。

但是这样做的意义不大，同样地丢失了WHERE信息。要得到像素级别的分类，为了得到一个heatmap（有一定的长和宽！），所以不需要这么大的kernel（比如上段的 $7 \times 7 \times \text{channel}$ 卷积核），只需要在需要**输出分辨率的特征中添加1000个 $1 \times 1 \times \text{channel}$ 的卷积核**即可。（假设1000为分类类别数量）。

https://mp.weixin.qq.com/s/2sw_OvSLiGVGIbbTc6TN0g



语义分割 (Semantic Segmentation) - DeepLab

系列网络由谷歌团队提出并发展

- **DeepLabV1**: Chen L C, Papandreou G, Kokkinos I, et al. Semantic Image Segmentation with Deep Convolutional Nets and Fully Connected CRFs[J]. Computer Science, 2014(4):357-361.
- **DeepLabV2**: L. -C. Chen, G. Papandreou, I. Kokkinos, K. Murphy and A. L. Yuille, "DeepLab: Semantic Image Segmentation with Deep Convolutional Nets, Atrous Convolution, and Fully Connected CRFs," in IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 40, no. 4, pp. 834-848, 2018
- **DeepLabV3**: Chen L C, Papandreou G, Schroff F, Adam H.: Rethinking atrous convolution for semantic image segmentation.2017, <https://doi.org/10.48550/arXiv.1706.05587>
- **DeepLabV3+**: Chen L C, Zhu Y, Papandreou G, Schroff F, Adam H.: Encoder-decoder with atrous separable convolution for semantic image segmentation. European Conference on Computer Vision, Berlin, 2018, pp. 833-851.



Liang-Chieh Chen 陈良杰

Research Scientist, ByteDance, LA
Verified email at cs.ucla.edu - [Homepage](#)

[Computer Vision](#) [Machine Learning](#)

做过分割、轻量化Backbone的同学应该都会知道这位CV巨佬，Liang-Chieh Chen 最著名的工作应该就是DeepLab (v1-v3+系列、Auto-deeplab、Axial-deeplab等) 和MobileNet系列 (v2和v3等)。



Cited by


	All	Since 2018
Citations	81298	78456
h-index	34	34
i10-index	44	41

语义分割 (Semantic Segmentation) - DeepLab

DeepLabV1

DeepLabV1[1]于2014年提出，在PASCAL VOC2012数据集上取得了分割任务第二名的成绩。该网络是研究FCN之后发现在FCN中池化层会使得特征图的长和宽不断下降，为了保证之后输出的尺寸不至于太小，FCN网络在第一层就对原图加了100的扩充，但这样会引入一些噪声，特征图尺寸的逐渐减小还会使得在语义分割时进行上采样，但是上采样并不能将丢失的信息全部无损的找回来，若是单单的去掉池化层，则会改变之前可用的结构，就不能再用以前的参数进行优化。

因此DeepLab的研究人员提出了**空洞卷积 (Dilated Convolutions)** 来解决这个问题：




空洞卷积最初的提出是为了解决图像分割的问题而提出的，常见的图像分割算法通常使用池化层和卷积层来**增加感受野(Receptive Filed)**，同时也**缩小了特征图尺寸(resolution)**，然后再利用上采样还原图像尺寸，特征图缩小再放大的过程造成了精度上的损失，因此需要一种操作**可以在增加感受野的同时保持特征图的尺寸不变**，从而代替下采样和上采样操作，在这种需求下，空洞卷积就诞生了。

<https://mp.weixin.qq.com/s/GulrRqub18Kyh7xAYrUVJw>

语义分割 (Semantic Segmentation) - DeepLab

DeepLabV2




DeepLabV2在前一代的基础上进行改进，依旧是使用空洞卷积，但主干网络已经替换为ResNet（V1使用的是VGG16），另外提出了空洞空间金字塔池化(ASPP)结构，如右图所示。

ASPP: 并行采用多个采样率的空间卷积提取特征，再将特征进行融合，该结构称为空洞空间金字塔池化

语义分割（Semantic Segmentation） - DeepLab


DeepLabV3



DeepLabV3去掉了最后的全连接随机条件场，同时进一步探讨了空洞卷积的使用，**让其在级联模块和空间金字塔池化的框架下获取更大的感受野，得到更多的信息**，还有ASPP模块，由不同采样率的空间卷积组成，以级联或并联的方式布局。

语义分割（Semantic Segmentation） - DeepLab

DeepLabV3+




DeepLabV3+是在V3的基础上加入了简单有效的解码模块去细化分割结果，还进一步探讨了Xception模型和ASPP模块，构造了更快更强的编码-解码网络

<https://mp.weixin.qq.com/s/61eloEmnCxDa-xpcyd26ig>

实例分割 (Instance Segmentation)

实例分割通常处理与可计数的物体相关的任务。它可以检测图像中每个物体或类别的实例，并为其分配一个带有唯一标识符的不同掩模或边界框。例如，在下图中，实例分割将分别识别出一辆小汽车、一辆公交车、两个骑自行车的行人（Bike_Person_1和Bike_Person_2）。




实例分割重点关心前景,相同的类别中不同的物体具有不同的实例ID

实例分割


实例分割 (Instance Segmentation)

常用的实例分割技术包括Mask R-CNN和PANet



实例分割 (Instance Segmentation) - Mask R-CNN

让我们先看看目标检测发展历程



第一代：R-CNN

R-CNN的意思就是Region based CNN，主要思路就是根据一张图像，**提取多个区域，再将每个区域输入CNN来进行特征的提取**。因此R-CNN就可以分为候选区域 (Region Proposals)，抽取特征 (Feature Extraction) 两个主要部分，提取的特征就可以输入任意一个分类器来进行分类。


R-CNN的目标是借助边界框 (Bounding Box) 获取图像，并正确地识别图像中的主要对象；它运用选择性搜索给出边界框或者候选区域，**选择性搜索通过不同尺寸的窗口在图像中进行滑动，然后通过纹理、颜色、亮度等特征将不同滑窗聚合，减少候选区域的数量，降低模型的复杂度**。

生成一组候选区域之后，**R-CNN将这些区域变换为标准的方形尺寸并采用改进后的AlexNet进行特征提取**。在CNN的最终层，R-CNN增加了**支持向量机** (Support Vector Machine, SVM)，用于简单判断区域中是否包含目标以及它是什么。

R-CNN效果非常好，但是**效率非常低**，训练困难主要的原因一是需要对每个图像的每个候选区域进行CNN (AlexNet) 前向传播 (Forward Pass)，每个图像需要大约2000次前向传播，存在大量重复计算；二是该方法必须分别训练三个不同的模型—CNN图像特征提取模型、SVM分类模型、线性边框回归模型，训练困难而且中间保存特征向量需占用大量的空间，这使得模型很难训练。

实例分割 (Instance Segmentation) - Mask R-CNN

让我们先看看目标检测发展历程



第二代: Fast R-CNN

2015年, R-CNN的作者Ross Girshick为解决R-CNN效率低、训练难的问题, 提出了Fast R-CNN的方法。

Fast R-CNN相对于R-CNN主要改进的一个方面在于, **不再是对每一个候选区域进行重复卷积操作, 而是对于整张图像先提取了泛化特征**, 这样子减少了大量的计算 (R-CNN中对于每一个候选区域做卷积会有很多重复计算), 并在**CNN中引入兴趣区池化层** (Region of interest pooling, RoIPooling), 这样图片首先进行选择性搜索生成候选区域, 同时在CNN中对整张图片进行特征提取, **将候选区域通过映射的方式在池化层特征图上确定位置和矩形框**。如此一来, 我们只需要一次原始图像的CNN前向传播, 而不是2000次;

另一方面, Fast R-CNN把分类从SVM改进为**softmax**, 并将**CNN、softmax分类和边界框线性回归的训练融合到一个模型中**, 降低了训练的难度。


实例分割

实例分割（Instance Segmentation） - Mask R-CNN

让我们先看看目标检测发展历程



第三代：Faster R-CNN




Anchor Box - RPN


Faster R-CNN的想法来源于候选区域的特征计算依赖于图像的特征，这些特征已经通过CNN的前向传播(分类的第一步)，那么为何不重用这些相同的CNN特征给出候选区，从而取代单独的选择性搜索，实际上，这就是Faster R-CNN方法的最大的改进。创新性的提出**候选框提取不一定非要在原图上做，可以考虑在特征图上做。继而提出了候选区域网络（Region Proposal Network, RPN），使得其可以抛弃传统的候选区域的方法，大幅加快训练速度。**

实例分割

实例分割 (Instance Segmentation) - Mask R-CNN



第三代: Faster R-CNN



Region Proposal Network (RPN)



实例分割 (Instance Segmentation) - Mask R-CNN



This ICCV paper is the Open Access version, provided by the Computer Vision Foundation.
Except for this watermark, it is identical to the version available on IEEE Xplore.

Mask R-CNN

Kaiming He Georgia Gkioxari Piotr Dollár Ross Girshick
Facebook AI Research (FAIR)

Mask r-cnn


[K He](#), [G Gkioxari](#), [P Dollár](#)... - Proceedings of the IEEE ..., 2017 - openaccess.thecvf.com

... **mask**, with minimal modification **Mask R-CNN** can be applied to detect instance-specific poses.

Without tricks, **Mask R-CNN** ... **masks** on the top 100 detection boxes, **Mask R-CNN** adds a ...

☆ Save 99 Cite **Cited by 30519** Related articles All 23 versions 》》

实例分割 (Instance Segmentation) - Mask R-CNN



第四代：Mask R-CNN

Mask R-CNN将Faster R-CNN扩展到像素级分割。原始的Faster R-CNN架构，由兴趣区池化层选择的特征图的区域与原始图像的区域稍有偏差，与边界框不同，图像分割需要像素级的特征，少量的偏差自然会导致不准确。

Mask R-CNN的作者通过巧妙地采用兴趣区对齐层（RoIAlign）的方法代替兴趣区池化层，使之更精确地对齐，从而解决了这个问题。


与Faster R-CNN不同，Mask R-CNN新增了一个输出，作为物体的mask。与Faster R-CNN类似的是，Mask R-CNN同样采用RPN来进行候选区域提取。但是在之后，对于每一个兴趣区域，Mask R-CNN还输出了一个二值化（二进制）的mask，说明给定像素是否是目标的一部分，从而实现像素级分割。所谓二进制mask，就是当像素属于目标的所有位置上时标识为1，其它位置标识为0。

RoI Pooling与RoI Align:


https://mp.weixin.qq.com/s/bXciyLf0_E_kfZqz2unJKA

实例分割

实例分割 (Instance Segmentation) - Mask R-CNN



Faster R-CNN



Mask R-CNN

RoI Pooling与RoI Align: https://mp.weixin.qq.com/s/bXciyLf0_E_kfZqz2unJKA



实例分割 (Instance Segmentation) - PANet



This CVPR paper is the Open Access version, provided by the Computer Vision Foundation.
Except for this watermark, it is identical to the version available on IEEE Xplore.

Path aggregation network for instance segmentation

[S Liu](#), [L Qi](#), [H Qin](#), [J Shi](#), [J Jia](#)

Proceedings of the IEEE conference on computer vision and ..., 2018 - openaccess.thecvf.com

Abstract

The way that information propagates in neural networks is of great importance. In this paper, we propose Path Aggregation Network (PANet) aiming at boosting information flow in proposal-based instance segmentation framework. Specifically, we enhance the entire feature hierarchy with accurate localization signals in lower layers by bottom-up path augmentation, which shortens the information path between lower layers and topmost feature. We present adaptive feature pooling, which links feature grid and all feature levels

SHOW MORE ▾

☆ Save 99 Cite **Cited by 5509** Related articles All 10 versions »

Path Aggregation Network for Instance Segmentation

Shu Liu[†] Lu Qi[†] Haifang Qin[§] Jianping Shi[‡] Jiaya Jia^{†,b}


[†]The Chinese University of Hong Kong [§]Peking University

[‡]SenseTime Research ^bYouTu Lab, Tencent

{sliu, luqi, leojia}@cse.cuhk.edu.hk qhfpku@pku.edu.cn shijianping@sensetime.com

实例分割


实例分割 (Instance Segmentation) - PANet



PANet是对Mask R-CNN的改进

增加了自底向上的路径，使低层信息更容易传播。作者设计了自适应特性池，允许每个proposal访问来自各个级别的信息进行预测。除此之外，作者在mask预测分支中加入了另一条支路。这种新结构带来了良好的性能。

实例分割 (Instance Segmentation) - PANet




自下而上的路径增强
Bottom-up Path Augmentation

自下而上的路径增强：主要是考虑到网络的**浅层特征对于实例分割非常重要**。浅层特征中包含大量边缘形状等特征，这对实例分割这种像素级别的分类任务是起到至关重要的作用的。因此，为了保留更多的浅层特征，引入了Bottom-up Path Augmentation。

红色的箭头表示在FPN中，因为要走自底向上的过程，浅层的特征传递到深层需要经过几十个甚至上百个网络层，当然这取决于BackBone网络用的什么，因此经过这么多层传递之后，浅层的特征信息丢失就会比较严重。

绿色的箭头表示添加了一个Bottom-up Path Augmentation结构，这个结构本身不到10层，这样浅层特征经过原始FPN中的横向连接到 P_2 然后再从 P_2 沿着Bottom-up Path Augmentation传递到深层，经过的层数不到10层，能较好的保存浅层特征信息。注意，这里的 N_2 和 P_2 表示同一个特征图。但 N_3, N_4, N_5 和 P_3, P_4, P_5 不一样，实际上 N_3, N_4, N_5 是 P_3, P_4, P_5 融合后的结果。


实例分割 (Instance Segmentation) - PANet



在Faster-RCNN系列目标检测或分割算法中，RPN网络得到的ROI需要经过ROI Pooling或ROI Align提取ROI特征，这一步操作中每个ROI所基于的特征都是单层特征。

Adaptive Feature Pooling则是将单层特征换成多层特征，即每个ROI需要和多层特征（论文中是4层）做ROI Align的操作，然后将得到的不同层的ROI特征融合在一起，这样每个ROI特征就融合了多层特征。RPN网络获得的每个ROI都要分别和特征层做ROI Align操作，这样个ROI就提取到4个不同的特征图，然后将4个不同的特征图融合在一起就得到最终的特征，后续的分类和回归都是基于此最终的特征进行。

实例分割 (Instance Segmentation) - PANet



全连接融合层对原有的分割支路(FCN)引入一个前景二分类的全连接支路，通过融合这两条支路的输出得到更加精确的分割结果。

这个结构主要是在原始的Mask支路（即带deconv那条支路）的基础上增加了下面那个支路做融合。增加的这个支路包含 $2 \times 3 \times 3$ 个的卷积层，然后接一个全连接层，再经过reshape操作得到维度和上面支路相同的前背景Mask，即是说下面这个支路做的就是前景和背景的二分类。最终，这两条支路的输出Mask做融合以获得更加精细的最终结果。

全景分割 (Panoptic Segmentation)

语义分割和实例分割技术的目标都是对场景进行连贯处理。自然而然，我们希望在场景中同时识别出物体和背景，以构建更实用的现实世界应用程序。研究人员提出了一种解决方案来统一处理场景中的物体和背景，即全景分割。



全景分割是两者兼具的最佳方案。它提供了一种统一的图像分割方法，其中场景中的每个像素都被分配了一个语义标签（通过语义分割）和一个唯一的实例标识符（通过实例分割）。

全景分割为每个像素分配了一个语义标签和一个实例标识符的配对。然而，物体之间的像素可能会重叠。在这种情况下，全景分割通过优先考虑物体实例来解决冲突，因为首要目标是识别每个物体而不是背景。

全景分割

全景分割 (Panoptic Segmentation)

大多数全景分割模型都基于Mask R-CNN方法。其主干架构包括UPNet、FPSNet、EPSNet和VPSNet

最新的全景分割方法包括: kMaX-DeepLab



全景分割（Panoptic Segmentation） - kMaX-DeepLab



European Conference on Computer Vision

→ ECCV 2022: **Computer Vision – ECCV 2022** pp 288–307 | [Cite as](#)

[Home](#) > [Computer Vision – ECCV 2022](#) > Conference paper

k-means Mask Transformer

[Qihang Yu](#) , [Huiyu Wang](#), [Siyuan Qiao](#), [Maxwell Collins](#), [Yukun Zhu](#), [Hartwig Adam](#), [Alan Yuille](#) & [Liang-Chieh Chen](#)

Conference paper | [First Online: 22 October 2022](#)

1845 Accesses | 7 Citations

Part of the [Lecture Notes in Computer Science](#) book series (LNCS, volume 13689)

k-means Mask Transformer

[Q Yu](#), [H Wang](#), [S Qiao](#), [M Collins](#), [Y Zhu](#)... - ... on Computer Vision, 2022 - Springer

... between **mask transformers** and the **k-means** clustering ... In this section, we first overview the **mask-transformer-based** ... the **transformer** cross-attention [89] and the **k-means** clustering ...

☆ Save  Cite Cited by 14 Related articles All 6 versions

[Submitted on 8 Jul 2022 (v1), last revised 10 Jul 2023 (this version, v5)]

kMaX-DeepLab: k-means Mask Transformer

[Qihang Yu](#), [Huiyu Wang](#), [Siyuan Qiao](#), [Maxwell Collins](#), [Yukun Zhu](#), [Hartwig Adam](#), [Alan Yuille](#), [Liang-Chieh Chen](#)

The rise of transformers in vision tasks not only advances network backbone designs, but also starts a brand-new page to achieve end-to-e (NLP), transformer architectures, consisting of self-attention and cross-attention, effectively learn long-range interactions between elements neglecting the crucial difference between languages and images, particularly the extremely large sequence length of spatially flattened pixel we rethink the relationship between pixels and object queries and propose to reformulate the cross-attention learning as a clustering proces segmentation tasks, which not only improves the state-of-the-art, but also enjoys a simple and elegant design. As a result, our kMaX-DeepL AP, and 83.5% mIoU, and ADE20K val set with 50.9% PQ and 55.2% mIoU without test-time augmentation or external dataset. We hope you [this https URL](#) A PyTorch re-implementation is also available at [this https URL](#)

Comments: ECCV 2022. arXiv v2: add results on ADE20K. arXiv v3: fix appendix. v4: fix typo. v5: add PyTorch re-implementation. Codes and models are availat

Subjects: **Computer Vision and Pattern Recognition (cs.CV)**

Cite as: [arXiv:2207.04044](#) [cs.CV]

(or [arXiv:2207.04044v5](#) [cs.CV] for this version)

<https://doi.org/10.48550/arXiv.2207.04044> 


kMaX-DeepLab: k-Means Mask Transformer

[Qihang Yu](#)¹, [Huiyu Wang](#)¹, [Siyuan Qiao](#)², [Maxwell Collins](#)², [Yukun Zhu](#)²,
[Hartwig Adam](#)², [Alan Yuille](#)¹, and [Liang-Chieh Chen](#)²

¹ Johns Hopkins University


² Google Research

全景分割（Panoptic Segmentation） - kMaX-DeepLab



包含三个主要组件：像素编码器、增强像素解码器和 kMaX 解码器。像素编码器通过 CNN 或Transformer 骨干提取像素特征，而增强像素解码器负责恢复特征图分辨率并通过Transformer编码器 增强像素特征或轴向注意力。最后， kMaX 解码器从 k-means 聚类的角度将目标查询（即聚类中心）转换为掩码嵌入向量。

全景分割 (Panoptic Segmentation) - kMaX-DeepLab



双路径 Transformer: 与卷积神经网络 (CNN) 上堆叠传统 Transformer 的方案不同, 我们提出了一种结合 CNN 与 Transformer 的双路径框架。具体而言, 我们通过一个双路径 Transformer 元件, 使 CNN 层能够从全局内存中读写数据。这里所说的这个元件采用了 CNN 路径和内存路径之间的所有四种注意力 (Attention) 类型, 可以插入到 CNN 中的任意位置, 从而允许在任何层与全局内存通信。

MaX-DeepLab 还利用堆叠的沙漏式解码器, 可将多种尺度特征聚合成高分辨率输出。然后系统会将该输出与全局内存特征相乘, 形成遮罩组预测。至于遮罩类别, 则使用另一种 Transformer 进行预测。

<https://zhuanlan.zhihu.com/p/540506595>

<https://discuss.tf.wiki/t/topic/1563>

总结



原图



语义分割




实例分割



全景分割

大数据与AI技术分享小栈



THANKS!