



第十节：图像识别-文字与指纹

杨聪






目录

CONTENTS

1. OCR文字识别 – 重点
2. 指纹识别 - 重点
3. 声纹识别 – 扩展阅读




OCR文字识别

OCR (Optical Character Recognition, 光学字符识别) 是指电子设备 (例如扫描仪或数码相机) 检查纸上打印的字符, 通过检测暗、亮的模式确定其形状, 然后用字符识别方法将形状翻译成计算机文字的过程。


(上述为老的定义)

现在基本上使用OCR指代文字检测、文字识别、图表识别等各类任务。



文本检测 (Scene Text Detection)

文本识别 (Scene Text Recognition)



End-to-End文本识别

文本检测背景与目标

识别图片中所有的文本实例（text instance），即一个单词或者一行话



相关工作：

1. 基于Box-regression的文本检测
2. 融入位置信息的文本检测（以Segmentation-Based为主）
3. 基于关系（Link）的文本检测
4. 基于Metric learning的文本检测

基于Box-regression的文本检测

TextBoxes++: A Single-Shot Oriented Scene Text Detector

Omnidirectional Scene Text Detection with Sequential-free Box Discretization

EAST: An Efficient and Accurate Scene Text Detector

Scene Text Detection with Supervised Pyramid Context Network

Arbitrary Shape Scene Text Detection with Adaptive Text Region Representation


基于Box-regression的文本检测

基本思路:

利用目标检测的方法 (Faster R-CNN等) 直接回归出text instance 的位置

研究关注点:

如何处理非矩形的text instance




基于Box-regression的文本检测

TextBoxes++: A Single-Shot Oriented Scene Text Detector

2018-TIP-华中科技大学-引用量91

改进了多方向的text instance的表达方式

该方法基于SSD回归出文本的四个顶点，其表达方式如下：
预测四个顶点的在 (x,y) 上的偏移




基于Box-regression的文本检测

EAST: An Efficient and Accurate Scene Text Detector

2017-CVPR - 旷视科技 - 引用量247

预测每一个像素距离边缘的偏移量。。。。。

Table 1. Output geometry design




• RRPN

Arbitrary-Oriented Scene Text Detection via Rotation Proposals

2018-TM-复旦-引用量153

RRPN沿用了Faster-rcnn中的RPN的思想(即使用其来生成候选区域), 并在此基础上进行了改进, 提出了基于旋转候选网络区域(RRPN). 整个网络结构和Faster-rcnn非常相似, RRPN也是分成并行两路: 一路用于预测类别, 另一路用于回归旋转矩形框. RRPN模块主要是用于生成带倾斜角的候选区域, 该层输出包括候选框的类别和旋转矩形框的回归; 再通过RRoI层(它扮演的是最大池化层的作用)将RRPN生成的候选框映射到特征图上, 得到最终的文本行检测结果.



• CTPN

Detecting Text in Natural Image with Connectionist Text Proposal Network

2016-ECCV-中国科学院深圳先进技术研究院-引用量271


• 解决的问题

Faster rnn直接检测文本时，由于文本检测不同于通用目标检测，文本之间距离很近，存在大量的字符笔画，导致Faster rnn检测效果不佳

• 解决方案

- 改进anchor机制

固定了anchor的宽度，等距离的生成anchor



• 解决方案

- LSTM

固定了anchor的宽度，来产生proposal，这样产生的proposal质量降低，因此采用lstm使得proposal具有相关性提升检测效果



Fig. 3: **Top:** CTPN without RNN. **Bottom:** CTPN with RNN connection.

• TextBoxes

TextBoxes: A Fast Text Detector with a Single Deep Neural Network

17-AAAI-华中科技大学-引用量227

- TextBoxes是在SSD的基础上进行改进的。相比SSD做了以下的改进：1).修改了default box的aspect ratio，分别为[1 2 3 5 7 10]，目的是适应文本行长度比较长，宽度比较短的特性；2).提出了text-box层，修改classifier卷积核的大小为这样做的目的是更适合文本行的检测，避免引入非文本噪声；3).提出了端到端的训练框架，并通过增加文本识别来提高文本行检测的效果





Figure 2: Illustration of default boxes for a 4*4 grid. For better visualization, only a column of default boxes whose aspect ratios 1 and 5 are plotted. The rest of the aspect ratios are 2,3,7 and 10, which are placed similarly. The black (aspect ratio: 5) and blue (ar: 1) default boxes are centered in their cells. The green (ar: 5) and red (ar: 1) boxes have the same aspect ratios and a vertical offset(half of the height of the cell) to the grid center respectively.

• TextBoxes++

- TextBoxes++是TextBoxes的扩展版，同样也是SSD的改进版，具体做了一下改进：1).修改最后的回归边框，将TextBoxes的水平边框改成普通四边形 (quadrilaterals) 或旋转矩形 (rbox)；2).修改了default box的aspect ratio 1, 2, 3, 5, 1/2, 1/3, 1/5 3).修改了网络结构中的部分参数，具体为：1).将TextBoxes中的最后的全局平均池化层(global average pooling layer)改成卷积层；2).修改Text-box layer中的卷积核大小为3x5




Fig. 2: The architecture of TextBoxes++, a fully convolutional network including 13 layers from VGG-16 followed by 10 extra convolutional layers, and 6 Text-box layers connected to 6 intermediate convolutional layers. Each location of a text-box layer predicts an n-dimensional vector for each default box consisting of the text presence scores (2 dimensions), horizontal bounding rectangles offsets (4 dimensions), and rotated rectangle bounding box offsets (5 dimensions) or quadrilateral bounding box offsets (8 dimensions). A non-maximum suppression is applied during test phase to merge the results of all 6 text-box layers. Note that “#c” stands for the number of channels.

• EAST

EAST思想非常简单，结合了DenseBox和Unet网络中的特性，具体流程如下：1).先用一个通用的网络(论文中采用的是Pvanet，实际在使用的时候可以采用VGG16，Resnet等)作为base net，用于特征提取；2).基于上述主干特征提取网络，抽取不同level的feature map，这样可以得到不同尺度的特征图。目的是解决文本行尺度变换剧烈的问题，early stage可用于预测小的文本行，late-stage可用于预测大的文本行；3).特征合并层，将抽取的特征进行merge。这里合并的规则采用了U-net的方法，合并规则：从特征提取网络的顶部特征按照相应的规则向下进行合并，这里描述可能不太好理解，具体参见下述的网络结构图；4).网络输出层，包含文本得分和文本形状。根据不同文本形状(可分为RBOX和QUAD)，输出也各不相同




Figure 3. Structure of our text detection FCN.


基于Box-regression的文本检测

Scene Text Detection with Supervised Pyramid Context Network

2019-AAAI-旷视科技-引用量12

基于Mask R-CNN直接获取任意形状的文字 instance

其核心工作是在网络中添加了attention，提高了网络性能



融入位置信息的文本检测

Pixellink- Detecting Scene Text via Instance Segmentation

Accurate Scene Text Detection through Border Semantics Awareness and Bootstrapping

Arbitrary Shape Scene Text Detection with Adaptive Text Region Representation

Shape Robust Text Detection with Progressive Scale Expansion Network

Efficient and Accurate Arbitrary-Shaped Text Detection with Pixel Aggregation Network

TextSnake- A Flexible Representation for Detecting Text of Arbitrary Shapes

融入位置信息的文本检测

基本思路：

预测边缘在哪里，然后对结果进行优化

预测像素点在text instance中的位置，然后对结果进行优化

Position-based;
Kernel-based;
Kernel+Position

融入位置信息的文本检测

预测边缘在哪里，然后对结果进行优化

PixelLink- Detecting Scene Text via Instance Segmentation

Accurate Scene Text Detection through Border Semantics Awareness and Bootstrapping


Arbitrary Shape Scene Text Detection with Adaptive Text Region Representation

融入位置信息的文本检测

PixelLink: Detecting Scene Text via Instance Segmentation

2018-AACL-浙江大学-引用量64

PixelLink放弃了边框回归的思想，采用实例分割的方法，分割出文本行区域，然后直接找对应文本行的外接矩形框。论文中给出了两种网络结构：PixelLink+VGG16 2s和PixelLink+VGG16 4s，对于PixelLink+VGG16 2s网络结构：其融合的特征层包括：{conv2_2, conv3_3, conv4_3, conv5_3, fc_7}，得到的特征图分辨率为原图的二分之一，对于PixelLink+VGG16 4s网络结构：其融合的特征层包括：{conv3_3, conv4_3, conv5_3, fc_7}，得到的特征图分辨率为原图的四分之一，整个实现过程包括两部分：先通过深度学习网络预测pixel positive和link positive，并根据link positive连接pixel positive得到文本实例分割图，然后从分割图中直接提取文本行的bbox




融入位置信息的文本检测

预测边缘在哪里，然后对结果进行优化

Accurate Scene Text Detection through Border Semantics Awareness and Bootstrapping

2018-ECCV-南洋理工-引用量17




融入位置信息的文本检测

Arbitrary Shape Scene Text Detection with Adaptive Text Region Representation

2019-CVPR-三星-引用量0

在获取text proposal之后，利用LSTM回归出文本的关键点




融入位置信息的文本检测

Pyramid Mask Text Detector

2019-CVPR-旷视科技-引用量4

修改了Mask-RCNN的Mask Branch，利用位置信息构建一个金字塔形的Ground Truth

1) 普通基于实例分割的方法只是将text从图片中分割出来而没有考虑gt的shape信息（四边形），pmtd则融入了shape信息（采用了soft lal平面聚类算法




融入位置信息的文本检测

TextField- Learning A Deep Direction Field for Irregular Scene Text Detection

2019-TIP- 华中科技大学-引用量7

Ground Truth为各text instance中每个像素距离最近non-text像素的方向



融入位置信息的文本检测

预测像素点在text instance中的位置，然后对结果进行优化– Kernel-based

Shape Robust Text Detection with Progressive Scale Expansion Network



Efficient and Accurate Arbitrary-Shaped Text Detection with Pixel Aggregation Network

融入位置信息的文本检测

Shape Robust Text Detection with Progressive Scale Expansion Network



2019-CVPR-旷世科技-引用量14

Ground Truth为text instance多个收缩结果;



融入位置信息的文本检测


Efficient and Accurate Arbitrary-Shaped Text Detection with Pixel Aggregation Network
与PSENet较相似



融入位置信息的文本检测

TextSnake- A Flexible Representation for Detecting Text of Arbitrary Shapes


2018-ECCV-北京大学-引用量39



融入位置信息的文本检测

Look More Than Once- An Accurate Detector for Text of Arbitrary Shapes

2019-CVPR-百度-引用量3



基于关系 (Link) 的文本检测


Detecting Oriented Text in Natural Images by Linking Segments
Towards Robust Curve Text Detection with Conditional Spatial Expansion
Character Region Awareness for Text Detection

基于关系 (Link) 的文本检测

Detecting Oriented Text in Natural Images by Linking Segments

2017-CVPR-华中科技大学-引用量151

SegLink是在SSD目标检测方法的基础上进行改进，其基本思想：既然一次性检测整个文本行比较困难，就先检测局部片段，然后通过规则将所有的片段进行连接，得到最终的文本行，这样做的好处是可以检测任意长度的文本行。该方法提出了文本行检测的两个基本组成元素：segment和link；通过改进的网络同时预测不同尺度的segments和link；根据不同的link（层内连接(within-layer link)和跨层连接(cross-layer link)）得到最终的文本行



• CRAFT

Character Region Awareness for Text Detection

2019-CVPR-Clova AI Research-引用量9

这篇论文的主要是解决文本检测的问题，思路是利用分割的方法，与图像分割有些不同的是，CRAFT不是对整个图像进行像素级分类，而是做了回归，它有两个分支，一个是目标是字符的中心的概率（这里用概率可能不是很准确，或许说是距离字符中心的距离更好一些），另一个是字符之间的连接关系，然后经过一步后处理，得到文本的边界框。




Figure 3. Illustration of ground truth generation procedure in our framework. We generate ground truth labels from a synthetic image that has character level annotations.




Figure 4. Illustration of the overall training stream for the proposed method. Training is carried out using both real and synthetic images in a weakly-supervised fashion.

基于Metric Learning的文本检测

Learning Shape-Aware Embedding for Scene Text Detection
Detecting Text in the Wild with Deep Character Embedding Network

基于Metric Learning的文本检测

Learning Shape-Aware Embedding for Scene Text Detection

2019-CVPR-港中文-引用量 3

利用metric learning学习每一个text instance
各像素的向量，并利用该向量对所有元素
进行聚类，得到最终的text instance





Figure 1. Given an input image (a), our model learns to map pixels in text regions (b) into an embedding space (c) where pixels belonging to the same instance are pulled together and pixels from different instances are pushed away from each other.

基于Metric Learning的文本检测

Detecting Text in the Wild with Deep Character Embedding Network

2019-ACCV-百度-引用量 1

利用metric learning学习每一个text instance 各字符的向量，并利用该向量对所有元素进行聚类，得到最终的text instance



数据库基本信息

数据库	图像数			标注级别				水平/倾斜	语言
	训练集	测试集	总计	字符	单词	文本线	分割		
ICDAR2003	258	251	509	有	有	无	无	水平	英文
ICDAR2011	229	255	484	无	有	无	无	水平	英文
ICDAR2013 /ICDAR2015-Focus	229	233	462	有	有	无	有	水平	英文
ICDAR2015- Incidental	1000	500	1500	无	有	无	无	倾斜	英文
SVT	100	250	350	无	有	无	无	水平	英文
MSRA-TD500	200	300	500	无	无	有	无	倾斜	中英文
CASIA_Multilingual	248	239	487	无	无	有	无	水平	中英文
IIIT5K-Word	2000	3000	5000	有	有	无	无	水平	英文
Synth80k	——	——	858750	无	有	无	无	水平	英文
Synth90k	——	——	约90k	无	有	无	无	水平	英文
SCUT_FORU_English	1200	515	1715	有	有	无	无	水平	英文
SCUT_FORU_Chinese	1861	355	2216	有	无	无	无	水平	中文
COCO-Text	43686	20000	63686	无	有	无	五	水平	英文
KAIST	——	——	3000	有	有	无	有	水平	中英韩文
OSTD	——	——	89	有	无	无	有	倾斜	英文
USTB	500	500	1000	无	有	无	无	倾斜	英文
Chars74k	7705个自然场景字符, 3410个手写字符, 62992 个合成字符			有	无	无	无	水平	英文
Chinese Text in the Wild	32,285 张图像和 1,018,402 个中文字符			有	有	无	无	倾斜	中文

数据库功能

数据库	水平/倾斜	语言	检测			识别		端到端	分割
			字符检测	单词检测	文本线检测	字符识别	单词识别		
ICDAR2003	水平	英文	✓	✓		✓	✓	✓	
ICDAR2011	水平	英文		✓			✓	✓	
ICDAR2013 /ICDAR2015-Focus	水平	英文	✓	✓		✓	✓	✓	✓
ICDAR2015-Incidental	倾斜	英文		✓			✓	✓	
SVT	水平	英文		✓			✓	✓	
MSRA-TD500	倾斜	中英文			✓				
CASIA_Multilingual	水平	中英文			✓				
IIIT5K-Word	水平	英文				✓	✓		
Synth80k	水平	英文		✓			✓		✓
Synth90k	水平	英文					✓		
SCUT_FORU_English	水平	英文	✓	✓		✓	✓	✓	
SCUT_FORU_Chinese	水平	中文	✓						
COCO-Text	水平	英文		✓			✓	✓	
KAIST	水平	中英韩文	✓	✓		✓	✓	✓	✓
OSTD	倾斜	英文	✓						✓
USTB	倾斜	英文		✓			✓	✓	
Chars74k	水平	英文				✓			

文本识别任务：

识别裁剪后图片中的字符序列



hollywood

文本识别的最常用解决方法：


基于序列的方法(如LSTM等)，逐个识别字符；

文本识别中存在的问题以及相关解决方案：

文本不规则-->图片修正

无法有效提取特征-->Attention模块

训练时Label存在不对齐情况-->修改loss



文本识别的最常用解决方法：

基于序列的方法，逐个识别字符；

文本识别中存在的问题以及相关解决方案：

文本不规则-->图片修正

无法有效提取特征-->Attention模块

训练时Label存在不对齐情况-->修改loss


Input Image




Rectified Image



Text
Rectification
Network





hotel



ASTER- An Attentional Scene Text Recognizer with Flexible Rectification

2018-TPAMI-华中科技大学-引用量 38



本文核心工作为图片修正，即预测K个控制点用于修正图片；



MORAN- A Multi-Object Rectified Attention Network for Scene Text Recognition


2019-PR- 中南大学—引用量 11

本文核心工作为图片修正以及attention模块



2019-arxiv-平安科技-引用量 0

采用的是谷歌的《attention is all you need》，不需要基于LSTM等方法进行文本序列识别




(c) The architecture of MASTER model

ESIR- End-to-end Scene Text Recognition via Iterative Image Rectification
2019-CVPR-南洋理工-引用量 11

本文核心工作为图片修正


$$y = a_K * x^K + a_{K-1} * x^{K-1} + \dots + a_1 * x + a_0$$



Input Image




Iterative Rectification Network



Synthetically Supervised Feature Learning for Scene Text Recognition.

2018-ECCV-哥伦比亚大学-引用量 11

并不是直接修正图片，而是 期望 网络提取出的特征与修正后图片的特征是一致的；




Aggregation Cross-Entropy for Sequence Recognition

2019-CVPR-中南大学-引用量 1

计算loss时忽略label位置、序列顺序，而是用各字符数量计算loss

$$\mathcal{L}(\omega) = - \sum_{(I, S) \in \mathcal{Q}} \sum_{l=1}^L \log P(S_l | l, I; \omega)$$

$$\approx - \sum_{(I, S) \in \mathcal{Q}} \sum_{k=1}^{|\mathcal{C}^e|} \log P(\mathcal{N}_k | I; \omega)$$



Scene Text Recognition from Two-Dimensional Perspective

2019-AAAI- 华中科技大学- 引用量 10

该方法与上述方法存在较大区别，即利用多分类语义分割识别文本序列


该方法实际上不存在以下三个问题：

文本不规则-->图片修正

无法有效提取特征-->Attention模块

训练时Label存在不对齐情况-->修改loss

但需要字符级的标注，且预测的字符间隔需要大一些，同时忽略了语义信息；



1. Towards Unconstrained End-to-End Text Spotting
2. FOTS- Fast Oriented Text Spotting with a Unified Network
3. Mask TextSpotter- An End-to-End Trainable Neural Network for Spotting Text with Arbitrary Shapes
4. An end-to-end TextSpotter with Explicit Alignment and Attention
5. Deep TextSpotter- An End-to-End Trainable Scene Text Localization and Recognition Framework


文本识别的最常用解决方法：

与Mask-RCNN相似，利用Box-Regression获取text proposal，然后在此基础上预测文本序列

文本识别中存在的问题以及相关解决方案：

如何从feature map提取特征

如何识别文本序列—主要方向为如何利用attention提高网络性能




Deep TextSpotter- An End-to-End Trainable Scene Text Localization and Recognition Framework
2017-ICCV-Czech Technical University-引用量 63

该方法的Pipeline较具有代表性

首先获取旋转的Bounding-Box;


然后根据Bounding-Box在特征图上采样;

利用LSTM预测采样后特征图上对应的文本序列



FOTS- Fast Oriented Text Spotting with a Unified Network.


2018-CVPR-商汤科技-引用量 65



Towards Unconstrained End-to-End Text Spotting

2019-ICCV-Google-引用量 43



利用Mask取代图片修正（如Bounding-Box的旋转）；
逐像素的添加Attention



Towards Unconstrained End-to-End Text Spotting


2019-ICCV-Google-引用量 43

逐像素的添加Attention



Mask TextSpotter- An End-to-End Trainable Neural Network for Spotting Text with Arbitrary Shapes

18-ECCV-华中科技大学-引用量 53




指纹识别

1. 指纹分割




2. 预估局部脊线的方向



3. 计算局部脊线的频率

在某一方向上，单位长度中有多少个脊线，进而可以计算脊线的周期频率




可以在右图看到有9个左右的峰值。左边指纹图也可以数一下，大概也是9个指纹条纹


我们使用一组Gabor filter来进行contextual convolution，达到我们的增强的目的

4. 指纹增强处理

不同方向的Gabor滤波器



滤波结果



我们使用一组Gabor filter来进行contextual convolution，达到我们的增强的目的


4.指纹增强处理

最后，我们把所有的卷积操作之后的图片组合起来：对于每个像素，找到和这个像素的脊线方向最接近的filter，然后得到他的index，然后将相应卷积之后的结果拿出来，合并到最后的结果图像中，如此组装所有的像素点，得到最后的图像。




首先增强之后的脊线图片进行二值化，然后脊线细化（thinning），最后检测出来我们感兴趣的细节点（endpoint终结点, junction point分叉点）。


5.细节点提取



6. 细节点方向计算



对于一个终结点，顺着脊线寻找直到到另外一个细节点被找到，或者最远20像素被搜索到，这个时候的点和该细节点之间的角度就记录为该细节点的方向。




对于分叉细节点而言，考虑它的三个分支($\theta_1 \theta_2 \theta_3$)，计算最近的两个分支的平均值作为该点的方向。如右图的 θ_1 和 θ_2 。

7. 指纹特征表征


Minutia Cylinder-Code (MCC) 是指纹里面，最最最有名的指纹特征表征。MCC发表在IEEE T-PAMI，影响非常大。感兴趣可以查询原文（这里不做过多细节解释，大家还可以回忆一下log-polar坐标）：

Minutia Cylinder-Code: a new representation and matching technique for fingerprint recognition", IEEE T-PAMI 2010



就是选择前 p 个最高的相似度，然后计算均值作为最终的相似度

8. 指纹特征匹配






<https://zhuanlan.zhihu.com/p/355000298>


看例子：jupyter notebook

声纹识别 (Speaker Recognition) - 扩展阅读


<https://zhuanlan.zhihu.com/p/381526743>



说话人验证
(他在说话?)



说话人辨认
(谁在说话?)



THANKS!