



第十一节：图像识别-生物特征1

杨聪







目录

CONTENTS

1. 指纹识别
2. 声纹识别 (扩展阅读)
3. 耳纹识别 (扩展阅读)
4. 掌纹识别 (扩展阅读)
5. 行为识别



生物特征



生物识别技术（英语：biometrics，也称生物测定学），是指用数理统计方法对生物进行分析，现在多指对生物体（一般特指人）本身的生物特征来区分生物体个体的计算机技术。


研究领域主要包括声音、脸、指纹、掌纹、虹膜、视网膜、体型、个人习惯（例如敲击键盘的力度和频率、签字）等，相应的识别技术就有说话人识别（声纹）、人脸识别、指纹识别、耳纹识别、步态识别、掌纹识别、虹膜识别、视网膜识别、体形识别、键盘敲击识别、签字识别、指静脉识别。

指纹识别

1. 指纹分割




2. 预估局部脊线的方向



3. 计算局部脊线的频率

在某一方向上，单位长度中有多少个脊线，进而可以计算脊线的周期频率




可以在右图看到有9个左右的峰值。左边指纹图也可以数一下，大概也是9个指纹条纹


我们使用一组Gabor filter来进行contextual convolution，达到我们的增强的目的

4.指纹增强处理

不同方向的Gabor滤波器



滤波结果



我们使用一组Gabor filter来进行contextual convolution，达到我们的增强的目的


4.指纹增强处理

最后，我们把所有的卷积操作之后的图片组合起来：对于每个像素，找到和这个像素的脊线方向最接近的filter，然后得到他的index，然后将相应卷积之后的结果拿出来，合并到最后的结果图像中，如此组装所有的像素点，得到最后的图像。




首先增强之后的脊线图片进行二值化，然后脊线细化（thinning），最后检测出来我们感兴趣的细节点（endpoint终结点, junction point分叉点）。


5.细节点提取



6. 细节点方向计算



对于一个终结点，顺着脊线寻找直到到另外一个细节点被找到，或者最远20像素被搜索到，这个时候的点和该细节点之间的角度就记录为该细节点的方向。




对于分叉细节点而言，考虑它的三个分支($\theta_1 \theta_2 \theta_3$)，计算最近的两个分支的平均值作为该点的方向。如右图的 θ_1 和 θ_2 。

7. 指纹特征表征


Minutia Cylinder-Code (MCC) 是指纹里面，最最最有名的指纹特征表征。MCC发表在IEEE T-PAMI，影响非常大。感兴趣可以查询原文（这里不做过多细节解释，大家还可以回忆一下log-polar坐标）：

Minutia Cylinder-Code: a new representation and matching technique for fingerprint recognition",
IEEE T-PAMI 2010



就是选择前 p 个最高的相似度，然后计算均值作为最终的相似度

8. 指纹特征匹配






<https://zhuanlan.zhihu.com/p/355000298>

看例子：jupyter notebook




声纹识别 (Speaker Recognition) - 扩展阅读

<https://zhuanlan.zhihu.com/p/381526743>



说话人验证
(他在说话?)





说话人辨认
(谁在说话?)

耳纹识别 (Ear Identification) - 扩展阅读

<https://ibug.doc.ic.ac.uk/resources/ibug-ears/>

<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC7594944/>



参考代码: <https://github.com/dhruvsingh50/Ear-Biometrics-in-Human-Identification-System/tree/master>



掌纹识别 (Palmprint Recognition) - 扩展阅读

掌纹是指手指末端到手腕部分的手掌图像。其中很多特征可以用来进行身份识别：如主线、皱纹、细小的纹理、脊末梢、分叉点等。掌纹识别技术也是一种非侵犯性的识别方法，用户比较容易接受，对采集设备要求不高。

首先对采集的掌纹训练样本进行预处理，然后进行特征提取，把提取的掌纹特征存入特征数据库中留待与被分类样本进行匹配。测试样本分类阶段是对获取的测试样本经过与训练样本相同的预处理、特征提取步骤后，送入分类器进行分类。

这两部分都包括以下三步：**掌纹图像采集、预处理以及特征提取。**

掌纹图像采集


掌纹图像采集的目的就是利用某种数字设备实现把掌纹转换成可以用计算机处理的矩阵数据。一般采集的都是二维灰度图像。

预处理

预处理的目的是使所采集的掌纹图像能方便对图像后续处理，如去除噪声使图像更清晰，对输入测量引起或其他因素所造成的退化现象进行复原，并对图像进行归一化处理。

特征提取


经过预处理的信息数据往往十分庞大，因此需要对信息数据进行特征提取和选择，即用某种方法把数据从模式空间转换到特征子空间。使得在特征空间中，数据具有很好的区分能力。



掌纹识别 (Palmprint Recognition) - 扩展阅读

A robust algorithm for extracting ROI from palm image *taken by mobile phone*

<https://github.com/leosocy/RobustPalmRoi>





掌纹识别 (Palmprint Recognition) - 扩展阅读

EDCC: An efficient and accurate algorithm for palmprint-recognition

<https://github.com/leosocy/EDCC-Palmprint-Recognition>

Database	N=2	N=4	N=6	N=8
Multispectral_B	98.6800%	99.8750%	99.9667%	99.9800%
Multispectral_G	98.8400%	99.8500%	99.9333%	99.9500%
Multispectral_I	98.9200%	99.9000%	99.9000%	99.9000%
Multispectral_R	98.8400%	99.7500%	99.8667%	99.9000%
Tongji	98.8056%	99.6979%	99.9881%	99.9861%


Python

```
import edcc

config = edcc.EncoderConfig(29, 5, 5, 10)
encoder = edcc.create_encoder(config)
one_palmprint_code = encoder.encode_using_filename("./palmprint_one.bmp")
another_palmprint_code = encoder.encode_using_filename("./palmprint_another.bmp")
similarity_score = one_palmprint_code.compare_to(another_palmprint_code)
```




行为识别



赛事分析

行为识别




识别打架

行为识别




街道监控

行为识别



室内监控




MMAction2工具箱

OpenMMLab 项目开源了 MMAction2，这是一套基于 PyTorch 实现的视频理解工具箱和 benchmark，目前包含了视频理解领域常见的任务，比如动作识别，时序动作检测，时空动作检测等

<https://mp.weixin.qq.com/s/Q2LepSg8wzcrQ8smbugxcA>

<https://mp.weixin.qq.com/s/nXCbqXSH8HtJC84wlmLueQ>



MMAction2工具箱

OpenMMLab 项目开源了 MMAction2，这是一套基于 PyTorch 实现的视频理解工具箱和 benchmark，目前包含了视频理解领域常见的任务，比如动作识别，时序动作检测，时空动作检测等。

<https://mp.weixin.qq.com/s/Q2LepSg8wzcrQ8smbugxcA>
<https://mp.weixin.qq.com/s/nXCbqXSH8HtJC84wlmLueQ>



动作识别任务

Task1: 未修剪视频分类(Untrimmed Video Classification)。这个有点类似于图像的分类, 未修剪的视频中通常含有多个动作, 而且视频很长。有许多动作或许都不是我们所关注的。所以这里提出的Task就是希望通过对输入的长视频进行全局分析, 然后软分类到多个类别。


Task2: 修剪视频识别(Trimmed Action Recognition)。这个在计算机视觉领域已经研究多年, 给出一段只包含一个动作的修剪视频, 要求给视频分类。

Task3: 时序行为提名(Temporal Action Proposal)。这个同样类似于图像目标检测任务中的候选框提取。在一段长视频中通常含有很多动作, 这个任务就是从视频中找出可能含有动作的视频段。

Task4: 时序行为定位(Temporal Action Localization)。相比于上面的时序行为提名而言, 时序行为定位于我们常说的目标检测一致。要求从视频中找到可能存在行为的视频段, 并且给视频段分类。

Task5: 密集行为描述(Dense-Captioning Events)。之所以称为密集行为描述, 主要是因为该任务要求在时序行为定位(检测)的基础上进行视频行为描述。也就是说, 该任务需要将一段未修剪的视频进行时序行为定位得到许多包含行为的视频段后, 对该视频段进行行为描述。比如: man playing a piano


动作识别方法概述 – (1) 基于单帧的识别方法



将视频进行截帧，然后基于单帧进行识别。

视频的某一帧通过网络获得一个识别结果。左图为一个典型的CNN网络，红色矩形是卷积层，绿色是归一化层，蓝色是池化层，黄色是全连接层。然而一张图相对整个视频是很小的一部分，特别当这帧图没有那么的具有区分度，或是一些和视频主题无关的图像，则会让分类器摸不着头脑。因此，学习视频时间域上的表达是提高视频识别的主要因素。当然，这在运动性强的视频上才有区分度，在较静止的视频上只能靠图像的特征了。

动作识别方法概述 – (2) 基于CNN扩展网络的识别方法




总体思路是在CNN框架中寻找时间域上的某个模式来表达局部运动信息，从而获得总体识别性能的提升。

左图网络结构，它总共有三层，在第一层对10帧（大概三分之一秒）图像序列进行 $M \times N \times 3 \times T$ 的卷积（其中 $M \times N$ 是图像的分辨率，3是图像的3个颜色通道， T 取4，是参与计算的帧数，从而形成在时间轴上4个响应），在第2、3层上进行 $T=2$ 的时间卷积，那么在第3层包含了这10帧图片的所有的时空信息。该网络在不同时间上的同一层网络参数是共享参数的。


它的总体精度在相对单帧提高了2%左右，特别在运动丰富的视频，如摔角、爬杆等强运动视频类型中有较大幅度的提升，这从而也证明了特征中运动信息对识别是有贡献的。在实现时，这个网络架构可以加入多分辨的处理方法，可以提高速度。

动作识别方法概述 – (3) 双路CNN的识别方法



两个独立的神经网络，最后再把两个模型的结果平均一下。上面一个就是普通的单帧的CNN，而且文章当中提到了，这个CNN是在ImageNet的数据上pre-train，然后在视频数据上对最后一层进行调参。下面的一个CNN网络，就是把连续几帧的光流叠起来作为CNN的输入。另外，它利用multi-task learning来克服数据量不足的问题。其实就是CNN的最后一层连到多个softmax的层上，对应不同的数据集，这样就可以在多个数据集上进行multi-task learning。网络结构如上图所示。


动作识别方法概述 – (4) 基于LSTM的识别方法



红色是卷积网络，灰色是LSTM单元，黄色是softmax分类器。LSTM把每个连续帧的CNN最后一层卷积特征作为输入，从左向右推进时间，从下到上通过5层LSTM，最上的softmax层会每个时间点给出分类结果。同样，该网络在不同时间上的同一层网络参数是共享参数的。在训练时，视频的分类结果在每帧都进行BP(back Propagation)，而不是每个clip进行BP。在BP时，后来的帧的梯度的权重会增大，因为在越往后，LSTM的内部状态会含有更多的信息。


在实现时，这个网络架构可以加入光流特征，可以让处理过程容忍对帧进行采样，因为如每秒一帧的采样已经丢失了帧间所隐含的运动信息，光流可以作为补偿。

动作识别方法概述 – (5) 三维卷积核 (3D CNN) 法



3D CNN 应用于一个视频帧序列图像集合，并不是简单地把图像集合作为多通道来看待输出多个图像（这种方式在卷积和池化后就丢失了时间域的信息，如上图左），而是让卷积核扩展到时间域，卷积在空域和时间域同时进行，输出仍然是有机的图像集合（如上图右）。

实现时，将视频分成多个包含16帧的片段作为网络的输入（维数为 $3 \times 16 \times 128 \times 171$ ）。池化层的卷积核的尺寸是 $d \times k \times k$ ，第一个池化层 $d=1$ ，是为了保证时间域的信息不要过早地被融合，接下来的池化层的 $d=2$ 。所有卷积层的卷积核大小为 $3 \times 3 \times 3$ ，相对其他尺寸的卷积核，达到了精度最优，计算性能最佳。网络结构如下图所示。这个是学习长度为16帧（采样后）视频片段的基础网络结构。对于一个完整的视频，会被分割成互相覆盖8帧的多个16帧的片段，分别提取他们的fc6特征，然后进行一个简单平均获得一个4096维的向量作为整个视频的特征。





经典行为识别算法包括：


- TSN
- TSM
- R(2+1)D
- I3D
- SlowOnly
- SlowFast
- CSN
- TIN
- TPN
- C3D
- X3D
- NonLocal
- OminiSource
- MultiModality: Audio

本节课重点介绍两类：

- 时空双流网络结构（Two-Stream）
- 人体骨架+LSTM系列

课外阅读：<https://mp.weixin.qq.com/s/JzlsC7nxpd6wnrH0k3aMPA>

时空双流网络结构 (Two-Stream)



Two-Stream Convolutional Networks for Action Recognition in Videos” (2014NIPS), Two Stream方法最初在这篇文章中被提出。

- 在空间部分，以单个帧上的外观形式，携带了视频描绘的场景和目标信息。其自身静态外表是一个很有用的线索，因为一些动作很明显地与特定的目标有联系。
- 在时间部分，以多帧上的运动形式，表达了观察者（摄像机）和目标者的运动。


基本原理为:

- 对视频序列中每两帧计算密集光流，得到密集光流的序列（即temporal信息）。
- 然后对于视频图像（spatial）和密集光流（temporal）分别训练CNN模型，两个分支的网络分别对动作的类别进行判断。
- 最后直接对两个网络的class score进行fusion（包括直接平均和svm两种方法），得到最终的分类结果。

注意，对两个分支使用了相同的2D CNN网络结构，其网络结构见上图。实验效果：UCF101-88.0%，HMDB51-59.4%

行为识别

时空双流网络结构 (Two-Stream)



Convolutional Two-Stream Network Fusion for Video Action Recognition" (2016CVPR), 对上面的工作进行了改进:


双流+LSTM

- 改进1: CNN网络进行了Spatial以及Temporal的融合
 - 在two stream network的基础上, 利用CNN网络进行了spatial以及temporal的融合, 从而进一步提高了效果;
 - 该文章还将基础的spatial和temporal网络都换成了VGG-16 network。
- 改进2: LSTM网络融合双流spatial以及temporal

实验效果: UCF101-92.5%, HMDB51-65.4%

行为识别

时空双流网络结构（Two-Stream）



Temporal Segment Networks: Towards Good Practices for Deep Action Recognition (ECCV 2016), 进行了进一步改进。

Spatial + Temporal Fusion


TSN (Temporal Segment Networks)

这篇文章对如何进一步提高two stream方法进行了详尽的讨论，主要包括几个方面：

- 输入类型：除去two stream原本的RGB image和 optical flow field这两种输入外，章中还尝试了RGB difference及 warped optical flow field两种输入。终结果是 RGB + optical flow + warped optical flow的组合效果最好。
- 网络结构：尝试了GoogLeNet,VGGNet-16及BN-Inception三种网络结构，其中BN-Inception的效果最好。
- 技巧包括跨模态预训练，正则化，数据增强等。

结果：UCF101-94.2%，HMDB51-69.4%

时空双流网络结构 (Two-Stream)



Temporal Segment Networks: Towards Good Practices for Deep Action Recognition (ECCV 2016), 进行了进一步改进。

Spatial + Temporal Fusion


TSN (Temporal Segment Networks)

two-stream 卷积网络对于长范围时间结构的建模无能为力，主要因为它仅仅操作一帧（空间网络）或者操作短片中的单堆帧（时间网络），因此对时间上下文的访问是有限的。视频级框架TSN可以从整段视频中建模动作。

和two-stream一样，TSN也是由空间流卷积网络和时间流卷积网络构成。但不同于two-stream采用单帧或者单堆帧，**TSN使用从整个视频中稀疏地采样一系列短片，每个片段都将给出其本身对于行为类别的初步预测，从这些片段的“共识”来得到视频级的预测结果。**在学习过程中，通过迭代更新模型参数来优化视频级预测的损失值（loss value）。

行为识别

时空双流网络结构 (Two-Stream)




Temporal Segment Networks: Towards Good Practices for Deep Action Recognition (ECCV 2016), 进行了进一步改进。

Spatial + Temporal Fusion

TSN (Temporal Segment Networks)

由上图所示，一个输入视频被分为 K 段 (segment)，一个片段 (snippet) 从它对应的段中随机采样得到。不同片段的类别得分采用段共识函数 (The segmental consensus function) 进行融合来产生段共识 (segmental consensus)，这是一个视频级的预测。然后对所有模式的预测融合产生最终的预测结果。

时空双流网络结构 (Two-Stream)



TSN改进: Deep Local Video Feature for Action Recognition [CVPR2017]

TSN改进版本之一：加权融合

改进的地方主要在于fusion部分，不同的片段的应该有不同的权重，而这部分由网络学习而得，最后由SVM分类得到结果。

TSN改进版本二 时间推理

该论文关注时序关系推理。对于那些仅靠关键帧（单帧RGB图像）无法辨别的动作，如摔倒，其实可以通过时序推理进行分类。除了两帧之间时序推理，还可以拓展到更多帧之间的时序推理。通过对不同长度视频帧的时序推理，最后进行融合得到结果。该模型建立TSN基础上，在输入的特征图上进行时序推理。增加三层全连接层学习不同长度视频帧的权重。




人体骨架检测 + LSTM

人体骨架获得途径：

- 通过RGB图像进行关节点估计（Pose Estimation openpose工具箱）获得。
- 通过深度摄像机直接获得（例如Kinect）。每一时刻（帧）骨架对应人体的K个关节点所在的坐标位置信息，一个时间序列由若干帧组成。
- Stacked Hourglass Networks for Human Pose Estimation使用全卷积网络解决人体姿态分析问题。
- Realtime Multi-person 2D Pose Estimation using Part Affinity Fields基于部分亲和字段PAF(Part Affinity Field)的2D图像姿态估计。

人体骨架检测 + LSTM




提出通过将图神经网络扩展到时空图模型(称为时空图卷积网络(ST-GCN))来设计用于动作识别的骨架序列的通用表示。

如左图所示, 该模型建立在一系列骨架图之上, 其中每个**节点**对应于人体的一个关节。有**两种类型的边**, 即符合节点自然连通性的**空间边** (图中淡蓝色线条) 和跨越连续时间步长连接相同节点的**时间边** (淡绿色线条)。在此基础上构建了多层时空图卷积, 实现了信息沿图维和时间维的整合。(在这里我将Node、Edge描述为节点、边, 为GNN中的概念)

蓝点表示身体的关节, 人体关节之间的体内边缘是根据人体的自然连接来定义的。框架间的边缘连接连续框架之间的相同节点, 关节坐标用作ST-GCN的输入。

行为识别


人体骨架检测 + LSTM



Spatial-Temporal Graph Convolutional Networks for Skeleton-Based Action Recognition (AAAI, 2018)


- 将图卷积网络扩展到时空域，称为时空图卷积网络（ST-GCN）。对于每个关节而言，不仅考虑它在空间上的相邻关节，还要考虑它在时间上的相邻关节，也就是说将邻域的概念扩展到了时间上。
- 新的权重分配策略，文章中提到了三种不同的权重分配策略：

经过测试发现第三种策略效果最好，这是因为第三种策略实际上也包含了对末肢关节赋予更多关注的思想，通常距离重心越近，运动幅度越小，同时能更好的区分向心运动和离心运动。



- 图(b)：唯一划分，将节点和其1邻域节点划分到相同的子集中，使他们具有相同的label，自然也就具有相同的权重。这样的话每个kernel中的权重实际上就是一个 $1 \times N$ 的向量， N 是节点的特征维数。
- 图(c)：按距离划分，将节点自身划分为一个子集，1邻域划分到一个子集。每个kernel的权重是一个 $2 \times N$ 的向量。
- 图(d)：按节点与重心距离划分，距离重心更近（相对于中心节点）的1邻域节点为一个子集，距离重心更远的1邻域节点为一个子集，中心节点自身为1个子集。每个kernel的权重是一个 $3 \times N$ 的向量。

人体骨架检测 + LSTM



Spatial-Temporal Graph Convolutional Networks for Skeleton-Based Action Recognition (AAAI, 2018)

核心思想：

- 将图卷积扩展到了时域上，从而更好的发掘动作的运动特征，而不仅仅是空间特征。
- 设计了新的权重分配策略，能更加差异化地学习不同节点的特征。
- 合理的运用先验知识，对运动幅度大的关节给予更多的关注，潜在的体现在权重分配策略中。


结果： **cv = 88.3%**，表示在NTU RGB+D数据集上cross-view验证结果



人体骨架检测 + LSTM

1. Deep Progressive Reinforcement Learning for Skeleton-based Action Recognition (CVPR,2018), (**cv=89.8%**)
2. Part-based Graph Convolutional Network for Action Recognition(BMVC,2018), (**cv=93.2%**)
3. Actional-Structural Graph Convolutional Networks for Skeleton-based Action Recognition(arXiv,2019), (**cv=94.2%**)
4. An AttentionEnhanced Graph Convolutional LSTM Network for Skeleton-Based ActionRecognition(CVPR,2019), (**cv=95%**)

扩展阅读: <https://mp.weixin.qq.com/s/JzIsC7nxpd6wnrH0k3aMPA>



THANKS!